

**PENGEMBANGAN MODEL PENGUKURAN *ECHO CHAMBER*
DENGAN KONSENSUS KOMUNITAS *MULTI-LEVEL* BERBASIS
ANALISIS SENTIMEN DAN DETEKSI KOMUNITAS**

Laporan Tugas Akhir

Disusun sebagai syarat kelulusan tingkat sarjana

**Oleh
AMALIA PUTRI
NIM: 13522042**



**PROGRAM STUDI TEKNIK INFORMATIKA
SEKOLAH TEKNIK ELEKTRO & INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
Juli 2026**

**PENGEMBANGAN MODEL PENGUKURAN *ECHO*
CHAMBER DENGAN KONSENSUS KOMUNITAS *MULTI-
LEVEL* BERBASIS ANALISIS SENTIMEN DAN DETEKSI
KOMUNITAS**

Laporan Tugas Akhir

Oleh

AMALIA PUTRI

NIM: 13522042

Program Studi Teknik Informatika

Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

Telah disetujui dan disahkan sebagai Draft Laporan Tugas Akhir
di Bandung, pada tanggal <tanggal>

Pembimbing I,

Pembimbing II,

Dr. Masayu Leylia Khodra, S.T, M.T.

NIP. 197604292008122000

Dr. Aqsath Rasyid Naradhipa, S.T., M.T.

NIP. -

LEMBAR PERNYATAAN

Dengan ini saya menyatakan bahwa:

1. Pengerjaan dan penulisan Laporan Tugas Akhir ini dilakukan tanpa menggunakan bantuan yang tidak dibenarkan.
2. Segala bentuk kutipan dan acuan terhadap tulisan orang lain yang digunakan di dalam penyusunan laporan tugas akhir ini telah dituliskan dengan baik dan benar.
3. Laporan Tugas Akhir ini belum pernah diajukan pada program pendidikan di perguruan tinggi mana pun.

Jika terbukti melanggar hal-hal di atas, saya bersedia dikenakan sanksi sesuai dengan Pelanggaran Peraturan Akademik dan Kemahasiswaan Institut Teknologi Bandung khususnya Pasal 14.

Bandung, <tanggal>



Amalia Putri

NIM 13522042

ABSTRAK

PENGEMBANGAN MODEL PENGUKURAN *ECHO CHAMBER* DENGAN KONSENSUS KOMUNITAS *MULTI-LEVEL* BERBASIS ANALISIS SENTIMEN DAN DETEKSI KOMUNITAS

Oleh

AMALIA PUTRI

NIM: 13522042

Fenomena *echo chamber* pada media sosial memperkuat bias konfirmasi dan polarisasi opini publik. Penelitian sebelumnya oleh Aidira (2025) mengukur *Echo Chamber Ratio* (ECR) berdasarkan komunitas yang dideteksi menggunakan algoritma Louvain. Namun, pendekatan ini memiliki dua keterbatasan, yakni Louvain tidak menjamin keterhubungan internal komunitas (*disconnected subgraph*), dan skor sentimen pengguna belum dikalibrasi sehingga reliabilitas estimasi preferensi rendah.

Tugas akhir ini mengembangkan model pengukuran *echo chamber* terintegrasi dengan tiga kontribusi, yakni deteksi komunitas menggunakan algoritma Leiden yang menjamin komunitas *well-connected* dan Infomap berbasis aliran informasi digabungkan melalui *Multi-level Consensus Clustering*, kalibrasi probabilistik, serta penentuan *threshold* berbasis *null model* permutasi. Model dievaluasi pada tiga topik berbahasa Indonesia di Twitter (X), yakni *Indonesia Vaccination*, *Indonesia Gelap*, *Boikot Produk Israel*, *Ijazah Jokowi*, *Korupsi Haji*, dan *Keracunan MBG*.

Hasil menunjukkan Leiden menghasilkan komunitas $61-1.256\times$ lebih sedikit dibandingkan Louvain, mengonfirmasi fragmentasi komunitas pada Louvain. Hal ini mengonfirmasi bahwa Leiden lebih *well-connected* dibanding Louvain.

Kata kunci: *echo chamber*, *Echo Chamber Ratio*, algoritma Leiden, kalibrasi probabilistik, media sosial

KATA PENGANTAR

Puji syukur penulis panjatkan kepada Tuhan Yang Maha Esa, Allah SWT., atas rahmat dan karunia-Nya sehingga penulis dapat menyelesaikan Tugas Akhir yang berjudul "Pengembangan Model Pengukuran *Echo Chamber* dengan Konsensus Komunitas *Multi-level* Berbasis Analisis Sentimen dan Deteksi Komunitas" sebagai salah satu syarat untuk meraih gelar sarjana di Institut Teknologi Bandung.

Penyelesaian Tugas Akhir ini tidak lepas dari bimbingan, dukungan, dan bantuan berbagai pihak. Oleh karena itu, dengan segala kerendahan hati, penulis menyampaikan terima kasih yang sebesar-besarnya kepada:

1. Dr. Masayu Leylia Khodra, S.T., M.T. dan Dr. Aqsath Rasyid Naradhipa, S.T., M.T. selaku Pembimbing I dan II yang telah meluangkan waktu, memberikan arahan, masukan, serta motivasi yang sangat berharga selama proses penyusunan Tugas Akhir ini.
2. Dosen Penguji yang telah berkenan menguji dan memberikan masukan konstruktif untuk penyempurnaan Tugas Akhir ini.
3. Anggrahita Bayu Sasmita, M.T., Dr. Fariska Zakhralativa Ruskanda, S.T., M.T., dan Dr. techn. Muhammad Zuhri Catur Candra, S.T, M.T. selaku Dosen Wali yang telah membimbing dan mendampingi penulis selama menempuh perkuliahan di Program Studi Teknik Informatika ITB.
4. Ir. Dicky Prima Satya, S.T, M.T., Adi Mulyanto, S.T, M.T., Ir. Robithoh Annur, S.T., M.Eng., Ph.D., dan Tricya Esterina Widagdo, S.T., M.Sc. selaku Dosen mata kuliah Penyusunan Proposal dan Tugas Akhir yang telah memberikan fondasi metodologi penelitian yang sangat membantu dalam penyusunan laporan ini..
5. Seluruh Dosen Tahap Persiapan Bersama (TPB) dan Program Studi Teknik Informatika ITB yang telah membagikan ilmu dan wawasan berharga selama masa studi penulis.
6. Staf Tata Usaha Program Studi Teknik Informatika ITB yang telah membantu kelancaran proses administrasi selama perkuliahan dan penyusunan Tugas Akhir.

7. Beasiswa Luar Biasa yang telah memberikan bantuan finansial dan *mentoring* sehingga penulis dapat menempuh pendidikan dengan tenang dan berkembang secara akademik maupun personal.
8. Kedua orang tua dan Ir. Wiwi Mukti Wibawasari (Wak Wiwi) sebagai wali penulis, yang dengan penuh kasih sayang telah mendukung, mendoakan, dan memfasilitasi penulis selama menempuh pendidikan di ITB.
9. Kedua kakak penulis, Almarhum Ir. Arif Nugraha, S.T., M.T. (alumni Teknik Sipil 2010 ITB) dan Ir. Afif Darmawan, S.T., M.M. (alumni Teknik Kelautan 2013 ITB), yang telah menjadi inspirasi dan pendukung utama bagi penulis dalam memilih jurusan teknik di ITB.
10. Teman-teman Informatika 2022, atas dukungan moral, semangat, kerja sama, dan kebersamaan selama menempuh masa perkuliahan, terutama dalam menghadapi tantangan akademik bersama-sama.
11. Rekan-rekan Laboratorium Riset dan rekan-rekan diskusi yang telah memberikan masukan teknis, ide, serta kritik membangun selama proses pengerjaan Tugas Akhir.
12. Seluruh pihak yang tidak dapat penulis sebutkan satu per satu, yang telah memberikan kontribusi langsung maupun tidak langsung dalam penyelesaian Tugas Akhir ini.

Penulis menyadari bahwa laporan Tugas Akhir ini masih jauh dari sempurna. Oleh karena itu, kritik dan saran yang membangun sangat penulis harapkan demi perbaikan di masa mendatang. Akhir kata, penulis berharap semoga Tugas Akhir ini dapat memberikan manfaat dan kontribusi bagi pengembangan ilmu pengetahuan, khususnya dalam bidang analisis jaringan sosial dan pengukuran *echo chamber* di media sosial.

Bandung, DD MM YYYY



Penulis

DAFTAR ISI

ABSTRAK	iii
KATA PENGANTAR.....	iv
DAFTAR ISI.....	vi
DAFTAR LAMPIRAN	x
DAFTAR GAMBAR.....	xi
DAFTAR TABEL	xiv
DAFTAR SINGKATAN	xvi
DAFTAR ISTILAH	xviii
BAB I PENDAHULUAN.....	1
I.1 Latar Belakang.....	1
I.2 Rumusan Masalah.....	4
I.3 Tujuan dan Ukuran Keberhasilan Pencapaian	4
I.4 Batasan Masalah	5
I.5 Metodologi.....	5
BAB II KAJIAN PUSTAKA.....	7
II.1 Interaksi pada Media Sosial.....	7
II.2 <i>Echo chamber</i>	9
II.2.1 Inferensi Learning Individu.....	10
II.2.2 <i>Homophily</i> dalam Jaringan Interaksi.....	10
II.2.3 Bias dalam Difusi Informasi	12
II.2.4 Formulasi <i>Echo Chamber Ratio</i>	13
II.2.5 <i>Echo Chamber Ratio Threshold</i>	13
II.3 Konsensus <i>Multi-level</i>	15
II.4 Algoritma Deteksi Komunitas	19

II.4.1	Algoritma Louvain dan Algoritma Leiden.....	20
II.4.2	Algoritma Infomap.....	25
II.4.3	Alasan Komunitas <i>Well-Connected</i> Lebih Baik	27
II.4.4	Sinergi Leiden dan Infomap dalam Analisis <i>Echo chamber</i>	31
II.5	Penelitian Terkait.....	32
II.5.1	Analisis Komunitas Diskursif dengan Infomap dan Leiden (Blekanov dkk., 2021).....	32
II.5.2	Evaluasi Deteksi Komunitas Berbasis GNN dan <i>Baseline</i> Leiden (Bonafilia, 2023)	33
II.5.3	Integrasi ASBA dan Metrik Konsensus untuk <i>Echo chamber</i> (Aidira, 2025)	34
II.5.4	<i>Towards Echo chamber Assessment by Employing Aspect-Based Sentiment Analysis and GDM Consensus Metrics</i> (Amendola dkk., 2024) ...	36
II.5.5	Relevansi Penelitian Terdahulu dengan Kebutuhan Tugas Akhir	37
BAB III ANALISIS PERSOALAN DAN RANCANGAN SOLUSI.....		39
III.1	Analisis Persoalan	39
III.2	Analisis Solusi.....	41
III.2.1	Ketersediaan <i>Dataset</i>	41
III.2.2	Kalibrasi Probabilistik	42
III.2.3	Validasi Sentimen.....	44
III.2.4	Estimasi <i>User Leaning</i> , Bias Difusi, dan Pengukuran Homofili ...	46
III.2.5	Pembangunan Graf Interaksi dan Deteksi Komunitas.....	47
III.2.6	<i>Echo Chamber Rasio</i> (ECR).....	48
III.2.7	Analisis Komunitas Pro vs Kontra dan Pergeseran Topik.....	49
III.3	Rancangan Solusi	49
III.3.1	Praproses Teks	52

III.3.2	Kalibrasi Probabilistik	53
III.3.3	Estimasi <i>User Learning</i>	54
III.3.4	Pembangunan Graf Interaksi dan Deteksi Komunitas.....	55
III.3.5	Pengukuran Homofili.....	58
III.3.6	Pengukuran Bias Difusi	59
III.3.7	<i>Echo Chamber Ratio</i> (ECR)	59
III.3.8	Analisis Komunitas Pro vs Kontra dan Pergeseran Topik.....	60
III.4	Implementasi Solusi	61
III.4.1	Praproses Teks	61
III.4.2	Klasifikasi Sentimen (<i>fine-tuned model</i>)	62
III.4.3	Pembangunan Graf Interaksi	62
III.4.4	Deteksi Komunitas.....	63
III.4.5	Pengukuran Homofili.....	67
III.4.6	Bias Difusi	68
III.4.7	Perhitungan <i>Echo Chamber Ratio</i> (ECR).....	69
III.4.8	<i>Pipeline</i> Utama	71
BAB IV EKSPERIMEN DAN PENGUJIAN		73
IV.1	Eksperimen Praproses	73
IV.2	Eksperimen Klasifikasi Sentimen	74
IV.2.1	Performa Model <i>Fine-Tuned</i> XLM-RoBERTa.....	74
IV.2.2	Hasil Perbandingan Model.....	76
IV.2.3	Distribusi <i>Confidence Bucket</i>	80
IV.3	Eksperimen Kalibrasi Probabilistik.....	82
IV.4	Eksperimen Estimasi <i>User Learning</i>	85
IV.5	Eksperimen Deteksi Komunitas Algoritma Leiden dan Louvain.....	87

IV.6	Eksperimen Pengukuran <i>Echo chamber</i>	92
IV.6.1	Analisis <i>Homophily</i>	94
IV.6.2	Analisis <i>Diffusion Bias</i>	99
IV.7	Eksperimen Pergeseran Sentimen	101
IV.8	Uji Hipotesis Pengukuran <i>Echo Chamber</i>	106
IV.8.1	Perumusan Hipotesis.....	106
IV.8.2	Prosedur Pengujian	106
IV.8.3	Hasil Uji Hipotesis.....	107
IV.8.4	<i>Ground Truth</i> ECR	108
IV.8.5	Kesimpulan Uji Hipotesis.....	109
BAB V KESIMPULAN DAN SARAN		110
V.1	Kesimpulan	110
V.2	Saran	111
DAFTAR PUSTAKA		113

DAFTAR LAMPIRAN

Lampiran A. Analisis Masalah	115
Lampiran B. Pengguna Pasif dan Hubungan Tidak Simetris	116
Lampiran C. Gambaran Umum Solusi.....	117

DAFTAR GAMBAR

Gambar II.1. Struktur jaringan pengguna pada media sosial dengan polarisasi ideologis (Cinelli dkk., 2021).....	11
Gambar II.2. Hubungan antara <i>seed leaning</i> dan <i>influence set leaning</i> pada difusi informasi (Cinelli dkk., 2021).....	12
Gambar II.3. <i>Multi-level consensus framework</i> (Pho dkk., 2021).	15
Gambar II.4. <i>Ensemble Clustering Framework</i> (Pho dkk., 2021).	16
Gambar II.5. Sebuah graf yang menunjukkan struktur komunitas (Bonafilia, 2023).	20
Gambar II.6. Dua fase algoritma Louvain (Bonafilia, 2023).....	21
Gambar II.7. Tiga fase algoritma Leiden (Bonafilia, 2023).	23
Gambar II.8. Algoritma Louvain dapat menetapkan sebuah node ke sebuah komunitas dalam sebuah langkah yang optimal secara lokal, namun hal ini memisahkan komunitas satu dengan yang lain (Bonafilia, 2023).....	25
Gambar II.9. Algoritma Infomap dan pengurangan panjang kode yang dihasilkan untuk sampel <i>random walk</i> (Bonafilia, 2023).....	26
Gambar II.10. Penskalaan hasil benchmark untuk ukuran jaringan (Traag dkk., 2019).	27
Gambar II.11. Waktu proses versus kualitas untuk jaringan benchmark (Traag dkk., 2019).	28
Gambar II.12. Skala hasil benchmark untuk tingkat kesulitan partisi (Traag dkk., 2019).	28
Gambar II.13. Waktu proses iterasi pertama untuk jaringan empiris (Traag dkk., 2019).	29
Gambar II.14. Sistem <i>pipeline</i> (Amendola dkk., 2024).	36
Gambar III.1. Legenda BEAM Notation.....	50

Gambar III.2. Rancangan Solusi Sistem.	50
Gambar III.3. Analisis kalibrasi per tingkat <i>confidence</i>	54
Gambar III.4. <i>User leaning</i> (kiri) dan <i>leaning vs confidence</i> (kanan)	55
Gambar III.5. Graf topik: <i>Indonesia Vaccination</i> (kiri) dan graf topik: Boikot Produk Israel (kanan).	56
Gambar III.6. <i>Homophily</i> dari topik <i>Indonesia Vaccination</i>	58
Gambar III.7. <i>Pseudocode</i> praproses teks.....	62
Gambar III.8. <i>Pseudocode</i> klasifikasi sentimen.....	62
Gambar III.9. <i>Pseudocode</i> pembangunan graf interaksi.....	63
Gambar III.10. <i>Pseudocode</i> deteksi komunitas.....	67
Gambar III.11. <i>Pseudocode</i> pengukuran homofili	68
Gambar III.12. <i>Pseudocode</i> bias difusi	69
Gambar III.13. <i>Pseudocode</i> perhitungan ECR.....	71
Gambar III.14. <i>Pseudocode pipeline</i> utama.....	72
Gambar IV.1. <i>Confusion matrices</i> dari topik <i>Indonesia Vaccination</i>	76
Gambar IV.2. <i>Confusion matrices</i> dari topik Indonesia Gelap.....	76
Gambar IV.3. <i>Confusion matrices</i> dari topik Boikot Produk Israel.....	77
Gambar IV.4. <i>Macro-F1</i> dan akurasi pada <i>gold label</i>	77
Gambar IV.5. <i>Confidence bucket</i> dari <i>Indonesia Vaccination</i>	81
Gambar IV.6. <i>Confidence bucket</i> dari Indonesia Gelap.....	81
Gambar IV.7. <i>Confidence bucket</i> dari Boikot Produk Israel	81
Gambar IV.8. Analisis kalibrasi probabilistik pada topik <i>Indonesia Vaccination</i>	84
Gambar IV.9. Analisis kalibrasi probabilistik pada topik Indonesia Gelap.....	84
Gambar IV.10. Analisis kalibrasi probabilistik pada topik boikot produk Israel .	84
Gambar IV.11. <i>User leaning</i> dari topik <i>Indonesia Vaccination</i>	85

Gambar IV.12. <i>User leaning</i> dari topik Indonesia Gelap	86
Gambar IV.13. <i>User leaning</i> dari topik Boikot Produk Israel	86
Gambar IV.14. <i>User leaning</i> dari topik Korupsi Haji.....	86
Gambar IV.15. <i>User leaning</i> dari topik Ijazah Jokowi	87
Gambar IV.16. <i>User leaning</i> dari topik Keracunan MBG	87
Gambar IV.17. Komunitas pro vs kontra topik <i>Indonesia Vaccination</i>	89
Gambar IV.18. Komunitas pro vs kontra topik Indonesia Gelap.....	89
Gambar IV.19. Komunitas pro vs kontra topik Boikot Produk Israel	89
Gambar IV.20. Komunitas pro vs kontra topik Korupsi Haji	90
Gambar IV.21. Komunitas pro vs kontra topik Ijazah Jokowi	90
Gambar IV.22. Komunitas pro vs kontra topik Keracunan MBG	91
Gambar IV.23. Distribusi pergeseran sentimen <i>dataset Indonesia Vaccination</i>	102
Gambar IV.24. Distribusi pergeseran sentimen <i>dataset</i> Indonesia Gelap	102
Gambar IV.25. Distribusi pergeseran sentimen <i>dataset</i> Boikot Produk Israel ...	103
Gambar IV.26. Distribusi pergeseran sentimen <i>dataset</i> Korupsi Haji.....	103
Gambar IV.27. Distribusi pergeseran sentimen <i>dataset</i> Ijazah Jokowi	104
Gambar IV.28. Distribusi pergeseran sentimen <i>dataset</i> Keracunan MBG	104
Gambar V.1. Difusi bias topik <i>Indonesia Vaccination</i> Error! Bookmark not defined.	
Gambar V.2. Difusi bias topik Indonesia Gelap Error! Bookmark not defined.	
Gambar V.3. Difusi bias topik Boikot Produk Israel Error! Bookmark not defined.	
Gambar V.4. Difusi bias topik	Error! Bookmark not defined.
Gambar V.5. Difusi bias topik	Error! Bookmark not defined.
Gambar V.6. Difusi bias topik	Error! Bookmark not defined.

DAFTAR TABEL

Tabel II.1. Tinjauan umum jaminan yang diberikan oleh algoritma Louvain dan algoritma Leiden (Traag dkk., 2019)	23
Tabel II.2. Hasil dari evaluasi model	33
Tabel II.3. Pemetaan relevansi dan kelemahan penelitian terdahulu terhadap kebutuhan Tugas Akhir	37
Tabel III.1. Pemetaan <i>dataset</i> Aidira (2025) dan penulis	39
Tabel III.2. Contoh data yang diambil dari topik <i>Indonesia Vaccination</i>	42
Tabel III.3. Desain <i>system prompt</i> dan <i>user prompt</i>	45
Tabel III.4. Contoh sebelum dan setelah praproses teks.....	53
Tabel III.5. Keterangan dari suatu komunitas	56
Tabel III.6. Deteksi komunitas algoritma Leiden	57
Tabel III.7. Deteksi komunitas algoritma Louvain Error! Bookmark not defined.	
Tabel IV.1. Jumlah data mentah dan praproses	74
Tabel IV.2. Jumlah data per topik	74
Tabel IV.3. Evaluasi dari XLM RoBERTa.....	75
Tabel IV.4. Akurasi pada sampel 10K dengan <i>pseudo ground truth</i> IndSight.....	76
Tabel IV.5. <i>Macro-F1</i> pada gold label	78
Tabel IV.5. Contoh sentimen dari tiap model serta <i>gold label</i>	78
Tabel IV.6. Hasil kalibrasi probabilistik pada topik <i>Indonesia vaccination</i>	82
Tabel IV.7. Hasil kalibrasi probabilistik pada topik Indonesia gelap	82
Tabel IV.8. Hasil kalibrasi probabilistik pada topik boikot produk Israel.....	82
Tabel IV.9. Perbandingan jumlah komunitas Leiden vs Louvain.....	87
Tabel IV.10. Hasil pengukuran ECR pada ketiga <i>dataset</i>	92

Tabel IV.11. Perbandingan ECR antara Leiden dan Louvain.....	93
Tabel IV.12. Nilai <i>homophily</i> per <i>dataset</i>	94
Tabel IV.13. Hasil analisis <i>diffusion bias</i> pada ketiga <i>dataset</i>	99
Tabel IV.15. Distribusi jenis pergeseran sentimen pada ketiga <i>dataset</i>	105
Tabel IV.16. Hasil uji hipotesis <i>echo chamber</i>	107

DAFTAR SINGKATAN

Singkatan	Definisi	Halaman
ECR	Singkatan dari <i>Echo Chamber Ratio</i> , yakni metrik kuantitatif yang mengukur tingkat keterkurungan informasi dalam komunitas daring.	2
SIR	Singkatan dari <i>Susceptible-Infectious-Recovered</i> , yakni model difusi informasi yang mensimulasikan penyebaran opini di jaringan sosial.	12
IC	Singkatan dari <i>Independent Cascade</i> , yakni model penyebaran informasi berbasis probabilitas aktivasi yang digunakan untuk mengukur bias difusi.	46
MLCC	Singkatan dari <i>Multi-level Consensus Clustering</i> , yakni kerangka tujuh langkah yang menggabungkan beberapa hasil partisi komunitas menjadi satu partisi konsensus dengan memanfaatkan kesamaan antar <i>cluster</i> pada banyak level transisi.	16
SCCS	Singkatan dari <i>Simple Cluster-Cluster Similarity</i> , yakni fungsi kesamaan antar cluster pada kerangka MLCC yang dihitung dari proporsi anggota beririsan dan ukuran <i>cluster</i> .	17
ASBA	Singkatan dari Analisis Sentimen Berbasis Aspek, yakni teknik analisis teks yang menentukan polaritas sentimen pada tiap aspek atau topik di dalam sebuah dokumen.	3
GDM	Singkatan dari <i>Group Decision Making</i> , yakni kerangka konsensus yang mengukur kesepakatan opini di antara dua atau lebih pihak di dalam suatu komunitas.	31

Singkatan	Definisi	Halaman
GNN	Singkatan dari <i>Graph Neural Network</i> , yakni kelas model pembelajaran mesin yang beroperasi langsung pada struktur graf untuk tugas klasifikasi simpul atau prediksi tepi.	33
NER	Singkatan dari <i>Named Entity Recognition</i> , yakni teknik ekstraksi entitas bernama (orang, organisasi, lokasi) dari teks tidak terstruktur.	34
NMI	Singkatan dari <i>Normalized Mutual Information</i> , yakni metrik kesepakatan antara dua partisi <i>clustering</i> yang bernilai 0 (tidak sepakat) hingga 1 (identik).	33
ARI	Singkatan dari <i>Adjusted Rand Index</i> , yakni metrik kesepakatan antara dua partisi yang dikoreksi terhadap ekspektasi pengelompokan acak.	33
ECE	Singkatan dari <i>Expected Calibration Error</i> , yakni rata-rata perbedaan absolut antara <i>confidence</i> prediksi model dan akurasi aktual pada setiap bin kepercayaan.	43
CI	Singkatan dari <i>Confidence Interval</i> , yakni rentang nilai yang menyatakan tingkat keyakinan statistik terhadap suatu estimasi metrik.	108
API	Singkatan dari <i>Application Programming Interface</i> , yakni antarmuka pemrograman yang memungkinkan suatu aplikasi mengakses data atau layanan aplikasi lain.	8
KBBI	Singkatan dari Kamus Besar Bahasa Indonesia, yakni kamus baku bahasa Indonesia yang diterbitkan oleh Badan Pengembangan dan Pembinaan Bahasa.	7

DAFTAR ISTILAH

Istilah	Definisi	Halaman
<i>Echo chamber</i>	Kondisi pengguna media sosial lebih banyak berinteraksi dengan individu yang berpandangan serupa sehingga opini internal kelompok diperkuat dan eksposur terhadap sudut pandang berbeda menjadi terbatas.	1
<i>Filter bubble</i>	Lingkungan informasi homogen yang terbentuk akibat algoritma personalisasi pada platform digital, yang membatasi keragaman konten yang ditampilkan kepada pengguna.	9
Leiden	Algoritma deteksi komunitas berbasis optimasi modularitas yang menjamin partisi komunitas yang <i>well-connected</i> melalui tahap <i>refinement</i> .	3
Louvain	Algoritma deteksi komunitas berbasis optimasi modularitas yang sering menghasilkan komunitas yang tidak sepenuhnya terhubung (fragmentatif) karena tidak memiliki tahap <i>refinement</i> .	2
Infomap	Algoritma deteksi komunitas yang meminimalkan panjang deskripsi aliran informasi (<i>map equation</i>) berdasarkan simulasi <i>random walk</i> pada graf, sehingga sesuai untuk graf berarah.	3
Modularitas	Ukuran kualitas partisi komunitas yang membandingkan proporsi sisi internal aktual	19

Istilah	Definisi	Halaman
	dengan proporsi yang diharapkan pada jaringan acak, nilai positif menandakan struktur komunitas yang lebih padat dari ekspektasi acak.	
Komunitas <i>well-connected</i>	Komunitas yang seluruh anggotanya terhubung satu sama lain melalui jalur internal, sehingga tidak mengandung subgraf yang terputus.	27
<i>Random walk</i>	Proses stokastik berjalan acak antar simpul yang mengikuti distribusi bobot tepi, digunakan oleh Infomap untuk memodelkan dinamika aliran informasi.	25
<i>Map equation</i>	Fungsi objektif Infomap yang merepresentasikan panjang deskripsi rata-rata dari lintasan <i>random walk</i> pada partisi modular.	65
Konsensus opini	Tingkat keseragaman pandangan ideologis di antara pengguna dalam suatu komunitas, dihitung dari rerata kesepakatan (<i>agreement</i>) antar pasangan pengguna.	94
Konsensus partisi	Hasil penggabungan beberapa partisi komunitas dari algoritma berbeda menjadi satu partisi tunggal yang lebih stabil dan representatif.	64
Konsensus <i>multi-level</i>	Konsensus partisi yang dihitung dengan mempertimbangkan kesamaan antar <i>cluster</i> pada banyak level transisi <i>random walk</i>	15

Istilah	Definisi	Halaman
	$(P^1, P^2, \dots, P^L)$, bukan hanya pada hubungan langsung.	
<i>Multi-level</i>	Dalam konteks MLCC, merujuk pada banyak level matriks transisi probabilistik antar <i>cluster</i> di mana setiap level merepresentasikan jumlah langkah <i>random walk</i> yang berbeda, bukan berarti hierarki komunitas yang bersarang.	13
<i>Agreement</i>	Ukuran kesepakatan opini antara dua pengguna, dihitung sebagai $1 - \frac{ \text{leaning}_u - \text{leaning}_v }{2}$, bernilai 0 (berlawanan total) hingga 1 (identik).	48
<i>Insularity</i>	Proporsi sisi internal terhadap total sisi yang menyentuh suatu komunitas, nilai mendekati 1 menandakan komunitas terisolasi secara struktural.	70
<i>Ensemble clustering</i>	Pendekatan yang menjalankan beberapa algoritma atau konfigurasi <i>clustering</i> pada data yang sama untuk menghasilkan kumpulan partisi awal yang nantinya digabungkan melalui fungsi konsensus.	15
<i>Co-association matrix</i>	Matriks yang mencatat frekuensi pasangan titik data ditempatkan pada <i>cluster</i> yang sama di sepanjang partisi-partisi <i>ensemble</i> .	15
<i>Hierarchical clustering</i>	Algoritma <i>clustering</i> yang menghasilkan pohon (dendrogram) berisi <i>nested</i> partisi pada banyak level granularitas, dapat bersifat <i>agglomerative</i> (<i>bottom-up</i>) atau <i>divisive</i> (<i>top-down</i>).	18

Istilah	Definisi	Halaman
Kalibrasi probabilistik	Proses menyesuaikan keluaran probabilistik model agar mencerminkan frekuensi kejadian aktual sehingga skor kepercayaan dapat ditafsirkan secara konsisten.	4
<i>Isotonic regression</i>	Metode kalibrasi nonparametrik yang memetakan probabilitas mentah ke probabilitas terkalibrasi melalui fungsi monoton tak menurun.	43
<i>Temperature scaling</i>	Metode kalibrasi yang membagi logit model dengan satu parameter skalar (temperatur) sebelum <i>softmax</i> untuk mengoreksi <i>confidence</i> yang terlalu tinggi atau rendah.	43
<i>Homophily</i>	Kecenderungan individu untuk berinteraksi dengan pengguna lain yang memiliki pandangan atau preferensi serupa, diukur sebagai korelasi antara <i>leaning</i> pengguna dan rerata <i>leaning</i> tetangganya.	4
Bias difusi	Kecenderungan informasi untuk menyebar ke arah komunitas yang memiliki pandangan sejenis, diukur melalui simulasi <i>Independent Cascade</i> .	4
<i>User leaning</i>	Skor skalar dalam rentang $[-1, +1]$ yang merepresentasikan kecenderungan ideologis seorang pengguna terhadap suatu topik, dihitung dari rerata probabilitas sentimen seluruh kontennya.	46

Istilah	Definisi	Halaman
Polarisasi	Kondisi terbaginya populasi pengguna ke dalam kutub-kutub pandangan yang saling berlawanan terhadap suatu topik.	1
<i>Null model</i>	Distribusi acuan yang dihasilkan dari jaringan acak yang mempertahankan properti tertentu (misalnya, distribusi <i>degree</i>) dari jaringan asli, digunakan sebagai pembanding untuk menilai signifikansi metrik observasi.	48
<i>Permutation test</i>	Uji statistik nonparametrik yang menghasilkan distribusi acuan dengan mengacak label data berkali-kali untuk memperoleh <i>p-value</i> empiris. Menilai signifikansi metrik observasi.	48
<i>Bridge user</i>	Pengguna yang berada di satu komunitas namun memiliki proporsi koneksi signifikan ke komunitas berlawanan, berpotensi menjadi jembatan pertukaran informasi lintas kutub.	49
Pergeseran sentimen	Perubahan rata-rata sentimen seorang pengguna antara periode awal dan akhir interaksinya, dikategorisasi menjadi <i>stable</i> , <i>positive_to_negative</i> , <i>negative_to_positive</i> , <i>pro_to_contra</i> , atau <i>contra_to_pro</i> .	61
<i>Entropy</i>	Ukuran ketidakaturan atau ketidakpastian distribusi, digunakan pada metrik konsensus GDM untuk mengukur keseragaman opini komunitas.	35

Istilah	Definisi	Halaman
<i>Ground truth</i>	Label acuan yang dianggap benar dan digunakan untuk mengevaluasi performa model prediksi.	41
<i>Pseudo ground truth</i>	Label acuan pengganti yang diperoleh dari sumber otomatis (misalnya, API anotasi) ketika <i>ground truth</i> manusia tidak tersedia, digunakan sebagai pembanding evaluasi awal.	46
<i>Confidence threshold</i>	Nilai ambang batas tingkat kepercayaan model yang digunakan untuk menyaring prediksi yang dianggap reliabel.	44

BAB I

PENDAHULUAN

I.1 Latar Belakang

Perkembangan teknologi telah memengaruhi cara manusia berinteraksi dalam membentuk suatu opini. Media sosial merupakan media di era digital yang memungkinkan pengguna untuk menyampaikan pendapatnya sehingga dapat menyebarkan informasi dalam skala besar secara langsung. Di balik itu, muncul suatu fenomena yang disebut dengan *echo chamber*, yaitu kondisi ketika pengguna lebih banyak berinteraksi dengan individu yang memiliki pandangan serupa sehingga memperkuat opini internal dan membatasi eksposur terhadap sudut pandang yang berbeda.

Sunstein (2017) menekankan bahwa internet dan sosial media tidak secara melekat menciptakan *echo chamber*. *Echo chamber* baru terbentuk ketika interaksi sosial berlangsung secara eksklusif di antara individu yang sepandangan secara ideologis sehingga terjadi penguatan keyakinan dan peningkatan polarisasi. Dalam penelitiannya, tren yang kontroversial di tahun 2015, seperti tim kontra (lawan) Presiden Trump yang mengunggah tagar #NeverTrump dan tim pro (pendukung) yang mengunggah tagar #MakeAmericaGreatAgain merupakan fenomena *echo chamber*. Sedangkan tren lainnya, seperti hiburan atau olahraga tidak memenuhi karakteristik *echo chamber* atau disebut sebagai fenomena *non-echo chamber* karena tim pro dan kontra saling membaaur atau bersifat heterogen.

Sunstein (2017) menyatakan bahwa fenomena *echo chamber* sangat memengaruhi kualitas wacana publik. Ketika informasi bersirkulasi dalam ruang-ruang yang homogen secara ideologis, terjadi penguatan bias konfirmasi dan berkurangnya toleransi terhadap perbedaan pendapat. Cinelli dkk. (2021) menunjukkan bahwa polarisasi yang diperkuat oleh fenomena ini tidak hanya disebabkan oleh algoritma rekomendasi, tetapi juga muncul secara alami yang cenderung mencari dan menjalin koneksi dengan kelompok yang sepemikiran (*homophily*).

Berbagai penelitian telah mengusulkan metode kuantitatif untuk mengukur keberadaan dan kekuatan *echo chamber* di media sosial. Pendekatan awal umumnya berbasis struktur jaringan, dengan menganalisis pola konektivitas antar pengguna, seperti modularitas komunitas, atau keterpisahan kelompok pro dan kontra (Cinelli dkk., 2021). Pendekatan ini dapat menangkap pola homofili dan segmentasi jaringan dengan baik, namun cenderung mengabaikan makna konten yang dipertukarkan di jaringan. Di sisi lain, pendekatan berbasis konten berfokus pada analisis sentimen atau bias opini dalam teks untuk menilai homogenitas pandangan pengguna (Sunstein, 2017), tetapi sering kali tidak mempertimbangkan cara opini tersebut terbentuk dan menyebar melalui struktur sosial. Sebagai upaya menjembatani kedua sudut pandang tersebut, sejumlah penelitian telah mengembangkan pendekatan hibrida yang mengombinasikan analisis jaringan dan konten, salah satunya melalui metrik seperti *Echo Chamber Ratio* (ECR) yang mengaitkan struktur komunitas dengan distribusi preferensi informasi pengguna (Amendola dkk., 2024). Pendekatan hibrida ini memberikan kerangka yang lebih komprehensif karena mampu merepresentasikan baik pola interaksi sosial, maupun keseragaman opini yang terbentuk di dalamnya.

Metrik *Echo Chamber Ratio* (ECR) Amendola dkk. (2024) mengukur derajat polarisasi dengan membandingkan kesamaan opini dalam dan antar komunitas. *Echo chamber* diidentifikasi ketika komunitas menunjukkan konsensus internal yang tinggi namun memiliki konsensus rendah terhadap komunitas lain dan menandakan adanya homogenitas opini serta isolasi pandangan. Pendekatan ini tidak menetapkan satu nilai rasio tunggal, melainkan menilai *echo chamber* sebagai pola polarisasi konsensus yang muncul secara struktural (jaringan sosial) dan semantik (konten).

Penelitian Aidira (2025) menggunakan pendekatan algoritma Louvain untuk deteksi komunitas. Meskipun Louvain populer karena efisiensi dan berbasis optimasi modularitas, ini sering menghasilkan suatu komunitas yang terdiri dari beberapa komponen yang tidak saling terhubung (*disconnected subgraph*). Hal ini mengganggu validitas asumsi komunitas sebagai unit yang berhubungan erat dalam pengukuran *echo chamber* karena dalam komunitas seharusnya terjadi pertukaran informasi secara intensif dan menyeluruh antar anggotanya.

Dalam konteks tersebut, stabilitas struktur komunitas didefinisikan sebagai sejauh mana komunitas yang terdeteksi benar-benar mewakili ruang interaksi sosial yang konsisten dan bermakna. Algoritma Leiden Blekanov dkk. (2021), membentuk komunitas dengan keterhubungan internal yang kuat antar anggotanya sehingga menjamin setiap komunitas merupakan adalah subgraf yang terhubung kuat (*strongly connected*). Komunitas yang dihasilkan tidak bersifat kebetulan, melainkan terbentuk dari pola komunikasi yang berulang antar pengguna. Namun, algoritma Leiden berfokus pada pengelolaan keterhubungan jaringan sosial sehingga diperlukan algoritma yang juga mengelola arah alur informasi dari pengguna ke pengguna, yakni algoritma Infomap.

Algoritma Infomap menawarkan keunggulan karena menggunakan pendekatan berbasis aliran informasi (*random walks*) (Bonafilia, 2023). Infomap memodelkan dinamika penyebaran informasi dengan melihat bagaimana alur interaksi bergerak dari pengguna ke pengguna lain di dalam jaringan. Pendekatan ini menjadikan Infomap sangat relevan dalam konteks *echo chamber*, yang tidak hanya ditandai oleh keterpisahan struktur komunitas, tetapi juga oleh bias difusi konten dan arah aliran informasi. Studi Blekanov dkk. (2021) menunjukkan bahwa Infomap lebih stabil dalam mendeteksi komunitas diskursif pada data Twitter berskala besar dibandingkan metode yang memecah sistem kompleks menjadi bagian-bagian kecil. Independen, dan dapat diganti.

Kalibrasi probabilistik adalah proses untuk memastikan bahwa prediksi probabilistik dari suatu model benar-benar sesuai dengan frekuensi kejadian aktual. Dalam konteks ini, kalibrasi bukan sekadar memperbaiki akurasi klasifikasi atau regresi, melainkan menyesuaikan distribusi probabilitas prediktif model agar lebih konsisten dengan distribusi data sebenarnya (Dheur & Ben, 2023). Dalam analisis konten, pendekatan sebelumnya mempertimbangkan distribusi probabilistik dalam estimasi opini pengguna. Penelitian Aidira (2025) belum mengkalibrasi model sentimen yang digunakan sehingga skor preferensi pengguna belum merefleksikan tingkat keyakinan model secara akurat. Hal ini menjadi penting terutama pada Analisis Sentimen Berbasis Aspek (ASBA), di mana keluaran model berupa probabilitas polaritas opini per aspek sering digunakan langsung sebagai dasar pengukuran keselarasan opini. Dampak dari penggunaan kalibrasi probabilistik

dapat memengaruhi sentimen pada *dataset* konten sehingga dapat berpengaruh pada penilaian tingkat *echo chamber* dari intra dan inter komunitas. Tanpa kalibrasi probabilistik, reliabilitas estimasi preferensi menjadi tidak akurat (Dheur & Ben, 2023).

I.2 Rumusan Masalah

Penelitian Aidira (2025) menggabungkan analisis struktur jaringan dengan algoritma Louvain dan orientasi informasi pengguna. Namun, pendekatan hibrida ini memiliki keterbatasan pada stabilitas struktur komunitas dan reliabilitas estimasi preferensi. Kalibrasi probabilistik juga digunakan untuk memastikan bahwa distribusi orientasi informasi pengguna merefleksikan tingkat keyakinan model secara konsisten. Ini membuat pengukuran bias dan intensitas *echo chamber* lebih dapat diukur secara kuantitatif.

Berdasarkan latar belakang tersebut, maka rumusan masalah dalam tugas akhir ini adalah sebagai berikut.

- 1) Bagaimana pengaruh penggunaan teknik deteksi komunitas algoritma Leiden dan Infomap dalam pengukuran *echo chamber* dibandingkan dengan algoritma Louvain?
- 2) Bagaimana pendekatan kalibrasi probabilistik digunakan untuk menilai kekonsistenan orientasi informasi pengguna terhadap bias internal dan eksternal komunitas?

I.3 Tujuan dan Ukuran Keberhasilan Pencapaian

Tujuan utama dari tugas akhir ini adalah untuk menghasilkan model pengukuran *echo chamber* yang terintegrasi, dengan menggabungkan pendekatan berbasis graf, distribusi preferensi informasi, serta kalibrasi probabilistik dalam konteks percakapan publik media sosial berbahasa Indonesia. Ukuran keberhasilan dari tugas akhir ini ditentukan melalui pencapaian indikator, yakni berupa keterhubungan komunitas yang terhubung dengan baik, serta tingkat homofili antar pengguna, pola bias difusi informasi, dan nilai *Echo Chamber Ratio* (ECR) yang dihasilkan. Nilai ECR digunakan sebagai indikator kuantitatif utama untuk menilai intensitas *echo chamber*, dengan evaluasi tambahan dilakukan melalui konsistensi

hasil antar topik serta dampak penerapan kalibrasi probabilistik terhadap stabilitas pengukuran.

I.4 Batasan Masalah

Batasan dalam pelaksanaan Tugas Akhir ini adalah *Dataset* yang digunakan berupa percakapan publik berbahasa Indonesia dari media sosial Twitter (X).

I.5 Metodologi

Pelaksanaan tugas akhir ini dilakukan melalui beberapa tahapan teknis yang saling terhubung untuk menjawab rumusan masalah dan mencapai tujuan penelitian. Secara umum, metodologi yang digunakan mengintegrasikan pendekatan graf, deteksi komunitas, estimasi preferensi informasi, kalibrasi probabilistik, dan perhitungan metrik *echo chamber* secara kuantitatif. Adapun tahapan yang dilalui dalam pelaksanaan tugas akhir ini adalah sebagai berikut.

1) Pengumpulan dan analisis data

Data dikumpulkan dari media sosial Twitter (X) menggunakan kata kunci dan *hashtag* yang relevan untuk masing-masing topik, yakni Boikot Produk Israel, Indonesia Gelap, *Indonesia Vaccination*, Korupsi Haji, Ijazah Jokowi, dan Keracunan MBG. Setelah data terkumpul, dilakukan tahap pra-pemrosesan untuk menghapus duplikasi, menyaring akun bot, serta mengelompokkan interaksi antar pengguna (*retweet*, *mention*, dan *reply*) ke dalam format yang sesuai untuk pembangunan graf.

2) Analisis dan Perancangan Solusi

Menganalisis cara kerja algoritma Louvain untuk jaringan sosial pada komunitas yang dilakukan tanpa kalibrasi probabilistik. Merancang solusi dengan algoritma Leiden dengan kalibrasi probabilistik. Selain itu, menghitung nilai homofili dan bias difusi untuk menentukan nilai *Echo Chamber Ratio* (ECR).

3) Implementasi

Melakukan pembangunan graf interaksi dengan Leiden dan Infomap. Selain itu, menerapkan kalibrasi probabilistik pada penentuan sentimen konten, serta menghitung nilai homofili dan bias dengan bahasa pemrograman Python.

Menjelaskan model matematis dan representasi formal dari sistem, yakni definisi model graf, model komunitas berupa partisi Leiden dan Infomap, model preferensi berupa *leaning* pengguna dan distribusi probabilistik, serta model *echo chamber* yang berupa homofili dan bias.

4) Eksperimen

Menjalankan *pipeling* pada *dataset* yang menggunakan algoritma Leiden dan Infomap dengan dan tanpa kalibrasi, serta melakukan perbandingan hasil komunitas tersebut.

5) Pengujian

Menguji validitas jenis komunitas yang *well-connected* dan konsistensi preferensi komunitas, yakni dengan cara mengukur hasil stabilitas antar topik dan nilai kalibrasi yang memperbaiki distribusi. Selain itu, menguji kesesuaian nilai *Echo Chamber Ratio* (ECR) sesuai dengan intuisi sosial, beserta penjelasannya.

BAB II

KAJIAN PUSTAKA

II.1 Interaksi pada Media Sosial

Menurut KBBI, media sosial adalah aplikasi atau laman yang memungkinkan pengguna untuk membuat, berbagi, atau terlibat dalam jaringan sosial. Secara lebih rinci, ini merujuk pada platform online di mana pengguna dapat berpartisipasi secara aktif, berbagi, dan menciptakan konten seperti blog, jejaring sosial, wiki, forum, dan dunia virtual. Menurut Kaplan & Haenlein (2010), media sosial dapat didefinisikan sebagai “sekelompok aplikasi berbasis internet yang membangun ideologi dan penemuan teknologi dari Web yang membebaskan kreativitas dan pertukaran konten yang dibuat oleh pengguna”. Media sosial terdiri dari beberapa aplikasi, seperti Facebook, Youtube, atau Twitter. Dengan munculnya platform seperti Facebook, Twitter, LinkedIn, Instagram, dan Pinterest sebagai platform yang populer untuk berbagi informasi, opini, foto, dan hobi di seluruh dunia, media sosial menjadi populer dan menarik perhatian pengiklan, memicu pergeseran lebih besar dalam pengeluaran pemasaran dari media tradisional ke media digital.

Selain itu, media sosial dapat dijadikan suatu ruang untuk para pengguna mengakses dan membagikan sekian jumlah informasi yang tak terduga sehingga dapat mengubah cara pengguna dalam berinteraksi, berdebat, dan beropini. Adanya aktivitas tersebut, suatu individu atau komunitas dapat saling memengaruhi dan membentuk suatu polarisasi terhadap suatu topik. Hal ini menciptakan fenomena yang bernama *echo chamber*.

X adalah salah satu *platform* media sosial yang dahulunya bernama Twitter. *Platform* ini menyediakan berbagai fitur untuk pengguna agar dapat berinteraksi dengan pengguna lainnya, yakni *mention*, *reply*, dan *retweet*. Fitur-fitur tersebut merupakan komponen yang penting untuk berinteraksi sehingga dapat membangun, memperluas, serta memperkuat jaringan sosial digital. Pengumpulan data dari X

dapat dilakukan dengan cara *text scraping* menggunakan X API sebagai X Developer.

Mention adalah istilah yang digunakan ketika pengguna menyertakan *username* dengan cara menuliskan “@{username}” pada suatu unggahan. Dalam metadata *tweet* dari API X, *mention* tercatat dalam bagian "entities.user_mentions", yang memuat informasi tentang akun yang disebut (X, 2025). Menurut Jensen dkk. (2023), *mention* berfungsi untuk memperluas percakapan melampaui konteks awal sebuah unggahan sehingga dapat menciptakan jaringan interaksi lateral (antarpengguna) dibanding vertikal (pengguna dengan unggahan).

Reply merupakan bentuk interaksi langsung di platform X, yakni saat pengguna memberikan tanggapan terhadap unggahan (*tweet*) pengguna lain. Fitur ini memungkinkan terjadinya percakapan dua arah sehingga memperluas komunikasi dari sekadar penyiaran satu arah menjadi pertukaran pesan yang bersifat dialogis. Dalam metadata *tweet* pada X API, *reply* tercatat melalui atribut "in_reply_to_status_id" dan "in_reply_to_user_id", yang menandakan bahwa suatu unggahan merupakan balasan terhadap pengguna atau *tweet* tertentu (X, 2025). Dalam studi “*Twitter Users’ Behavioral Response to Toxic Replies*” (Aleksandric dkk., 2022) menemukan bahwa ketika pengguna menjadi sasaran *reply* toksik, pengguna punya reaksi seperti menghindar (*avoidance*), membalas (*reply* dalam bentuk vokal), atau bahkan unfollow pelaku.

Retweet merupakan fitur yang memungkinkan pengguna untuk membagikan kembali unggahan orang lain ke linimasa pengguna. Fitur ini berfungsi memperluas jangkauan pesan dan mempercepat penyebaran informasi di dalam jaringan sosial. Dalam metadata *tweet* pada X API, tindakan ini dicatat melalui atribut "retweeted_status", yang berisi informasi tentang *tweet* asli dan pengguna sumber (X, 2025). Dalam konteks penelitian *echo chamber*, Jensen dkk. (2023) menekankan bahwa perilaku *retweet* berperan besar dalam memperkuat struktur *echo chamber*. Dijelaskan bahwa kebiasaan *retweet* sering kali memperkuat narasi dari kelompok yang sehaluan, sehingga membentuk struktur informasi yang menggemakan pandangan internal kelompok itu sendiri. Dengan kata lain, *retweet*

menjadi sarana utama dalam memperkuat resonansi opini di dalam kelompok sosial yang homogen.

II.2 *Echo chamber*

Menurut Terren & Borge (2021), *echo chamber* adalah suatu situasi atau ruang, khususnya dalam konteks media sosial, yakni tempat pengguna “lebih banyak berinteraksi dengan orang-orang yang sependapat dan terpapar konten yang selaras secara ideologis,” sehingga pandangan yang sudah ada diulang dan diperkuat seperti gema dalam ruang tertutup. Kondisi ini sering disebabkan oleh *homophily* (kecenderungan berinteraksi dengan yang serupa), *selective exposure* (kecenderungan memilih informasi yang sejalan), dan *confirmation bias* (kecenderungan mencari dan menafsirkan informasi sesuai keyakinan). Selain itu, algoritma platform media sosial yang menyajikan konten berdasarkan perilaku dan preferensi pengguna turut memperkuat terbentuknya *echo chamber* digital yang tertutup.

Konsep *echo chamber* banyak dibahas dalam literatur demokrasi deliberatif dan komunikasi politik. Sunstein (2017) menjelaskan bahwa ketika individu berkumpul dalam kelompok yang berpandangan serupa, diskusi di dalam kelompok tersebut cenderung memperkuat kecenderungan awal kelompok, bahkan dapat mendorong kelompok ke posisi yang lebih ekstrem. Pariser (2011) menambahkan melalui konsep *filter bubble* bahwa algoritma personalisasi di internet dan media sosial dapat membatasi keragaman informasi yang ditampilkan kepada pengguna, sehingga kelompok hanya menerima konten yang sesuai dengan preferensi sebelumnya. Meskipun keduanya sering digunakan secara bergantian, *echo chamber* lebih menekankan pada interaksi sosial sesama pengguna, sedangkan *filter bubble* lebih fokus pada peran teknologi dan algoritma dalam membentuk lingkungan informasi yang homogen (Terren & Borge, 2021).

Echo Chamber Ratio (ECR) merupakan metrik yang digunakan untuk mengukur kekuatan *echo chamber* dalam jaringan sosial online melalui pendekatan kuantitatif terhadap struktur interaksi dan pola difusi informasi. Konsep dasar ECR berangkat dari definisi operasional *echo chamber* yang dikemukakan oleh Cinelli dkk. (2021), yang menekankan dua dimensi utama, yakni sebagai berikut.

- (1) *Homophily* dalam jaringan interaksi, yakni kecenderungan pengguna untuk berinteraksi dengan individu yang memiliki kecenderungan ideologis serupa.
- (2) *Bias* dalam difusi informasi ke arah kelompok sehaluan, yaitu sejauh mana informasi yang disebarkan oleh satu pengguna terutama menjangkau pengguna lain dengan pandangan ideologis yang sama.

II.2.1 Inferensi Leaning Individu

Langkah pertama adalah menentukan *leaning* atau kecenderungan ideologis setiap pengguna terhadap suatu topik tertentu. *Leaning* pengguna ke- i , dilambangkan dengan x_i , dihitung dari rata-rata leaning konten yang dihasilkan atau dukung, dapat dilihat pada persamaan 2.1 (Cinelli dkk., 2021).

$$x_i = \frac{1}{a_i} \sum_{j=1}^{a_i} c_j \quad (2.1)$$

Keterangan:

- 1) a_i adalah jumlah konten yang diproduksi atau didukung oleh pengguna i ,
- 2) c_j adalah nilai *leaning* konten ke- j (misalnya +1 untuk konten pro, -1 untuk konten kontra).

Rumus ini merepresentasikan posisi ideologis rata-rata pengguna. Misalnya, seorang pengguna yang konsisten membagikan konten pro-vaksin akan memiliki nilai x_i mendekati +1, sebaliknya akan memiliki nilai x_i yang mendekati -1. Pendekatan ini digunakan oleh Cinelli dkk. (2021) untuk menginferensi kecenderungan politik atau sikap pengguna terhadap topik kontroversial seperti vaksinasi, kontrol senjata, dan aborsi.

II.2.2 Homophily dalam Jaringan Interaksi

Setelah memperoleh *leaning* individu, langkah berikutnya adalah mengukur *homophily*, yaitu kecenderungan pengguna untuk berinteraksi dengan pengguna lain yang memiliki pandangan serupa. Jaringan sosial direpresentasikan sebagai graf berarah $G = (V, E)$. Untuk setiap pengguna i , dihitung rata-rata leaning tetangga keluar yang dapat dilihat pada persamaan 2.2 (Cinelli dkk., 2021).

$$x_i^N = \frac{1}{k_i^{\rightarrow}} \sum_j A_{ij} x_j \quad (2.2)$$


Keterangan:

- 1) $A_{ij} = 1$ jika terdapat interaksi dari pengguna i ke j , dan 0 jika tidak,
- 2) $k_i^{\rightarrow} = \sum_j A_{ij} x_j$ adalah jumlah tetangga keluar dari pengguna i ,
- 3) x_j adalah *leaning* pengguna j .

Nilai x_i^N mencerminkan orientasi ideologis rata-rata lingkungan sosial pengguna i . Jika x_i^N sangat mendekati x_i , maka pengguna tersebut berada dalam komunitas homogen secara ideologis, ciri khas *echo chamber* struktural. Untuk mengukur tingkat homophily secara global, digunakan koefisien korelasi antara x_i dan x_i^N dapat dilihat pada persamaan 2.3 (Cinelli dkk., 2021).

$$H = \text{corr}(x_i, x_i^N) \quad (2.3)$$

Nilai H mendekati 1 menunjukkan tingkat *homophily* tinggi, artinya interaksi dalam jaringan sangat tersegmentasi menurut pandangan ideologis. Sedangkan N merujuk pada *neighborhood* atau lingkungan sosial langsung dari node i di dalam graf. Pada Gambar II.1 ditunjukkan struktur jaringan pengguna pada media sosial dengan polarisasi ideologis.



Gambar II.1. Struktur jaringan pengguna pada media sosial dengan polarisasi ideologis (Cinelli dkk., 2021).

II.2.3 Bias dalam Difusi Informasi


Komponen kedua dari *echo chamber* mengukur bias dalam proses penyebaran informasi, yaitu sejauh mana informasi hanya menyebar di dalam kelompok ideologis yang sehaluan. Untuk ini digunakan model penyebaran informasi berbasis SIR (*Susceptible-Infected-Recovered*). Misalkan pengguna i menjadi sumber awal (*seed*) penyebaran, maka kumpulan pengguna yang menerima informasi tersebut disebut *influence set*, dilambangkan dengan I_i . *Leaning* rata-rata dari *influence set* dihitung menggunakan persamaan 2.4 (Cinelli dkk., 2021).

$$\mu_i = \frac{1}{|I_i|} \sum_{j \in I_i} x_j \quad (2.4)$$

Keterangan:

- 1) $|I_i|$ adalah jumlah pengguna dalam *influence set*,
- 2) x_j adalah *leaning* pengguna j yang menerima informasi.

Jika $\mu_i \approx x_i$, maka informasi dari pengguna *i* terutama menyebar kepada pengguna yang berpandangan serupa. Analisis ini dilakukan secara agregat melalui fungsi $\langle \mu(x) \rangle$, yaitu rata-rata μ_i untuk semua pengguna dengan *leaning* x . Jika $\langle \mu(x) \rangle$ hampir identik dengan x , maka difusi informasi bersifat “tertutup,” ciri khas *echo chamber* dinamis (Cinelli dkk., 2021). Pada Gambar II.2 ditunjukkan hubungan antara *seed leaning* dan *influence set leaning* pada difusi informasi.



Gambar II.2. Hubungan antara *seed leaning* dan *influence set leaning* pada difusi informasi (Cinelli dkk., 2021).

II.2.4 Formulasi *Echo Chamber Ratio*

Setelah kedua komponen tersebut diukur, *Echo Chamber Ratio* dirumuskan pada persamaan 2.5, yakni sebagai rasio antara kesepakatan intra-komunitas dan inter-komunitas, dengan mempertimbangkan kalibrasi probabilistik serta struktur komunitas *multi-level*. Formulasi ini dikembangkan berdasarkan kerangka konseptual yang dikemukakan oleh Cinelli dkk. (2021) dengan penyesuaian untuk memungkinkan perhitungan kuantitatif terhadap ekspektasi kesepakatan intra dan inter-komunitas. Formulasi ini digunakan untuk menghitung rasio *echo chamber* oleh Aidira (2025).

$$ECR = \frac{E[S_{intra}]}{E[S_{inter}]} \quad (2.5)$$

Keterangan:

- 1) S_{intra} adalah skor kesepakatan ideologis di dalam komunitas,
- 2) S_{inter} adalah skor kesepakatan antar komunitas yang berbeda,
- 3) $E[\cdot]$ menyatakan ekspektasi terhadap seluruh interaksi.

Rasio ini akan tinggi jika komunitas internal memiliki keseragaman opini yang kuat (intra tinggi) namun berbeda jauh dari komunitas lain (inter rendah), yang merupakan indikator kuat adanya *echo chamber*. Dalam ECR, sebelum perhitungan rasio, distribusi leaning x_i dapat dikalibrasi menggunakan *temperature scaling* atau *isotonic regression* agar probabilitas model sentimen menjadi lebih reliabel. Selanjutnya, agregasi dilakukan secara bertingkat: konten $\rightarrow$ pengguna $\rightarrow$ komunitas, untuk menangkap struktur komunikasi yang lebih realistis.

II.2.5 *Echo Chamber Ratio Threshold*

Pengukuran *Echo Chamber Ratio* (ECR) saja belum cukup untuk menyimpulkan suatu jaringan percakapan benar-benar menunjukkan fenomena *echo chamber*. Penentuan fenomena ini *echo chamber* atau bukan, memerlukan nilai ambang batas (*threshold*) yang dapat membedakan nilai ECR yang diperoleh merupakan fenomena struktural nyata atau hanya muncul akibat ketidakaturan acak dalam jaringan. Agar *threshold* ECR memiliki dasar ilmiah yang kuat, nilai ini tidak boleh

bersifat arbitrer. Sebaliknya, *threshold* harus ditentukan berdasarkan distribusi acuan.

Istilah arbitrer merujuk pada keputusan yang ditetapkan secara sembarangan, tanpa justifikasi metodologis atau tanpa mempertimbangkan karakteristik data. Dalam konteks ini, nilai threshold seperti “ $ECR \geq 1$ berarti *echo chamber*” merupakan contoh ambang arbitrer karena tidak berasal dari proses statistik apa pun dan tidak mempertimbangkan variasi struktur jaringan serta distribusi leaning pengguna, seperti yang dilakukan oleh Aidira (2025). Distribusi acuan (*null-model distribution*) adalah distribusi nilai suatu metrik yang dihasilkan dari jaringan acak yang mempertahankan properti tertentu dari jaringan asli, seperti distribusi derajat (*degree sequence*). Dengan kata lain, distribusi acuan menunjukkan nilai ECR yang diharapkan terjadi apabila jaringan tidak memiliki struktur komunitas ideologis yang bermakna. Dengan demikian, setiap deviasi yang signifikan antara ECR observasi dan distribusi acuan dapat ditafsirkan sebagai indikasi adanya struktur *echo chamber* yang nyata.

Pendekatan berbasis distribusi acuan ini sejalan dengan metodologi *network science*, khususnya kajian *network motifs* oleh Milo dkk. (2011). Dalam penelitian tersebut, Milo menunjukkan bahwa signifikansi suatu motif bukan dilihat dari nilai absolutnya, tetapi dari berapa jauh nilai tersebut menyimpang dari nilai rata-rata motif yang muncul pada jaringan acak. Dinyatakan bahwa “*the number of times they appear is more than 10 standard deviations greater than their mean number of appearances in randomized networks.*” (Milo dkk., 2011).

Pernyataan ini mengimplikasikan penggunaan deviasi dari distribusi acuan sebagai dasar penilaian signifikansi. Milo menghitung Z-score menggunakan formulasi 2.6.

$$Z = \frac{N_{real} - N_{rand}}{\sigma} \quad (2.6)$$


N_{real} adalah jumlah motif pada jaringan asli, N_{rand} adalah rata-rata jumlah motif pada jaringan acak, dan σ adalah simpangan bakunya. Secara matematis, struktur dianggap signifikan apabila nilai observasi melampaui ekspektasi acak setidaknya sebesar satu standar deviasi pada persamaan 2.7.

$$Z > 1 \Leftrightarrow N_{real} > N_{rand} + \sigma \quad (2.7)$$

Prinsip signifikansi berbasis deviasi dari null-model inilah yang kemudian diadaptasi untuk menentukan threshold ECR.

II.3 Konsensus *Multi-level*


Dalam konteks *ensemble clustering*, *consensus function* adalah mekanisme untuk menggabungkan beberapa hasil partisi (*clustering*) yang berbeda menjadi satu partisi akhir yang dianggap lebih stabil, akurat, dan representatif. Alih-alih bergantung pada satu algoritma *clustering* yang mungkin sensitif terhadap inisialisasi, parameter, atau distribusi data, *ensemble clustering* membuat banyak *primary partitions*, lalu menggabungkannya menjadi satu *consensus partition*. Secara umum, dua tahap utama dalam *ensemble clustering* adalah (1) *Ensemble generation* yang menghasilkan sejumlah partisi awal dengan metode yang beragam, misalnya variasi inisialisasi *k-means*, subsampling, atau penggunaan algoritma berbeda; dan (2) *Consensus function* yang menggabungkan seluruh partisi tersebut untuk menghasilkan satu hasil *clustering* akhir.



Gambar II.3. *Multi-level consensus framework* (Pho dkk., 2021).

Dari Gambar II.3, metode konsensus tradisional sering hanya mengukur kesamaan antar partisi pada satu level (misalnya berdasarkan *co-association matrix* atau *voting* antar partisi). Namun, pendekatan tersebut memiliki keterbatasan, yakni tidak cukupnya menangkap hubungan hierarkis antar *cluster*, lalu tidak memperhitungkan kemiripan *multi-level* antar *cluster* (baik secara langsung

maupun melalui relasi transisi), dan sensitif terhadap jumlah *cluster* yang digunakan dalam partisi awal. Untuk mengatasi ini, *Multi-level Consensus Clustering* (MLCC) diperkenalkan. Metode ini memperluas gagasan konsensus dengan memanfaatkan *multi-level similarity* antar cluster, sehingga informasi struktur global dan lokal dari *ensemble* dapat dieksploitasi secara lebih menyeluruh (Pho dkk., 2021). Tahapan MLCC terdiri dari tujuh tahapan yang memiliki persamaan di beberapa tahapan, yakni ditunjukkan pada Gambar II.4.



Gambar II.4. *Ensemble Clustering Framework* (Pho dkk., 2021).

- 1) *Ensemble creation*, yakni dari melakukan subsampling beberapa kali terhadap *dataset X*. Setiap subset yang dipartisi tersebut menggunakan algoritma sederhana (umumnya K-Means) dengan jumlah *cluster* acak. Hasil dari partisi tersebut Adalah himpunan partisi awal $\{p_x^1, p_x^2, \dots, p_x^M\}$ yang beragam. Kemudian diperluas ke bentuk “*complete partition*” untuk memudahkan perbandingan antar *cluster*.
- 2) *Graph construction (cluster graph)*. Dari seluruh *cluster* dalam *ensemble*, dibuat sebuah graf transisi yang terlihat pada persamaan 2.8

$$G(px) = (V(px), E(px)) \quad (2.8)$$

Dengan:

- a. $V(px)$: simpul yang merepresentasikan semua *cluster* dari semua partisi,
- b. $E(px)$: sisi dengan bobot kesamaan antar *cluster*.

Bobot kesamaan antar *cluster* didefinisikan dengan dengan fungsi *Simple Cluster-Cluster Similarity* (SCCS) yang ditunjukkan pada persamaan 2.9 (Pho dkk., 2021).

$$SCCS(A, B) = \frac{1}{2} + \frac{|A \cap B|}{|X|} - \sqrt{\frac{|A||B|}{|X|^2}} \quad (2.9)$$

Nilai SCCS berada antara 0 dan 1, menunjukkan tingkat kemiripan dua cluster berdasarkan anggota datanya.

- 3) *Multi-level transition probability*. Untuk menangkap hubungan *multi-level*, didefinisikan matriks probabilitas transisi antar *cluster* dengan langkah pertama, yakni ditunjukkan pada persamaan 2.10 (Pho dkk., 2021).

$$TP_{ij}^1 = \frac{w_{ij}}{\sum_k w_{ik}} \quad (2.10)$$

Dengan w_{ij} Adalah bobot SCSS antara cluster i dan j . Selanjutnya, yakni langkah ke- r (*multi-level*) yang ditunjukkan pada persamaan 2.11 (Pho dkk., 2021).

$$TP^r = (TP^1)^r \quad (2.11)$$

Matriks ini merepresentasikan probabilitas berpindah dari satu *cluster* ke *cluster* lain setelah r langkah sehingga hubungan tidak langsung antar *cluster* juga dipertimbangkan.

- 4) *Multi-level feature space*. Berdasarkan transisi *multi-level*, dibentuk ruang fitur baru untuk setiap *cluster* yang ditunjukkan pada persamaan 2.12 (Pho dkk., 2021).

$$NF^r = [TP^1, TP^2, \dots, TP^r] \quad (2.12)$$

di mana setiap baris mewakili satu *cluster* dan setiap kolom mewakili distribusi probabilitas transisi pada level tertentu. Ruang ini menangkap struktur hubungan antar *cluster* di banyak level (*local* $\rightarrow$ *global*).

- 5) *Multi-level cluster-cluster similarity matrix*. Dengan ruang *multi-level*, kemiripan antar *cluster* dapat dihitung menggunakan jarak Euclidean atau Cosine, lalu diubah menjadi *similarity matrix* yang ditunjukkan pada persamaan ke 2.13 (Pho dkk., 2021).

$$\begin{aligned} CCS^T &= 1 - \text{EuclideanDistance}(NF^T) \\ &= 1 - \text{CosineDistance}(NF^T) \end{aligned} \quad (2.13)$$

- 6) *Point-point similarity matrix*. Untuk menghasilkan consensus akhir, *cluster-cluster similarity matrix* digunakan untuk meningkatkan *point-point similarity matrix* yang ditunjukkan pada persamaan 2.14 (Pho dkk., 2021).

$$PPS^T(i, j) = \frac{1}{B} \sum_{b=1}^B CCS^T(CI(x_i, b), CI(x_j, b)) \quad (2.14)$$

dengan $CI(x, b)$ adalah indeks cluster tempat data x berada pada partisi ke- b . Matriks PPS^r ini bersifat simetris dan menggambarkan kedekatan *multi-level* antar data.

- 7) *Consensus partition via hierarchical clustering*. Terakhir, diterapkan algoritma clustering sekunder, misalnya *agglomerative hierarchical clustering* dengan *complete linkage* pada PPS^r untuk menghasilkan *consensus partition* akhir.

Selain tahapan yang telah dijelaskan, *multi-level consensus* memiliki keunggulan. Menurut Pho dkk. (2021), MLCC memiliki beberapa keunggulan dibandingkan metode *ensemble clustering* klasik, yakni

- 1) Lebih akurat dan *robust*, terutama pada *dataset* dengan *noise* tinggi atau struktur *cluster* kompleks.
- 2) Tidak sensitif terhadap jumlah *cluster* awal, karena struktur *multi-level* mengkompensasi variasi partisi.
- 3) Menggabungkan informasi lokal dan global, sehingga lebih stabil terhadap variasi algoritma dasar.


- 4) Kompleksitas waktu tetap terkontrol: $O(r \cdot n^3)$ pada kasus terburuk, dengan r adalah kedalaman level transisi.

Dalam konteks analisis *echo chamber*, konsep *multi-level consensus* sangat relevan karena *echo chamber* tidak selalu terbentuk secara eksplisit pada satu level, misalnya hanya dari interaksi langsung, tetapi bisa muncul dari struktur *multi-level* dalam jaringan (hubungan tidak langsung, efek komunitas berlapis). Selain itu, *multi-level consensus* dapat digunakan untuk menggabungkan berbagai partisi ideologis/komunitas dari algoritma berbeda, misalnya hasil *clustering* berdasarkan konten, jaringan, dan difusi untuk memperoleh satu struktur komunitas “konsensus”. Hal ini sangat tepat apabila ECR diukur dengan pertimbangan agregasi *multi-level* opini dan jaringan.

II.4 Algoritma Deteksi Komunitas

Dalam analisis jaringan sosial, deteksi komunitas bertujuan untuk mengidentifikasi kelompok simpul yang memiliki interaksi lebih padat satu sama lain dibandingkan dengan simpul di luar kelompok tersebut. Dapat dilihat ilustrasi dari hubungan antarsimpul yang dihubungkan oleh sisi pada Gambar II.5. Proses ini penting dalam analisis *echo chamber* karena komunitas sosial sering kali berperan sebagai tempat suatu opini serupa saling diperkuat melalui interaksi internal yang intens. Dua algoritma yang banyak digunakan untuk tugas ini adalah Leiden dan Infomap, yang merepresentasikan dua paradigma utama deteksi komunitas, yakni berbasis *modularity optimization* dan berbasis *information flow*.

Paradigma berbasis *modularity optimization* merupakan metode deteksi komunitas yang berfokus pada kepadatan koneksi struktural di dalam jaringan. Algoritma yang menggunakan pendekatan ini, seperti Louvain dan Leiden, berupaya memaksimalkan nilai modularitas sehingga simpul-simpul yang memiliki keterkaitan erat secara struktural dikelompokkan ke dalam komunitas yang sama. Sedangkan *information flow* merupakan cara informasi bergerak dari simpul ke simpul. Algoritma yang menggunakan pendekatan ini adalah Infomap.



Gambar II.5. Sebuah graf yang menunjukkan struktur komunitas (Bonafilia, 2023).

II.4.1 Algoritma Louvain dan Algoritma Leiden

II.4.1.1 Algoritma Louvain

Salah satu metrik yang paling umum untuk mengevaluasi partisi dalam graf adalah modularitas. Modularitas adalah fraksi sisi antara simpul dalam suatu komunitas dikurangi nilai harapan dari distribusi acak sisi antara simpul yang sama. Modularitas ini menggunakan model graf acak di mana simpul mempertahankan derajatnya untuk menentukan fraksi sisi yang diharapkan. Dalam graf acak seperti itu, peluang sisi-sisi ini menjadi sisi antara dua simpul adalah $\frac{d_i d_j}{2m}$, di mana m adalah ukuran graf (jumlah sisi). Modularitas dievaluasi berdasarkan partisi setiap simpul i ke dalam suatu komunitas c_i . Dengan demikian, modularitas dapat dinyatakan pada persamaan 2.15 (Bonafilia, 2023).


$$Q = \frac{1}{2m} \sum_{ij} \left[A_{ij} - \frac{d_i d_j}{2m} \right] \delta_{c_i, c_j} \quad (2.15)$$

Nilai maksimum untuk Q merepresentasikan partisi optimal menggunakan modularitas sebagai metrik evaluasi. Perlu dicatat bahwa terdapat beberapa keterbatasan dalam penggunaan modularitas sebagai metrik evaluasi yang akan dibahas di bagian selanjutnya. Sebuah algoritma telah dikembangkan untuk memaksimalkan metrik ini secara efisien. Algoritma ini umumnya disebut Algoritma Louvain, sesuai dengan nama para peneliti dari Universitas Louvain

yang menciptakannya. Algoritma Louvain menginisialisasi simpul-simpul sebagai anggota komunitasnya masing-masing. Dari sana, algoritma ini mencoba memaksimalkan modularitas dalam langkah-langkah iteratif dari dua fase (Bonafilia, 2023).

Pada fase pertama, untuk setiap simpul i , simpul-simpul tetangga j dipertimbangkan. Perolehan modularitas dari pemindahan simpul i ke komunitas yang sama dengan beberapa tetangga j dievaluasi, dan perpindahan yang menghasilkan perolehan maksimum dalam modularitas dilakukan. Jika beberapa perpindahan menghasilkan perolehan yang sama, maka perpindahan yang dipilih ditentukan secara acak. Fase ini berakhir ketika nilai maksimum lokal ditemukan. Fase kedua menciptakan sebuah graf baru yang simpul-simpulnya merupakan komunitas-komunitas yang ditemukan pada fase pertama. Bobot antara dua simpul adalah jumlah bobot sisi antara simpul di masing-masing dari dua komunitas yang diwakili oleh dua simpul tersebut (Bonafilia, 2023).

Koneksi dalam komunitas direpresentasikan sebagai *self-loop*. Dari sini, fase pertama dapat diulang. Gambar II.6 mengilustrasikan dua fase algoritma selama beberapa langkah. Algoritma ini hanya berlaku untuk grafik tak berarah. Variasi untuk grafik berarah telah dikembangkan menggunakan pengukuran modularitas berdasarkan derajat masuk dan derajat keluar.



Gambar II.6. Dua fase algoritma Louvain (Bonafilia, 2023).

Selain itu, formulasi untuk modularitas dalam grafik berbobot harus memperhitungkan bahwa jumlah koneksi yang diharapkan bukanlah fungsi dari jumlah total sisi, m , melainkan fungsi dari jumlah semua derajat, w . Ini memberikan formulasi akhir untuk modularitas yang digunakan, yakni ditunjukkan pada persamaan 2.16 (Bonafilia, 2023).


$$Q_d = \frac{1}{w} \sum_{ij} \left[A_{ij} - \frac{d_i^+ d_j^-}{w} \right] \delta_{c_i, c_j} \quad (2.16)$$

II.4.1.2 Algoritma Leiden

Algoritma Leiden dikembangkan oleh Traag dkk. (2019) sebagai pengembangan dari algoritma Louvain. Kedua algoritma tersebut menggunakan konsep *modularity* (Q), yaitu ukuran seberapa baik suatu partisi jaringan membentuk komunitas internal yang padat dibandingkan dengan jaringan acak. Secara umum, modularitas dihitung berdasarkan perbandingan antara proporsi sisi aktual di dalam komunitas dan proporsi yang diharapkan bila koneksi terdistribusi secara acak. Namun, Traag dkk. (2019) menunjukkan bahwa Louvain memiliki kelemahan mendasar, yakni komunitas yang dihasilkan tidak selalu terhubung secara internal. Dinyatakan bahwa algoritma Louvain mungkin menghasilkan komunitas yang tidak terhubung dengan baik, dimana bagian-bagian dari komunitas terputus satu sama lain. Hal ini berarti satu komunitas dapat terdiri dari beberapa sub-komponen yang tidak memiliki jalur penghubung antar anggotanya. Kondisi tersebut menyebabkan hasil partisi sulit diinterpretasikan secara sosial, karena komunitas seharusnya merepresentasikan kelompok individu yang saling berinteraksi.

Leiden memperbaiki kelemahan ini dengan menambahkan tahap *refinement* yang memastikan setiap komunitas adalah *well-connected* yang dapat dilihat fase-fasenya pada Gambar II.7. Ditunjukkan bahwa pada langkah pertama, fase pertama mampu menetapkan simpul-simpul ke dalam dua komunitas sebelum mencapai modularitas maksimum, yang dapat mengakibatkan komunitas terpecah seperti yang ditunjukkan jika penugasan acak tidak berhasil. Pada fase kedua, penyempurnaan mencegah komunitas-komunitas yang tidak terhubung ini digabungkan dalam fase agregat. Fase ketiga menyiapkan agregasi.

Penyempurnaan pada langkah berikutnya akan mencegah dua simpul biru (yang mewakili komunitas biru dan hijau) digabungkan karena tidak ada koneksi timbal balik (Bonafilia, 2023).



Gambar II.7. Tiga fase algoritma Leiden (Bonafilia, 2023).


Traag dkk. (2019) menegaskan bahwa algoritma Leiden menjamin komunitas yang terhubung dengan baik, di mana semua node dalam komunitas terhubung satu sama lain. Jika komunitas hasil Louvain mengandung sub-komponen yang terputus, Leiden akan memecahnya menjadi komunitas yang lebih kecil namun terhubung penuh. Dengan demikian, Leiden menghasilkan partisi yang lebih stabil, bermakna, dan representatif terhadap struktur jaringan yang sesungguhnya. Dalam konteks analisis sosial, *well-connectedness* menunjukkan kohesi internal yang kuat, di mana semua anggota komunitas dapat berinteraksi langsung atau tidak langsung. Hal ini sangat penting untuk mengukur fenomena *echo chamber* karena tingkat kesamaan opini di dalam komunitas hanya bermakna jika komunitas tersebut benar-benar saling berhubungan, dapat dilihat di Tabel II.1.

Tabel II.1. Tinjauan umum jaminan yang diberikan oleh algoritma Louvain dan algoritma Leiden (Traag dkk., 2019)

		Louvain	Leiden
<i>Each iteration</i>	γ -separation	✓	✓

		Louvain	Leiden
	γ -connectivity		✓
<i>Stable iteration</i>	Node optimality	✓	✓
	Subpartition γ -density		✓
<i>Asymptotic</i>	Uniform γ -density		✓
	Subset optimality		✓

Gambar II.8 menunjukkan contoh cara algoritma Louvain dengan strategi *greedy* dapat menyebabkan pemutusan komunitas dengan memindahkan simpul penghubung ke komunitas lain untuk meningkatkan modularitas. Solusi yang diusulkan dalam bentuk Algoritma Leiden diberikan oleh para peneliti di Universitas Leiden yang mengidentifikasi masalah ini. Algoritma Leiden berbeda dari Algoritma Louvain dalam beberapa hal utama. Pertama, algoritma Leiden menetapkan simpul ke komunitas baru berdasarkan probabilitas yang didasarkan pada besarnya peningkatan potensial dalam fungsi objektif, alih-alih memilih perolehan terbesar seperti pada algoritma Louvain. Lebih penting lagi, algoritma Leiden memiliki langkah penyempurnaan sebelum membentuk komunitas agregat pada fase kedua. Penyempurnaan ini menempatkan semua simpul dalam komunitas ke dalam partisinya masing-masing dan mengulangi proses pemindahan, membatasi simpul untuk membentuk komunitas dengan simpul yang berbagi partisi dengannya pada fase awal (Bonafilia, 2023).




Gambar II.8. Algoritma Louvain dapat menetapkan sebuah node ke sebuah komunitas dalam sebuah langkah yang optimal secara lokal, namun hal ini memisahkan komunitas satu dengan yang lain (Bonafilia, 2023).

II.4.2 Algoritma Infomap

Berbeda dengan Leiden yang berfokus pada kepadatan struktur internal, algoritma Infomap (Rosvall & Bergstrom, 2008) berlandaskan pada paradigma aliran informasi (*information flow*). Infomap memandang jaringan sebagai sistem di mana informasi bergerak mengikuti jalur koneksi antar simpul. Dengan memanfaatkan teori *random walk*, algoritma ini mencari pembagian komunitas yang meminimalkan panjang deskripsi (*code length*) dari lintasan pergerakan informasi. Rosvall & Bergstrom (2008) menjelaskan bahwa komunitas dalam Infomap adalah kelompok simpul di mana informasi “terperangkap” lebih lama sebelum berpindah ke komunitas lain. Dengan cara ini, Infomap mengidentifikasi struktur komunitas yang bukan hanya padat secara topologis, tetapi juga fungsional secara dinamis. Pendekatan Infomap sangat efektif untuk graf terarah (*directed networks*), seperti jaringan *reply*, *mention*, atau *retweet* di media sosial karena memperhitungkan arah dan intensitas aliran komunikasi antar pengguna. Dalam konteks *echo chamber*, hal ini penting untuk memahami bagaimana informasi dan opini menyebar dan bertahan dalam kelompok sosial tertentu (Bonafilia, 2023).

Bahkan dengan bentuk minimal, jelas bahwa kode untuk satu simpul dapat menjadi panjang seiring bertambahnya jumlah simpul. Solusi yang diusulkan dengan algoritma Infomap adalah mengembangkan suatu partisi, M , dari graf tempat simpul-simpul dikelompokkan ke dalam modul-modul. Setiap modul memiliki buku kodenya sendiri, sehingga kode untuk sebuah simpul hanya perlu unik dalam modulnya. Buku kode tambahan, yaitu buku kode indeks, ditambahkan dengan

kode entri yang menunjukkan buku kode mana yang harus digunakan untuk mendekode simpul-simpul berikutnya. Ilustrasinya diberikan pada Gambar II.9 (Bonafilia, 2023).



Gambar II.9. Algoritma Infomap dan pengurangan panjang kode yang dihasilkan untuk sampel *random walk* (Bonafilia, 2023).


Hal ini dicapai dengan menjalankan proses yang serupa dengan Algoritma Leiden, tetapi alih-alih memaksimalkan modularitas, tujuannya adalah meminimalkan Persamaan Peta pada persamaan 2.17 (Bonafilia, 2023).

$$L(M) = q_{\sim}H(Q) + \sum_{i=1}^m p_{\cup}^i H(P^i) \quad (2.17)$$

$H(Q)$ adalah panjang rata-rata tertimbang frekuensi dari kata sandi dalam buku kode indeks, $H(P^i)$ adalah panjang rata-rata tertimbang frekuensi dari kata sandi dalam buku kode i , $q_{\sim}$ adalah probabilitas untuk keluar dari modul, dan $p_{\cup}^i$ adalah probabilitas untuk tetap berada dalam modul i . Probabilitas keluar hanya diambil dari pembobotan relatif tepi dari suatu simpul ke simpul-simpul dalam modulnya dan ke simpul-simpul di luar modulnya. Algoritma ini membentuk modul-modul dari wilayah-wilayah di mana pejalan acak memiliki kemungkinan besar untuk tinggal di sana dalam waktu lama. Hal ini menyebabkan Algoritma Infomap secara alami mengasumsikan struktur berdasarkan aliran dalam grafik dan dinamika jaringan, yang sangat penting ketika hipotesis didasarkan pada aliran informasi (Bonafilia, 2023).

II.4.3 Alasan Komunitas *Well-Connected* Lebih Baik


Menurut Traag (2019), Louvain sudah dipastikan ada di kondisi di antara *disconnected* atau *badly-connected*, sedangkan Leiden sudah pasti *well-connected*. Dapat dibuktikan dari penelitian Traag dkk. (2019), ditunjukkan pada Gambar II.10 sampai dengan Gambar II.13. Dapat dilihat bahwa hasil Leiden lebih baik daripada Louvain.



Gambar II.10. Penskalaan hasil benchmark untuk ukuran jaringan (Traag dkk., 2019).


Gambar II.10 memperlihatkan hasil *benchmark* perbandingan antara algoritma Louvain dan Leiden pada berbagai ukuran jaringan serta parameter μ yang berbeda. Nilai μ menunjukkan tingkat kekaburan struktur komunitas; semakin tinggi μ , semakin sulit mendeteksi komunitas yang koheren. Berdasarkan hasil tersebut, Leiden secara konsisten menghasilkan kualitas partisi yang lebih tinggi dibandingkan Louvain, terutama ketika μ bernilai besar ($\mu \geq 0.6$).

Hal ini membuktikan bahwa Leiden mampu mengidentifikasi komunitas yang lebih stabil dan terhubung penuh (*well-connected*) bahkan pada jaringan yang kompleks. Selain itu, waktu komputasi kedua algoritma relatif serupa, menandakan bahwa peningkatan kualitas oleh Leiden tidak menyebabkan beban komputasi yang signifikan. Oleh karena itu, Leiden menjadi pilihan lebih unggul dalam konteks penelitian ini, karena menjamin keterhubungan internal komunitas dan kestabilan hasil deteksi komunitas yang menjadi dasar perhitungan *Echo Chamber Ratio*.




Gambar II.11. Waktu proses versus kualitas untuk jaringan benchmark (Traag dkk., 2019).

Gambar II.11 memperlihatkan hubungan antara waktu komputasi dan kualitas hasil partisi komunitas pada jaringan sintesis dengan dua ukuran berbeda, yaitu $n = 10^6$ dan $n = 10^7$, untuk empat nilai parameter μ (0.2, 0.4, 0.6, 0.8). Parameter μ menggambarkan tingkat kekaburan komunitas; semakin besar nilainya, semakin sulit komunitas dipisahkan. Berdasarkan grafik tersebut, terlihat bahwa algoritma Leiden (garis biru) secara konsisten menghasilkan kualitas partisi yang lebih tinggi dibandingkan Louvain (garis merah), bahkan pada kondisi jaringan dengan μ tinggi (komunitas tumpang tindih). Selain itu, hasil Leiden tampak stabil dan meningkat secara halus seiring waktu, sedangkan Louvain menunjukkan fluktuasi yang besar dan penurunan kualitas pada jaringan besar. Hal ini menegaskan bahwa Leiden lebih robust terhadap struktur jaringan yang kompleks serta mampu mempertahankan *well-connected communities* dengan efisiensi waktu yang setara.



Gambar II.12. Skala hasil benchmark untuk tingkat kesulitan partisi (Traag dkk., 2019).

Gambar II.12 menunjukkan pengaruh tingkat kesulitan partisi komunitas terhadap waktu komputasi algoritma Louvain dan Leiden. Sumbu horizontal menunjukkan nilai parameter μ sebagai indikator tingkat *mixing* antar komunitas, sedangkan sumbu vertikal menunjukkan waktu komputasi dalam satuan detik. Terlihat bahwa ketika nilai μ meningkat, waktu komputasi Louvain meningkat secara eksponensial, sementara Leiden tetap relatif stabil dan meningkat secara linier. Hal ini menunjukkan bahwa Leiden mampu mengatasi jaringan dengan batas komunitas yang kabur tanpa kehilangan efisiensi. Secara khusus, pada $\mu \geq 0.6$, perbedaan performa antara keduanya semakin mencolok, di mana Louvain memerlukan waktu hingga dua orde lebih lama daripada Leiden. Dengan demikian, Leiden lebih unggul dalam hal skalabilitas dan efisiensi pada jaringan dengan struktur komunitas yang lemah.



Gambar II.13. Waktu proses iterasi pertama untuk jaringan empiris (Traag dkk., 2019).

Gambar II.13 menampilkan hasil pengujian algoritma Louvain dan Leiden pada jaringan empiris dari berbagai domain, seperti DBLP, Amazon, IMDB, Live Journal, Web of Science, dan Web UK (2005). Grafik batang menunjukkan waktu eksekusi iterasi pertama (dalam detik) untuk masing-masing algoritma. Secara konsisten, Leiden (biru) memerlukan waktu yang lebih singkat dibanding Louvain (merah) pada seluruh *dataset*. Perbedaan waktu menjadi sangat signifikan pada jaringan besar seperti Web of Science dan Web UK, di mana Louvain membutuhkan waktu sepuluh kali lebih lama. Selain itu, variasi hasil Leiden

tampak lebih kecil, menandakan stabilitas dan konsistensi kinerja yang lebih baik. Hasil ini memperkuat temuan bahwa Leiden tidak hanya lebih efisien secara teoritis, tetapi juga unggul dalam penerapan pada jaringan nyata berskala besar, menjadikannya metode yang lebih andal untuk deteksi komunitas dalam analisis *echo chamber*.

Komunitas yang *well-connected* memiliki beberapa keunggulan penting dibandingkan komunitas yang *disconnected*, baik dari sisi teori jaringan maupun relevansi analisis sosial. Keunggulan-keunggulan tersebut, yakni sebagai berikut.

1) Kohesi internal yang kuat.

Komunitas *well-connected* menjamin bahwa setiap anggota komunitas dapat dijangkau oleh anggota lain melalui jalur internal. Menurut Traag dkk. (2019), hal ini menjamin “*each community is internally connected, ensuring that they represent meaningful groups.*” Dengan demikian, komunitas tersebut benar-benar mewakili kelompok sosial atau ideologis yang kohesif. Sebaliknya, komunitas *disconnected* dapat mengandung subkelompok yang tidak saling berinteraksi, sehingga tidak mencerminkan realitas sosial.

2) Stabilitas struktural

Komunitas *well-connected* lebih tahan terhadap perubahan kecil dalam struktur jaringan, seperti penambahan atau penghapusan hubungan antar pengguna. Louvain, sebaliknya, sering menghasilkan partisi tidak stabil karena tidak menjamin konektivitas internal (Traag dkk., 2019). Stabilitas ini sangat penting dalam analisis jaringan sosial berskala besar seperti media sosial, di mana struktur koneksi bersifat dinamis.

3) Relevansi terhadap *echo chamber*

Fenomena *echo chamber* hanya dapat diamati secara bermakna jika komunitas yang dianalisis benar-benar saling terhubung. Jika komunitas tidak terhubung, maka resonansi opini internal tidak dapat terjadi, karena sebagian anggota tidak memiliki jalur komunikasi satu sama lain. Dengan demikian, *well-connectedness* menjadi syarat metodologis agar metrik seperti *Echo Chamber Ratio* (ECR) valid secara konseptual maupun empiris.

4) Kesahihan difusi informasi

Dalam model penyebaran informasi seperti *Susceptible-Infected-Recovered* (SIR), proses difusi membutuhkan jalur konektivitas antar pengguna. Komunitas yang tidak terhubung akan menghambat penyebaran informasi di antara anggotanya. Sebaliknya, komunitas *well-connected* memastikan bahwa informasi dapat mengalir secara alami dan lengkap di dalam komunitas tersebut, sebagaimana asumsi yang digunakan dalam model difusi Cinelli dkk. (2021).

II.4.4 Sinergi Leiden dan Infomap dalam Analisis *Echo chamber*

Pada penelitian sebelumnya, seperti yang dilakukan oleh Aidira (2025), pengukuran *echo chamber* dilakukan dengan mengombinasikan deteksi komunitas menggunakan algoritma Louvain dan metrik konsensus berbasis *Group Decision Making* (GDM) untuk menilai keselarasan opini di dalam komunitas. Pendekatan ini efektif dalam menangkap keseragaman opini secara semantik, namun masih memiliki keterbatasan pada sisi struktural jaringan, karena partisi komunitas yang dihasilkan Louvain tidak menjamin keterhubungan internal komunitas secara menyeluruh. Akibatnya, komunitas yang terbentuk berpotensi mencakup kelompok pengguna yang secara struktural tidak benar-benar berinteraksi, sehingga asumsi ruang diskusi internal yang kohesif menjadi kurang terpenuhi.

Penggunaan Leiden dan Infomap secara bersamaan memberikan dua sudut pandang yang saling melengkapi. Leiden menekankan pada struktur jaringan yang kohesif secara topologis, sementara Infomap menyoroti pola aliran informasi yang fungsional secara dinamis. Dengan mengombinasikan keduanya, analisis *echo chamber* dapat menangkap baik dimensi struktural maupun dinamis, yakni cara informasi menyebar dan terperangkap di dalam kelompok. Pho dkk. (2021) menegaskan bahwa dalam pendekatan *multi-level consensus clustering*, penggunaan lebih dari satu algoritma partisi, seperti Leiden dan Infomap tidak hanya memperkuat stabilitas partisi komunitas, tetapi juga meningkatkan keakuratan dalam merepresentasikan realitas sosial yang kompleks, seperti fenomena *echo chamber* di media sosial.

II.5 Penelitian Terkait

Dalam rangka membangun fondasi teoretis dan metodologis yang kuat, dua penelitian utama yang relevan ditinjau secara mendalam, yaitu studi oleh Blekanov dkk. (2021) dan Bonafilia (2021). Keduanya mengkaji efektivitas algoritma deteksi komunitas seperti Infomap, Leiden, dan Louvain dalam konteks media sosial dan jaringan informasi berskala besar. Dalam konteks ini, struktur komunitas yang *well-connected* merujuk pada komunitas yang seluruh anggotanya terhubung melalui jalur interaksi langsung maupun tidak langsung, membentuk satu subgraf yang utuh tanpa bagian yang terputus.

Berdasarkan eksperimen pada *dataset* media sosial, khususnya Twitter, data mentah yang dibangun dari kemiripan konten sering kali membentuk graf yang pada dasarnya sudah cukup *well-connected*, karena pengguna yang membahas topik serupa cenderung saling merespons atau mengutip satu sama lain. Namun, apabila partisi dilakukan dengan Louvain, komunitas yang seharusnya menyatu bisa dipisahkan ke dalam beberapa bagian yang terisolasi. Hal ini diperlihatkan oleh studi Traag dkk. (2019), di mana Leiden mampu memperbaiki kelemahan tersebut dengan menjamin setiap komunitas merupakan subgraf yang terhubung kuat (*connected subgraph*).

II.5.1 Analisis Komunitas Diskursif dengan Infomap dan Leiden (Blekanov dkk., 2021)

Penelitian oleh Blekanov dkk. berjudul “*Detection of Hidden Communities in Twitter Discussions of Varying Volumes*” membahas efektivitas berbagai algoritma deteksi komunitas dalam memetakan komunitas tersembunyi dalam diskusi Twitter dengan topik politik, sosial, dan protes publik. Fokus utama penelitian ini adalah mengevaluasi sembilan algoritma, termasuk Infomap, Leiden, dan Louvain, terhadap *dataset* nyata dengan pendekatan berbasis struktur jaringan.

Tahapan penelitian dimulai dengan membangun graf interaksi *mention* dan *retweet* dari data Twitter, kemudian algoritma dijalankan untuk mendeteksi partisi komunitas. Infomap dipilih karena berbasis aliran informasi (*information flow*), sedangkan Leiden digunakan karena kemampuannya menghasilkan komunitas yang *well-connected*. Evaluasi dilakukan tidak hanya berdasarkan metrik

modularitas dan ukuran komunitas, tetapi juga dari relevansi tematik antar anggota komunitas (analisis diskursif). Hasil analisis menunjukkan bahwa Infomap memberikan partisi komunitas dengan granularitas tinggi, sedangkan Leiden memberikan hasil partisi yang stabil dan representatif terhadap kelompok diskursif utama.

Hasil yang paling menonjol adalah bahwa Leiden dan Infomap memberikan kualitas komunitas terbaik, khususnya dalam mendeteksi komunitas diskursif yang relevan dengan isu-isu sosial. Komunitas hasil Leiden cenderung lebih padat dan terhubung secara internal, yang penting untuk analisis *echo chamber*. Louvain, sebaliknya, menghasilkan komunitas yang fragmentatif dan tidak stabil secara struktur. Semua hasil dan perbandingannya direkap dalam Tabel II.2.

Tabel II.2. Hasil dari evaluasi model

	DirMod				ClusCoe				ComFit				NEDind				Conduc				Contrac				Expans			
	Bir	Col	Fer	ChE	Bir	Col	Fer	ChE	Bir	Col	Fer	ChE	Bir	Col	Fer	ChE	Bir	Col	Fer	ChE	Bir	Col	Fer	ChE	Bir	Col	Fer	ChE
DLPA 0.486	-	-	-	0.056	0.07	0.085	0.027	1.373	2.299	1.522	1.375	0.605	0.723	0.64	0.672	0.625	0.521	0.599	0.514	0.849	0.815	0.847	0.764	2.361	1.378	2.735	1.55	
DirLouv 0.574	-	-	-	0.039	0.028	0.027	0.012	6.548	7.753	6.318	4.395	0.793	0.917	0.949	0.953	0.286	0.234	0.208	0.163	0.766	0.691	0.666	0.604	0.715	0.459	0.371	0.256	
Infomap 0.088	-	-	-	0.034	0.024	0.026	0.012	7.877	8.468	6.476	4.381	0.94	0.949	0.959	0.942	0.209	0.201	0.199	0.166	0.685	0.653	0.635	0.608	0.375	0.344	0.34	0.268	
OSLOM -	-	-	-	0.035	0.034	0.034	0.015	2.479	3.38	2.426	1.73	0.501	0.495	0.493	0.479	0.967	0.963	0.964	0.979	0.087	0.098	0.096	0.054	1.403	1.249	1.305	1.239	
GKM 0.39	-	-	-	0.0099	0.013	-	-	7.956	28.498	-	-	0.423	0.422	-	-	0.95	0.934	-	-	0.19	0.209	-	-	2.161	2.6	-	-	
LeidMod 0.584	-	-	-	0.039	0.028	0.027	0.011	6.686	7.764	6.244	4.408	0.806	0.916	0.945	0.955	0.279	0.233	0.212	0.162	0.761	0.693	0.67	0.603	0.686	0.459	0.38	0.253	
LeidCPM 0.571	-	-	-	0.04	0.033	0.035	0.016	5.052	4.379	4.484	3.351	0.676	0.689	0.74	0.758	0.365	0.397	0.345	0.276	0.828	0.793	0.782	0.713	1.001	1.030	1.062	0.663	
GANXISd 0.406	-	-	-	0.04	0.031	0.031	-	2.538	3.057	3.303	-	0.661	0.693	0.772	-	0.526	0.501	0.422	-	0.841	0.807	0.773	-	1.681	1.798	1.26	-	
GANXISo -	-	-	-	0.049	0.042	0.034	-	3.295	3.551	4.064	-	0.643	0.67	0.799	-	0.35	0.526	0.397	-	0.848	0.829	0.756	-	2.282	2.290	1.284	-	

II.5.2 Evaluasi Deteksi Komunitas Berbasis GNN dan *Baseline* Leiden (Bonafilia, 2023)

Studi oleh Bonafilia mengeksplorasi penerapan *Graph Neural Networks* (GNN) untuk deteksi komunitas sosial dalam jaringan besar dan membandingkan performanya dengan algoritma konvensional seperti Louvain dan Leiden. Tujuan utama studi ini adalah mengevaluasi apakah model pembelajaran struktural seperti GNN dapat mengungguli metode heuristik dalam menemukan komunitas nyata pada graf media sosial seperti Twitter dan Reddit.

Tahapan penelitian dilakukan dengan membangun representasi graf dari *dataset* Twitter, lalu melatih model GNN untuk memprediksi partisi komunitas. Hasil dari model GNN ini kemudian dibandingkan dengan hasil dari Louvain dan Leiden, yang digunakan sebagai baseline referensi. Evaluasi dilakukan menggunakan metrik akurasi, NMI (Normalized Mutual Information), dan ARI (Adjusted Rand Index). Dalam semua eksperimen, Leiden menunjukkan kinerja paling stabil dan

akurat sebagai metode partisi dasar, mengungguli Louvain dari segi konsistensi struktur komunitas yang terbentuk.

Meskipun GNN memiliki keunggulan dalam adaptasi terhadap bentuk jaringan yang kompleks, studi ini menunjukkan bahwa struktur komunitas yang diperoleh dari Leiden tetap menjadi tolok ukur terbaik dalam penilaian model pembelajaran graf. Hal ini menguatkan posisi Leiden sebagai pendekatan valid dalam mendeteksi komunitas sosial yang terpisah, yang secara tidak langsung relevan dengan deteksi *echo chamber*.

II.5.3 Integrasi ASBA dan Metrik Konsensus untuk *Echo chamber* (Aidira, 2025)

Penelitian oleh Amendola dkk. (2024) mengusulkan metrik *Echo Chamber Ratio* (ECR) sebagai pendekatan kuantitatif untuk mengukur tingkat keterkurungan informasi dalam komunitas daring. Pendekatan ini menggabungkan dua dimensi utama, yakni keselarasan opini dalam komunitas (*intra-consensus*) dan perbedaan opini antar komunitas (*inter-consensus*). ECR dirumuskan sebagai rasio antara ekspektasi konsensus dalam komunitas terhadap konsensus antar komunitas secara global. Dengan cara ini, nilai ECR yang tinggi mencerminkan tingkat polarisasi yang tajam sehingga komunitas bersifat homogen secara internal, namun heterogen terhadap komunitas lain. Metrik ini tidak hanya mengukur bias informasi, tetapi juga memberikan kerangka pengukuran yang dapat digeneralisasi untuk berbagai jenis jaringan sosial.

Tugas akhir oleh Aidira (2025) melengkapi dimensi ini dengan pendekatan semantik berbasis konten menggunakan Analisis Sentimen Berbasis Aspek (ASBA) dan kerangka konsensus *Group Decision Making* (GDM). ASBA digunakan untuk mengevaluasi polaritas opini pengguna terhadap berbagai entitas atau aspek dalam percakapan media sosial, sementara GDM digunakan untuk mengukur konsistensi opini di dalam komunitas. Sistem ini terbagi ke dalam beberapa tahap utama, yakni sebagai berikut.

- 1) Aidira menggunakan metode zero-shot NER dan *keyword extraction* untuk mengambil entitas publik seperti “Kampus Merdeka”, “Anies Baswedan”,

“Vaksin Sinovac”, dan aspek diskusi seperti “kebijakan”, “transparansi”, atau “efektivitas”.

- 2) Dilakukan menggunakan model transformer multibahasa (XLM-RoBERTa) yang telah dituning untuk ASBA secara domain-independen. Model ini menghasilkan skor polaritas dari -1 (negatif) hingga 1 (positif) untuk setiap pengguna terhadap tiap aspek.
- 3) Skor polaritas pengguna pada aspek-aspek tersebut kemudian dianalisis secara agregat menggunakan *entropy-based consensus score* dari GDM, yang menangkap kestabilan dan keseragaman opini dalam komunitas.

Namun, model Aidira (2025) belum mengeksplorasi secara langsung struktur jaringan dan arah difusi informasi antarkomunitas. Keterbatasan ini menimbulkan kebutuhan akan pendekatan hibrida yang mengintegrasikan baik dimensi semantik (ASBA + GDM) maupun struktural (graf interaksi + deteksi komunitas + metrik ECR). Oleh karena itu, penelitian ini mengambil inspirasi dari dua pendekatan tersebut dengan menyatukan kekuatan keduanya.


Dalam rancangan sistem tugas akhir Aidira (2025), arsitektur solusi menyelaraskan alur sebagai berikut.

- 1) Tahap awal dimulai dengan praproses teks terhadap data percakapan media sosial untuk membersihkan *noise* seperti URL, *mention*, emoji, dan karakter tidak relevan, serta melakukan normalisasi teks agar siap diproses pada tahap berikutnya.
- 2) Selanjutnya, dilakukan Analisis Sentimen Berbasis Aspek (ASBA) bebas domain menggunakan pendekatan *zero-shot Large Language Model* (LLM) generatif untuk mengidentifikasi aspek yang dibahas pengguna beserta polaritas sentimennya. Hasil ASBA digunakan untuk membangun representasi opini pengguna terhadap berbagai aspek dalam isu tertentu.
- 3) Setelah itu, dibentuk graf interaksi antarpengguna berdasarkan aktivitas interaksi di media sosial. Graf ini kemudian dianalisis menggunakan metode deteksi komunitas untuk mengidentifikasi kelompok pengguna yang memiliki keterhubungan erat dalam jaringan.

- 4) Pada tahap berikutnya, dilakukan perhitungan metrik konsensus dalam kerangka *Group Decision Making* (GDM) guna mengukur tingkat keselarasan opini di dalam komunitas maupun perbedaan opini antarkomunitas.
- 5) Nilai konsensus yang diperoleh kemudian digunakan untuk menghitung *Echo Chamber Ratio* (ECR) sebagai indikator tingkat keterkurungan informasi dan polarisasi dalam jaringan sosial daring.

II.5.4 Towards Echo chamber Assessment by Employing Aspect-Based Sentiment Analysis and GDM Consensus Metrics (Amendola dkk., 2024)

Penelitian ini mengukur tingkat *echo chamber* dalam media sosial dengan Analisis Sentimen Berbasis Aspek (ASBA) dan metrik consensus *Group Decision Making* (GDM) yang bertujuan untuk memperbaiki metode yang pernah ada sebelumnya dengan cara memasukkan analisis semantik dari opini pengguna dari berbagai topik. ASBA adalah teknik analisis teks yang mengategorisasikan data dari aspek dan menentukan polaritas sentimen di tiap kategori sedangkan GDM melibatkan dua atau lebih bidang dalam suatu konten. Terdapat sistem *pipeline* yang digunakan yang ditunjukkan pada Gambar II.14.



Gambar II.14. Sistem *pipeline* (Amendola dkk., 2024).

Dari sistem tersebut, penelitian ini menghasilkan deteksi polarisasi yang didefinisikan sebagai masalah GDM dan metrik-metrik *consensus* yang

diaplikasikan untuk menentukan kesepakatan di dalam komunitas dan antar komunitas yang berbeda dalam suatu jaringan. Eksperimen membandingkan metrik yang dirancang dengan opini yang diekstrak berdasarkan sentimen dan metrik berbasis topologi terkini pada dua *dataset* publik. Hasil yang dicapai menunjukkan bahwa konsensus menyediakan metrik yang ringkas untuk deteksi *echo chamber* dengan mempertimbangkan berbagai aspek topik, polarisasi komunitas, dan perbedaan antar komunitas. Lebih lanjut, dari perbandingan dengan metrik terkini, ternyata metrik yang diusulkan dapat digunakan secara sinergis dengan metrik terkini untuk mempertimbangkan topologi dan analisis konten untuk penilaian *echo chamber* yang lebih andal.

II.5.5 Relevansi Penelitian Terdahulu dengan Kebutuhan Tugas Akhir

Tabel II.3. Pemetaan relevansi dan kelemahan penelitian terdahulu terhadap kebutuhan Tugas Akhir

Penelitian (Tahun)	Relevansi terhadap Tugas Akhir	Kelemahan / GAP
Blekanov dkk. (2021)	Menunjukkan efektivitas Infomap dan Leiden dalam mendeteksi komunitas diskursif pada Twitter; mendukung pemilihan algoritma ECR.	Tidak melakukan pengukuran <i>echo chamber</i> secara kuantitatif; belum mengembangkan indeks seperti ECR untuk membandingkan komunitas.
Bonafilia (2023)	Menggunakan Leiden sebagai <i>baseline</i> dalam evaluasi GNN; membuktikan bahwa struktur partisi Leiden tetap valid dan kompetitif di era pembelajaran mesin.	Tidak membahas isi komunitas atau polarisasi; hanya fokus pada struktur dan akurasi partisi tanpa analisis bias informasi.

Penelitian (Tahun)	Relevansi terhadap Tugas Akhir	Kelemahan / GAP
Aidira (2025)	Mengukur keselarasan opini dalam komunitas secara semantik menggunakan ASBA dan konsensus GDM; relevan untuk menginspirasi pendekatan agregasi opini.	Tidak menggunakan struktur jaringan sosial eksplisit; tidak mengukur bias difusi
Amendola dkk. (2024)	Menggunakan pendekatan hibrida, yakni berbasis jaringan dan konten.	Tidak menggunakan kalibrasi dalam menentukan sentimen pada konten.

BAB III

ANALISIS PERSOALAN DAN RANCANGAN SOLUSI

III.1 Analisis Persoalan

Tugas akhir ini menggunakan algoritma Leiden untuk mendeteksi komunitas yang saling terhubung dan algoritma Infomap sebagai pembanding berbasis aliran informasi. Komunitas yang terbentuk harus memiliki ruang diskusi yang kohesif karena data media sosial secara alami berskala besar, tidak merata, dan jarang (*sparse*). Komunitas yang tidak terhubung secara internal akan menyebabkan interpretasi keliru tentang keseragaman opini dan arah difusi informasi.

Persoalan pertama berkaitan dengan *dataset*. *Dataset* ini masih perlu divalidasi terhadap sentimen dan tingkat kepercayaan sentimen yang ada. Pada dasarnya, nilai tingkat kepercayaan sentimen yang belum divalidasi tidak akan berubah jika sudah divalidasi. Hal-hal yang perlu divalidasi, yakni tingkat kepercayaan sentimen yang memiliki nilai $[0, 0.8)$. Jika memiliki nilai $[0.8, 1]$, maka hal ini dapat dipercaya. Dari *baseline* sebelumnya, yakni milik Aidira (2025) mempunyai *dataset* serta metode yang berbeda dengan penulis. Perbedaan tersebut dapat dilihat pada Tabel III.1.

Tabel III.1. Pemetaan *dataset* Aidira (2025) dan penulis

Referensi	<i>Dataset</i>	Nama Kolom
Aidira (2025)	<i>Budget Efficiency</i>	a. id_conversation b. created_at c. favorite_count d. text e. id f. image_url g. in_reply_to_screen_name h. lang

Referensi	Dataset	Nama Kolom
		i. location j. quote_count k. reply_count l. retweet_count
	<i>Indonesia Vaccination</i>	a. id b. text c. aspect_category_final d. aspect_sentiment e. community f. hard_label_final
	Pilpres 2024	a. id b. name c. text d. in_reply_to_status_id e. in_reply_to_screen_name f. community
Penulis	a. <i>Indonesia Vaccination</i> b. Indonesia Gelap c. Boikot Produk Israel d. Korupsi Haji e. Ijazah Jokowi f. Keracunan MBG	a. original_id b. from_id c. from_username d. cleaned_text e. final_sentiment f. sentiment_confidence_level g. reply_to_user_id h. retweet_from_user_id i. mentioned

Perbedaan signifikannya, yakni pada nama kolom `sentiment_confidence_level` yang membedakan bahwa Aidira (2025) tidak menggunakan kalibrasi probabilistik dalam menentukan sentimen suatu konten. Selain itu, interaksinya sangat terbatas, suatu *dataset* hanya memiliki satu sampai dengan dua jenis interaksi saja.

Sedangkan *dataset* penulis memiliki data yang lebih dinamis interaksinya, mencakup tiga jenis interaksi sekaligus, yakni *retweet*, *reply*, dan *mention*. Selain itu, jumlah *dataset* penulis 70 kali lebih banyak.

Label sentimen yang dihasilkan oleh sistem anotasi otomatis seperti IndSight API perlu divalidasi terhadap *ground truth* yang lebih andal. Tanpa validasi independen, hasil pengukuran ECR bergantung sepenuhnya pada kualitas label sentimen sumber, yang belum tentu mencerminkan opini nyata pengguna dalam konteks topik kontroversial berbahasa Indonesia.

III.2 Analisis Solusi

III.2.1 Ketersediaan Dataset

Dataset yang memenuhi kriteria adalah kumpulan cuitan (*tweet*) berbahasa Indonesia dengan domain yang kontroversial. *Dataset* ini diperoleh dari *platform* IndSight API dan mencakup tiga topik utama, yakni *Indonesia Vaccination* (vaksinasi COVID-19 periode Juli 2021), *Indonesia Gelap* (gerakan protes yang terjadi pada awal 2025), *Boikot Produk Israel* (kampanye boikot berbasis sentimen nasional dan keagamaan pada periode 2025), *Korupsi Haji* (korupsi yang dilakukan oleh Mantan Menteri Agama Yaquut Cholil Qoumas), *Ijazah Jokowi* (ijazah yang dipertanyakan keberadaannya), dan *Keracunan MBG* (program makan bergizi gratis yang menyebabkan sebagian siswa keracunan). Keenam topik ini dipilih karena sifatnya yang polaritatif, yaitu mendorong pengguna untuk mengambil sikap yang berlawanan secara eksplisit, sehingga cocok untuk pengukuran *echo chamber*.

Proses persiapan *dataset* dilakukan dalam tiga tahap. Pertama, pembersihan awal meliputi penghapusan karakter kutip tunggal (') di awal dan akhir kalimat yang berasal dari artefak pengambilan data via API. Kedua, pembersihan penuh dilakukan dengan menghapus emoji, tagar (#hashtag), karakter non-alfanumerik yang tidak relevan, serta tautan URL. Pembersihan ini bertujuan agar teks yang masuk ke model analisis sentimen tidak terganggu oleh elemen yang tidak bermakna semantis. Ketiga, normalisasi bahasa dilakukan dengan menyaring konten yang hanya berbahasa Indonesia menggunakan modul Python *langdetect*,

sehingga konten berbahasa asing yang terselip dalam *dataset* tidak ikut memengaruhi analisis.

Dataset mentah memiliki 700.000 data. Setelah proses pemfilteran berdasarkan ketersediaan nilai *sentiment_confidence_level* ($\geq 0,2$), *dataset* efektif yang digunakan dalam *pipeline* berjumlah ± 600.000 data yang tersebar atas ± 300.000 pengguna unik. Setiap data setidaknya memuat sembilan kolom utama, yakni *original_id*, *from_id*, *from_username*, *cleaned_text*, *final_sentiment*, *sentiment_confidence_level*, *reply_to_user_id*, *retweet_from_user_id*, dan *mentioned* yang dapat dilihat pada Tabel III.2.

Tabel III.2. Contoh data yang diambil dari topik *Indonesia Vaccination*

original_id	from_id	from_username	cleaned_text	final_sentiment
"1421259300488372230"	1,1105E+18	KeliekSoedarto	Kl u/ PTMT.... hrs ada sertifikat vaksin krn ke...	<i>positive</i>
sentiment_confidence_level	reply_to_user_id	retweet_from_user_id	mentioned	
0.496742	1,07E+24	NaN	(id,1074322491349262336)/(name,NurmaWa27)	

III.2.2 Kalibrasi Probabilistik

Label sentimen dari IndSight API diberikan dalam bentuk kategorik (*positive*, *neutral*, *negative*) disertai nilai *confidence_level* dalam rentang $[0, 1]$. Agar dapat digunakan dalam perhitungan ECR berbasis probabilistik, setiap label dikoversi menjadi distribusi probabilitas tiga kelas $[p_{neg}, p_{neu}, p_{pos}]$ menggunakan formula 3.1 dan 3.2.

$$p_{main} = \frac{1}{3} + confidence \times \left(\frac{2}{3}\right) \quad (3.1)$$

$$p_{other} = \frac{1 - p_{main}}{2} \quad (3.2)$$

Kelas yang sesuai dengan label sentimen mendapatkan nilai p_{main} , sedangkan dua kelas lainnya masing-masing mendapatkan nilai p_{other} . Hasil akhir dinormalisasi agar ketiga probabilitas menjumlahkan tepat 1,0. Dengan konstruksi ini, sebuah data dengan *confidence* = 0,5 pada label *positive* akan menghasilkan distribusi [0,167; 0,167; 0,667], sedangkan data dengan *confidence* = 0,9 pada label *negative* akan menghasilkan distribusi [0,933; 0,033; 0,033].

Penting untuk dicatat bahwa jumlah baris dari ketiga kolom probabilitas selalu bernilai tepat 1,0 untuk setiap data, sehingga standar deviasi dari jumlah baris tersebut secara matematis bernilai 0. Ini bukan anomali, melainkan konfirmasi bahwa formula normalisasi bekerja dengan benar. Variasi bermakna ada pada kolom-kolom probabilitas secara individual, yakni standar deviasi p_{neg} , p_{neu} , dan p_{pos} masing-masing menunjukkan nilai yang jauh dari nol, mencerminkan keberagaman distribusi keyakinan antarkelas di seluruh *dataset*.

Distribusi probabilitas yang dihasilkan dari konversi langsung belum tentu mencerminkan frekuensi kesalahan model yang sebenarnya. Model yang *overconfident* akan menghasilkan nilai p_{main} mendekati 1 meski prediksinya tidak selalu benar, sedangkan model *underconfident* menghasilkan distribusi yang terlalu mendekati seragam. Untuk mengukur dan memperbaiki ketidaksesuaian ini, digunakan metrik *Expected Calibration Error* (ECE) yang didefinisikan sebagai nilai absolut perbedaan antara rerata *confidence* dan rerata akurasi dalam setiap *bin* kepercayaan yang dibagi secara merata.

Metode kalibrasi yang digunakan adalah *isotonic regression* dengan skema *cross-validation* berlipat-5 (*stratified 5-fold*). Pilihan ini dilandasi oleh sifat *isotonic regression* yang nonparametrik dan mampu menangani distribusi probabilitas *non-monoton* tanpa asumsi distribusional, sementara *cross-validation* mencegah data *leakage* yang akan membuat hasil kalibrasi tidak realistis. Sebagai pembanding, dilakukan pula kalibrasi dengan metode *sigmoid* (*platt scaling*) dan *temperature scaling* agar dapat dipilih metode dengan ECE terendah. Persamaan ECE dapat dilihat pada formula 3.3.

$$ECE = \sum_{i=1}^K P(i) \cdot |o_i - e_i|, MCE = \max_{i=1}^K (|o_i - e_i|) \quad (3.3)$$

Di mana o_i adalah fraksi sebenarnya dari kejadian positif dalam bin i , e_i adalah rata-rata probabilitas pasca-kalibrasi untuk kejadian dalam bin i , dan $P(i)$ adalah probabilitas empiris (fraksi) dari semua kejadian yang termasuk dalam bin i . Semakin rendah nilai ECE dan MCE , semakin baik kalibrasi suatu model.

Selain kalibrasi keseluruhan, analisis juga dilakukan per tingkat kepercayaan minimum (*confidence threshold*). Untuk setiap *threshold* dari 0,2 hingga 0,9, dilakukan subpengambilan data dan kalibrasi independen agar terlihat bagaimana kualitas kalibrasi berubah seiring meningkatnya keyakinan awal label. Intuisi di balik analisis ini adalah bahwa data dengan *confidence* tinggi seharusnya sudah lebih terkalibrasi secara alami sehingga ECE sebelum kalibrasi lebih kecil, dan setelah kalibrasi dapat mencapai ECE mendekati 0.

III.2.3 Validasi Sentimen

Untuk memvalidasi kualitas label sentimen dari IndSight API sekaligus membandingkan performa metode analisis sentimen, dilakukan evaluasi menggunakan sampel 10.000 data yang dipilih secara acak dari data yang tidak memiliki nilai kosong pada kolom manapun. Syarat tidak ada nilai kosong diterapkan agar setiap data dapat direpresentasikan secara lengkap dalam analisis perbandingan.

Model yang digunakan untuk validasi adalah GPT 5.4 *mini* dari Open AI. Pemilihan GPT 5.4 *mini* dilandasi oleh kemampuannya memahami konteks bahasa Indonesia secara alami tanpa memerlukan proses translasi, serta ketepatan klasifikasi *zero-shot* yang tinggi pada teks pendek berkonten opini. Untuk efisiensi penggunaan token, teks dipotong maksimum 200 karakter per data dan dikirim dalam *batch* 50 teks per panggilan API dengan 5 pekerja konkuren. Sistem *prompt* yang digunakan sederhana dan terstruktur, yakni model diminta mengklasifikasikan setiap teks menjadi *positive*, *neutral*, atau *negative* tanpa penjelasan tambahan. Untuk *system prompt* dan *user prompt* dapat dilihat di Tabel III.3.

Tabel III.3. Desain *system prompt* dan *user prompt*

Jenis Prompt	Isi Prompt
<i>System Prompt</i>	"Anda adalah ahli analisis sentimen Bahasa Indonesia dan memahami slang/gaul." "Tugas Anda hanya mengklasifikasikan cleaned_text menjadi: <i>positive</i>, <i>neutral</i>, atau <i>negative</i>. " "Selalu kembalikan JSON array murni tanpa penjelasan."
<i>User Prompt</i>	Klasifikasikan setiap cleaned_text di bawah ini ke dalam salah satu label: - <i>positive</i> - <i>neutral</i> - <i>negative</i> Daftar cleaned_text: {<i>tweet_1</i>} {<i>tweet_2</i>} {<i>tweet_...</i>} Aturan: - Jawaburut sesuai nomor. - Output WAJIB JSON array murni sebanyak jumlah teks. - Jangan tambahkan penjelasan apa pun. - Contoh format: [<i>"positive"</i>, <i>"neutral"</i>, <i>"negative"</i>]

Sebagai pembandingan tambahan, digunakan pula model IndoBERT (mdhugol/indonesia-bert-sentiment-classification) yang merupakan model BERT yang telah di-*fine-tune* khusus untuk analisis sentimen bahasa Indonesia. IndoBERT dijalankan secara lokal menggunakan GPU dengan library Transformers dari Hugging Face. Akurasi dan *F1-score* dari kedua model dihitung dengan menggunakan label `final_sentiment` dari IndSight API sebagai referensi (*pseudo ground truth*).

III.2.4 Estimasi *User Leaning*, Bias Difusi, dan Pengukuran Homofili

Kecenderungan opini setiap pengguna (*user leaning*) dinyatakan sebagai nilai skalar dalam rentang $[-1, +1]$, di mana $+1$ berarti sepenuhnya pro terhadap topik, 0 berarti netral, dan -1 berarti sepenuhnya kontra. Nilai ini dihitung dari rerata probabilitas sentimen seluruh data milik pengguna tersebut menggunakan pemetaan ekspektasi yang ditunjukkan pada formula 3.4.

$$lean_{scalar} = 1 \cdot p_{neg_{mean}} + 0 \cdot p_{neu_{mean}} + (-1) \cdot p_{pos_{mean}} \quad (3.4)$$

Kelas "pro" dalam konteks topik Indonesia Gelap berarti setuju bahwa Indonesia sedang dalam kondisi gelap (sentimen negatif terhadap pemerintah), sehingga p_{neg} menjadi sinyal pro dan p_{pos} menjadi sinyal kontra. Nilai *leaning* dikalibrasi terlebih dahulu sebelum digunakan dalam perhitungan ECR.

Bias difusi diukur menggunakan simulasi *Independent Cascade* (IC) untuk merepresentasikan penyebaran informasi secara organik. Setiap pengguna secara bergantian dijadikan *seed*, kemudian dijalankan 20 kali simulasi untuk mendapatkan rata-rata himpunan pengguna yang terpengaruh. Dari himpunan tersebut dihitung rerata `lean_scalar` pengguna yang terpengaruh (`influence_mean`). Bias difusi diukur melalui regresi linear antara `lean_scalar seed` (sumbu x) dengan `influence_mean` (sumbu y). *Slope* regresi yang positif menandakan bahwa pengguna pro cenderung menyebarkan informasi ke pengguna yang juga pro (bias pro), dan sebaliknya.

Homofili mengukur sejauh mana pengguna cenderung berinteraksi dengan pengguna lain yang memiliki *leaning* serupa. Nilai ini diukur menggunakan korelasi *Pearson* antara `lean_scalar` setiap pengguna dengan rerata `lean_scalar` para

tetangganya (baik *predecessor* maupun *successor* dalam graf berarah). Nilai *Pearson r* yang mendekati 1 menunjukkan homofili kuat (pengguna pro berkumpul dengan pengguna pro, dan sebaliknya), sedangkan nilai mendekati 0 menunjukkan tidak ada pola preferensi dalam pembentukan koneksi.

III.2.5 Pembangunan Graf Interaksi dan Deteksi Komunitas

Graf interaksi dibangun dari tiga jenis interaksi eksplisit antarpengguna, yakni *retweet*, *reply*, dan *mention*. Setiap interaksi direpresentasikan sebagai sisi berarah dari pengguna sumber (*src*) ke pengguna tujuan (*dst*) dengan bobot default 1. Untuk *retweet*, kolom *retweet_from_user_id* diparsing menjadi pasangan *src-dst*. Untuk *mention*, kolom *mentioned* yang berformat (name,USERNAME)/(id,USERID) di-*parsing* menggunakan ekspresi reguler untuk mengekstrak setiap pasangan pengguna yang disebut. Sisi *self-loop* (*src* = *dst*) dan sisi yang melibatkan pengguna yang tidak memiliki data konten dieliminasi agar setiap simpul dalam graf dapat dikaitkan dengan setidaknya satu konten untuk perhitungan *leaning*.

Graf akhir bersifat berarah (*directed graph*) karena arah interaksi (siapa me-*retweet* siapa, siapa membalas siapa) mengandung informasi tentang arah aliran informasi yang relevan untuk simulasi difusi. Simpul merepresentasikan pengguna dan sisi merepresentasikan satu atau lebih interaksi antara dua pengguna.

Komunitas dalam jaringan dideteksi menggunakan algoritma Leiden dengan *RBConfigurationVertexPartition* sebagai fungsi objektif. Leiden dipilih karena menjamin komunitas yang *well-connected* secara internal, tidak seperti Louvain yang dapat menghasilkan komunitas yang saling terputus (*disconnected*). Nilai resolusi (γ) ditetapkan secara adaptif berdasarkan skala jaringan pada formula 3.5.

$$\gamma = \max(0,5; \log_{10}(|V| + 1)) \quad (3.5)$$

mana $|V|$ adalah jumlah simpul. Pendekatan ini menghasilkan komunitas yang cukup granular untuk menangkap kelompok diskusi yang bermakna namun tidak terlalu terfragmentasi menjadi komunitas-komunitas kecil yang tidak stabil.

Setiap komunitas diklasifikasikan ke dalam tiga sikap berdasarkan rerata *lean_scalar* anggotanya dengan ambang batas $\pm 0,2$ dengan klasifikasi, yakni

komunitas disebut "pro" jika $avg_leaning > 0,2$, "kontra" jika $avg_leaning < -0,2$, dan "neutral" jika berada di antara keduanya.

III.2.6 Echo Chamber Rasio (ECR)

Echo Chamber Ratio (ECR) didefinisikan sebagai rasio antara kesepakatan rata-rata intra-komunitas dengan kesepakatan rata-rata antar-komunitas dengan formula 3.6.

$$ECR = \frac{E[S_{intra}]}{E[S_{inter}]} \quad (3.6)$$

Fungsi kesepakatan menggunakan *agreement kernel* berbasis perbedaan *leaning* absolut pada persamaan 3.7.

$$agreement(u, v) = 1 - \frac{|lean_u - lean_v|}{2} \quad (3.7)$$

Nilai *agreement* berkisar antara 0 (berlawanan total) hingga 1 (identik). $ECR > 1$ menunjukkan bahwa pengguna dalam komunitas yang sama lebih sependapat daripada pengguna lintas komunitas, yang merupakan indikasi *echo chamber*.

Sebagai pembanding, dihitung pula ECR menggunakan *cosine similarity* dari vektor probabilitas [p_neg, p_neu, p_pos] setiap pengguna (GDM *Cosine Consensus*). Perbandingan dua metrik ini bertujuan memverifikasi bahwa kesimpulan ECR bersifat *robust* terhadap pilihan fungsi kemiripan.

Nilai ambang batas (*threshold*) ECR diperoleh dari *null model* berbasis permutasi. Sebanyak 100 iterasi dilakukan, di mana setiap iterasi mengacak sisi-sisi graf (*directed edge swap*) sambil mempertahankan distribusi *degree in-* dan *out-degree* setiap simpul, kemudian menghitung ECR pada graf yang teracak. *Threshold* ditetapkan sebagai persamaan 3.8.

$$threshold = \mu(ECR_{null}) + \sigma(ECR_{null}) \quad (3.8)$$

Jika ECR pengamatan melebihi *threshold*, maka fenomena diklasifikasikan sebagai *echo chamber*; jika tidak, maka diklasifikasikan sebagai *non-echo chamber*. Penting untuk dicatat bahwa standar deviasi distribusi *null model* (std_{null}) yang

digunakan di sini merujuk pada distribusi ECR dari 100 graf teracak, bukan pada standar deviasi baris probabilitas. Jika $std_{null} = 0$, hal ini menunjukkan bahwa semua graf teracak menghasilkan ECR yang identik, yang menandakan ada masalah dalam prosedur permutasi (misalnya, graf terlalu kecil atau tidak ada variasi *edge*). Solusinya adalah meningkatkan jumlah pertukaran sisi (n_swap) secara adaptif berdasarkan jumlah sisi aktual, serta memastikan bahwa nilai ECR dari graf teracak yang negatif atau tidak valid (*NaN*) tidak ikut dihitung.

III.2.7 Analisis Komunitas Pro vs Kontra dan Pergeseran Topik

Setiap komunitas dikategorisasi berdasarkan sikap dominannya, lalu diidentifikasi pengguna-pengguna sentral di komunitas pro dan komunitas kontra menggunakan beberapa ukuran sentralitas, yakni *degree centrality*, *betweenness centrality*, *PageRank*, dan *eigenvector centrality*. Pengguna yang memiliki skor sentralitas gabungan tertinggi dalam komunitasnya masing-masing disebut pengguna sentral.


Selain itu, diidentifikasi pula *bridge users*, yaitu pengguna yang berada di satu komunitas pro atau kontra, namun memiliki proporsi koneksi yang signifikan ke komunitas dengan sikap berlawanan. *Bridge score* dihitung sebagai rasio koneksi ke komunitas berlawanan terhadap total koneksi pengguna tersebut. *Bridge users* berperan penting dalam dinamika *echo chamber* karena mereka berpotensi menjadi jembatan pertukaran informasi lintas kutub.

Pergeseran topik mengukur perubahan sentimen rata-rata pengguna antara paruh awal dan paruh akhir postingan mereka. Analisis ini hanya dilakukan pada pengguna dengan *jumlah postingan* ≥ 10 agar pergeseran yang terdeteksi cukup andal secara statistik. Pergeseran dikategorikan ke dalam lima tipe, yakni stabil ($|shift| \leq 0,3$); *negative_to_positive*; *positive_to_negative*; *contra_to_pro*; dan *pro_to_contra*, dengan ambang batas awal dan akhir $\pm 0,2$ untuk kategori terakhir, yaitu perubahan kutub.


III.3 Rancangan Solusi

Dari Gambar III.1, ditunjukkan legenda BEAM Notation dan dari Gambar III.2, ditunjukkan model solusi yang bertujuan untuk mengukur tingkat *echo chamber* secara komprehensif dengan menggabungkan struktur jaringan sosial, distribusi

orientasi informasi pengguna, serta proses kalibrasi probabilistik. *Dataset* yang digunakan mencakup topik-topik publik yang kontroversial, yakni Boikot Produk Israel, Indonesia Gelap, dan *Indonesia Vaccination*.



Gambar III.1. Legenda BEAM Notation.



Gambar III.2. Rancangan Solusi Sistem.

Data ini terdiri atas cuitan (*tweets*), *retweet*, *mention*, dan interaksi lainnya yang mencerminkan aktivitas diskusi daring. Dari data mentah, dibangun graf interaksi pengguna berdasarkan relasi *retweet* dan *mention* yang mencerminkan hubungan diskusi eksplisit di platform X (Twitter). Simpul merepresentasikan pengguna, sementara sisi menunjukkan koneksi atau kesamaan antarpengguna. Graf berarah

dibentuk dari data, di mana bobot antarsimpul dihitung berdasarkan kemiripan konten atau intensitas interaksi sosial.

Komunitas dalam jaringan dibentuk menggunakan algoritma Leiden. Algoritma ini menjamin pembentukan komunitas yang *well-connected*, stabil, dan terhindar dari fragmentasi tidak realistis, berbeda dengan Louvain yang rentan menghasilkan komunitas tidak saling terhubung. Preferensi informasi pengguna dihitung berdasarkan distribusi label *leaning* $(-1, 0, +1)$, yang dikalibrasi ulang menggunakan metode *isotonic regression* dengan *cross-validation*, sehingga menghasilkan distribusi probabilitas yang lebih akurat.

Kalibrasi probabilistik diperlukan untuk mengatasi permasalahan tersebut, namun penerapannya juga menghadirkan tantangan. Proses kalibrasi harus menjaga keseimbangan antara penyesuaian distribusi probabilitas dan pelestarian informasi awal yang dikandung oleh model. Kalibrasi yang berlebihan berisiko meredam perbedaan opini yang sebenarnya signifikan, sedangkan kalibrasi yang tidak memadai tetap meninggalkan ketidakpastian pada estimasi preferensi pengguna.

Homofili diukur berdasarkan korelasi antara orientasi preferensi pengguna dengan lingkungan sosialnya. Sementara bias difusi dihitung menggunakan simulasi *Independent Cascade* (IC) untuk melihat arah penyebaran informasi dari sumber ke target. Nilai ECR dirumuskan sebagai rasio antara ekspektasi kesepakatan sesama komunitas ($E[S_{intra}]$) dengan kesepakatan antarkomunitas ($E[S_{inter}]$). Nilai ECR yang tinggi menunjukkan *echo chamber* yang kuat karena komunitas internal sangat homogen namun berbeda tajam dengan komunitas lain.

Setelah mendapatkan nilai ECR, dilakukan perhitungan *threshold* ECR karena nilai ini merupakan nilai ambang dari penentuan suatu topik merupakan *echo chamber* atau tidak. Jika $ECR > threshold$, maka ini diklasifikasikan sebagai fenomena *echo chamber*. Sebaliknya, maka ini diklasifikasikan sebagai fenomena *non-echo chamber*.

Secara keseluruhan, alur *pipeline* ECR dapat diringkas dalam tahap-tahap berikut. Pertama, data mentah dimuat dan dibersihkan, lalu label sentimen dikonversi menjadi distribusi probabilitas menggunakan formula *confidence-weighted*. Kedua, probabilitas dikalibrasi menggunakan *isotonic regression* lintas lipatan agar

mencerminkan tingkat ketidakpastian yang sesungguhnya. Ketiga, graf interaksi dibangun dan komunitas dideteksi dengan Leiden pada resolusi adaptif. Keempat, *user leaning* dihitung dari distribusi probabilitas terkalibrasi, lalu homofili dan ECR dihitung. Kelima, *threshold* diperoleh dari *null model* permutasi dan fenomena diklasifikasikan. Keenam, simulasi *Independent Cascade* dijalankan untuk mengukur bias difusi, dan pergeseran topik dianalisis untuk memahami dinamika opini pengguna secara temporal.

III.3.1 Praproses Teks

Masukan dari praproses, yakni berupa *dataset tweet* mentah dari X. Praproses teks diperlukan untuk membersihkan teks-teks yang hanya diperlukan dan dibersihkan. Ada beberapa tahapan yang perlu dilakukan untuk menyaringnya sehingga benar-benar bersih. Tahapan praproses tersebut, yakni sebagai berikut.

- (1) Mengubah seluruh teks menjadi huruf kecil untuk menghindari duplikasi fitur akibat perbedaan kapitalisasi.
- (2) Menghapus semua tautan karena tidak memberikan kontribusi langsung terhadap makna sentimen.
- (3) Menghapus semua *mention* karena lebih merepresentasikan interaksi sosial daripada konten semantik.
- (4) Melakukan normalisasi tagar dengan cara menghapus simbol “#,” namun kata tetap dipertahankan, karena sering mengandung informasi topik.
- (5) Menghapus *emoji* dan tanda baca untuk menyederhanakan teks.
- (6) Mengubah kata tidak baku menjadi bentuk baku menggunakan kamus slang.
- (7) Menghapus kata umum yang tidak memiliki makna signifikan (misalnya “dan”, “yang”, “di”).
- (8) Menghapus *tweet* dengan teks identik, serta *tweet* kosong setelah *preprocessing* dibuang.

Contoh hasil dari setelah dilakukan tahapan praproses dapat dilihat pada tabel, yakni Tabel III.4.

Tabel III.4. Contoh sebelum dan setelah praproses teks


Sebelum Praproses	Setelah Praproses
Warga Antusias, @pembkabsidoarjo2 Diminta Lobi Pusat untuk Tambah Kuota Vaksin https://t.co/L2us6Ez5w3 lewat @Radar Sidoarjo #Sidoarjo	Warga Antusias, Diminta Lobi Pusat untuk Tambah Kuota Vaksin lewat Sidoarjo

III.3.2 Kalibrasi Probabilistik

Masukan tahap ini adalah label sentimen kategorik (*positive/neutral/negative*) beserta nilai *confidence_level* dalam rentang $[0,1]$ dari model *fine-tuned*. Tujuannya adalah memastikan distribusi probabilitas prediktif model konsisten dengan frekuensi kejadian aktual sehingga skor kepercayaan dapat digunakan secara andal pada perhitungan ECR. Prosesnya terdiri dari empat langkah, yakni sebagai berikut.

- (1) Konversi label kategorik menjadi distribusi probabilitas tiga kelas $[p_{neg}, p_{neu}, p_{pos}]$.
- (2) Penerapan tiga metode kalibrasi pembandingan, yakni *isotonic regression* (5-fold *stratified cross-validation*), *sigmoid* (*Platt scaling*), dan *temperature scaling*.
- (3) Evaluasi kalibrasi menggunakan metrik *Expected Calibration Error* (ECE), *log loss*, dan *Brier score*.
- (4) Analisis kalibrasi per *confidence threshold* dari 0,2 hingga 0,9 untuk melihat bagaimana kualitas kalibrasi berubah seiring meningkatnya keyakinan awal label.

Keluaran tahap ini adalah distribusi probabilitas tiga kelas yang lebih reliabel, yang akan digunakan sebagai dasar perhitungan *user leaning* pada tahap selanjutnya. Sebagai catatan, eksperimen menunjukkan bahwa kalibrasi tidak mengubah label sentimen akhir sehingga dalam *pipeline* ECR final tidak diterapkan, namun analisis kalibrasi tetap dilakukan untuk memvalidasi kelayakan probabilitas yang dihasilkan. Contohnya seperti pada Gambar III.3.




Gambar III.3. Analisis kalibrasi per tingkat *confidence*

Ditunjukkan bahwa tidak ada sentimen yang berubah setelah dilakukan kalibrasi probabilistik meskipun nilai ECE sudah turun ke nilai 0 (nol). Artinya, label sentimen sebelumnya sudah valid dan perlu dilakukan pengecekan tingkat kepercayaan sentimen dalam rentang $[0, 0.8)$ dan $[0.8, 1]$ dengan metrik akurasi dan *f1-score*.

III.3.3 Estimasi *User Leaning*

Masukan tahap ini adalah distribusi probabilitas sentimen $[p_{neg}, p_{neu}, p_{pos}]$ setiap data milik tiap pengguna. Tujuannya adalah menghasilkan satu nilai skalar yang merepresentasikan kecenderungan opini setiap pengguna terhadap topik dalam rentang $[-1, +1]$, di mana $+1$ berarti sepenuhnya pro, 0 berarti netral, dan -1 berarti sepenuhnya kontra. Prosesnya menggunakan rerata probabilitas sentimen seluruh data pengguna lalu memetakannya melalui pemetaan ekspektasi yang memerhatikan konteks topik, misalnya pada topik Indonesia Gelap, kelas "pro" berarti setuju bahwa Indonesia sedang gelap (sentimen negatif terhadap pemerintah), sehingga p_{neg} menjadi sinyal pro. Keluaran tahap ini adalah nilai *lean_scalar* per pengguna yang divisualisasikan dalam Gambar III.4. Distribusi *user leaning* (kiri) dan *leaning vs confidence* (kanan).




Gambar III.4. *User leaning* (kiri) dan *leaning vs confidence* (kanan)

Berdasarkan Gambar III.4, arti dari gambar sebelah kiri (*user leaning*), yakni mendekati suatu nilai, artinya pro (+1), netral (0), dan kontra (-1). Pada gambar tersebut juga ditunjukkan *user* terbanyak di pro, lalu kontra, dan terakhir netral. Sisanya, ambigu di antara kedua tim. Sedangkan pada gambar sebelah kanan (*leaning vs confidence*), tingkat kepercayaan/keakuratan bahwa *user* termasuk pada suatu tim itu tinggi/rendah. Pada gambar, hampir 100% akurat dan dapat dipercaya hasil pembagian timnya.

III.3.4 Pembangunan Graf Interaksi dan Deteksi Komunitas

Masukan dari proses ini adalah gabungan dari dua komponen, yakni interaksi (pengguna asal dan pengguna tujuan, jenis interaksi, dan bobot interaksi), serta konten (pengguna dan probabilitas dari tingkat kepercayaan sentimen). Graf interaksi dibangun untuk merepresentasikan hubungan antar pengguna dalam *platform*. Pengguna direpresentasikan sebagai simpul, interaksi antar pengguna direpresentasikan sebagai sisi, dan frekuensi interaksi adalah bobot dari suatu graf. Setiap simpul juga diberi atribut sentimen dan graf ini menjadi dasar untuk deteksi komunitas, analisis homofili, dan simulasi difusi informasi. Contoh suatu graf, yakni ditunjukkan pada Gambar III.5 (kiri) yang didominasi oleh tim kontra dan Gambar III.5 (kanan) yang didominasi oleh tim pro.



Gambar III.5. Graf topik: *Indonesia Vaccination* (kiri) dan graf topik: Boikot Produk Israel (kanan).

Dari graf-graf yang ditunjukkan pada Gambar III.6, interaksi antarpengguna cenderung sering terjadi sehingga ini bersifat aktif. Gambar tersebut juga menunjukkan bahwa tim kontra mendominasi pada topik *Indonesia Vaccination* dan tim pro mendominasi pada topik boikot produk Israel. Lalu, yang membedakan antara kedua graf tersebut adalah graf kanan lebih luas interaksinya daripada graf kiri, sehingga penggunaanya lebih menyebar dalam gambar tersebut.

Selanjutnya, suatu komunitas dapat dilihat tim yang mendominasi, banyak penggunaanya, serta nilai-nilai, seperti rata-rata, standar deviasi, dan hingga modularitas suatu graf yang ditunjukkan pada Tabel III.5.

Tabel III.5. Keterangan dari suatu komunitas

commu nity_id	stance	size	avg_lea ning	std_lea ning	interna l_edges	externa l_edges	modula rity
0	pro	4213	0.965	0.1644	4213	140	0.968

Berdasarkan Tabel III.8, komunitas ini terdiri dari 4.213 simpul yang hampir seluruhnya berpendirian pro, sangat terhubung satu sama lain (*internal edges* tinggi), dan sangat sedikit terhubung ke luar (hanya 140 *external edges*). *Modularity* 0.968 menunjukkan komunitas ini sangat terpisah dengan baik dari komunitas lain ini adalah *echo chamber* yang kuat.

Tabel III.6. Deteksi komunitas algoritma Leiden


<i>Dataset</i>	Jumlah komunitas	Jumlah komunitas dari tim (pro/netral/kontra)
<i>Indonesia Vaccination</i>	7794	Pro: 2900
		Netral: 2464
		Kontra: 2430
Indonesia Gelap	352	Pro: 303
		Netral: 38
		Kontra: 11
Boikot Produk Israel	1632	Pro: 1234
		Netral: 340
		Kontra: 58
Korupsi Haji		Pro:
		Netral:
		Kontra:
Ijazah Jokowi		Pro:
		Netral:
		Kontra:
Keracunan MBG		Pro:
		Netral:

<i>Dataset</i>	Jumlah komunitas	Jumlah komunitas dari tim (pro/netral/kontra)
		Kontra:

Berdasarkan Tabel III.6, misalnya pada topik *Indonesia Vaccination* yang memiliki 2900 komunitas yang pro dengan topik tersebut, sedangkan jumlah pengguna yang kontra dengan topik tersebut terlihat dominan dari graf pada Gambar III.6. Ini terlihat kontradiktif, namun bisa terjadi karena bisa saja orang yang kontra dengan topik, justru satu komunitas dengan yang mayoritas adalah tim pro.

III.3.5 Pengukuran Homofili

Masukan tahap ini adalah graf interaksi G dan nilai *lean_scalar* setiap pengguna. Tujuannya adalah mengukur sejauh mana pengguna cenderung berinteraksi dengan pengguna lain yang memiliki orientasi serupa, sebagai indikator pendukung *echo chamber*. Prosesnya dilakukan dengan menghitung korelasi *Pearson* antara *lean_scalar* setiap pengguna dengan rerata *lean_scalar* para tetangganya (baik *predecessor* maupun *successor* dalam graf berarah).



Gambar III.6. *Homophily* dari topik *Indonesia Vaccination*

Keluaran tahap ini adalah nilai korelasi *Pearson* r . Jika r mendekati 1, maka ini menunjukkan homofili kuat (pengguna pro berkumpul dengan pengguna pro) dan jika r mendekati 0, maka ini menunjukkan tidak ada pola preferensi dalam pembentukan koneksi.

III.3.6 Pengukuran Bias Difusi

Masukan tahap ini adalah graf interaksi G dengan atribut *lean_scalar* per pengguna. Tujuannya adalah mengukur sejauh mana informasi cenderung menyebar secara selektif di antara pengguna dengan orientasi serupa. Prosesnya menggunakan simulasi *Independent Cascade* (IC) di mana setiap pengguna secara bergantian dijadikan *seed* dengan 20 kali iterasi simulasi untuk mendapatkan rerata himpunan pengguna yang terpengaruh. Setelah itu, regresi linier dilakukan antara *lean_scalar seed* (sumbu x) dan rerata *lean_scalar* pengguna terpengaruh *influence_mean* (sumbu y). Keluaran tahap ini adalah lima metrik utama, yakni *slope* regresi, R^2 , *bias ratio*, statistik uji- t , dan *Cohen's d*. *Slope* yang positif menandakan pengguna pro cenderung menyebarkan informasi ke sesama pro (bias pro), sedangkan *Cohen's d* kecil menunjukkan efek bias secara praktis tidak bermakna meskipun signifikan secara statistik.

III.3.7 Echo Chamber Ratio (ECR)

Tahap ini menerima tiga masukan utama, yakni sebagai berikut.

- (1) Graf interaksi berarah $G = (V, E)$ hasil pembangunan graf pada tahap sebelumnya, di mana V adalah himpunan pengguna dan E adalah himpunan *edge* berbobot yang merepresentasikan interaksi (*retweet*, *reply*, dan *mention*).
- (2) Nilai *user leaning*: $\ell_u \in [-1, +1]$ untuk setiap pengguna $u \in V$ yang telah dikalibrasi secara probabilistik.
- (3) Partisi komunitas $C = \{C_1, C_2, \dots, C_k\}$ hasil deteksi komunitas menggunakan algoritma Leiden.

Proses dimulai dengan penghitungan *agreement kernel* untuk setiap pasangan pengguna (u, v) yang terhubung oleh *edge* dalam graf menggunakan fungsi $agreement(u, v) = 1 - \frac{|\ell_u - \ell_v|}{2}$, yang menghasilkan nilai dalam rentang $[0, 1]$ di mana nilai mendekati 1 menunjukkan kesamaan orientasi yang tinggi. Selanjutnya, setiap *edge* (u, v) diklasifikasikan sebagai *intra-community edge* jika $C(u) = C(v)$ atau *inter-community edge* jika $C(u) \neq C(v)$. Dari klasifikasi tersebut, dihitung rata-rata *agreement* untuk masing-masing kelompok, yakni untuk intra:

$$E[S_{intra}] = \frac{1}{|E_{intra}|} \sum_{(u,v) \in E_{intra}} agreement(u, v) \text{ dan untuk inter: } E[S_{inter}] =$$

$\frac{1}{|E_{inter}|} \sum_{(u,v) \in E_{inter}} agreement(u,v)$. Rasio ECR kemudian dihitung sebagai $ECR = \frac{E[S_{intra}]}{E[S_{inter}]}$, di mana nilai $ECR > 1$ mengindikasikan kesamaan opini di dalam komunitas lebih tinggi dibandingkan antar komunitas sebagai indikasi awal potensi *echo chamber*.

Untuk menentukan apakah nilai ECR yang diperoleh bermakna, dilakukan estimasi *threshold* menggunakan *null model* melalui 100 iterasi permutasi dengan *directed edge swap* yang mempertahankan distribusi derajat. Pada setiap iterasi, ECR dihitung ulang pada graf acak dan *threshold* ditentukan sebagai $\theta = \mu(ECR_{null}) + \sigma(ECR_{null})$. Jika $ECR \geq \theta$, fenomena diklasifikasikan sebagai *echo chamber*. Sebaliknya sebagai *non-echo chamber*.

III.3.8 Analisis Komunitas Pro vs Kontra dan Pergeseran Topik

Tahap ini menerima tiga masukan, yakni sebagai berikut.

- (1) Partisi komunitas $C = \{C_1, C_2, \dots, C_k\}$ hasil deteksi komunitas pada tahap sebelumnya.
- (2) Nilai user leaning ℓ_u untuk setiap pengguna.
- (3) Data temporal posting setiap pengguna dalam urutan kronologis.

Proses dimulai dengan klasifikasi *stance* setiap komunitas C_i berdasarkan rata-rata *leaning* anggotanya adalah pro jika $\bar{\ell}_{C_i} > 0.2$, kontra jika $\bar{\ell}_{C_i} < -0.2$, dan netral jika $-0.2 \leq \bar{\ell}_{C_i} \leq 0.2$. Untuk setiap komunitas dihitung statistik deskriptif meliputi ukuran, rata-rata *leaning*, standar deviasi *leaning*, jumlah internal *edges*, jumlah *external edges*, dan modularitas lokal. Selanjutnya, diidentifikasi *bridge users* yaitu pengguna yang memiliki koneksi signifikan ke komunitas dengan *stance* berbeda, yakni dihitung sebagai $bridge\ score(u) = \frac{\min(pro\ connections, contra\ connections)}{total\ connections}$.

Analisis pergeseran sentimen dilakukan terhadap pengguna yang memiliki minimal 10 *posting* dengan membagi *posting* secara kronologis menjadi paruh awal dan paruh akhir, kemudian menghitung selisih rata-rata sentimen $\Delta\ell_u = \bar{\ell}_{u,late} - \bar{\ell}_{u,early}$. Setiap pengguna dikategorikan ke dalam salah satu tipe pergeseran, yakni

stable jika perubahan kecil dan tidak signifikan ($|\Delta \ell_u| < 0.3$); *positive to negative* atau *negative to positive* jika terjadi perubahan arah sentimen umum; serta *pro to contra* atau *contra to pro* jika terjadi perubahan orientasi *stance* yang ekstrem melewati batas ± 0.2 .

Tahap ini menghasilkan tiga keluaran utama, yakni tabel ringkasan komunitas yang memuat *stance*, ukuran, rata-rata *leaning*, standar deviasi, jumlah *edge* internal dan eksternal, serta modularitas per komunitas; daftar *bridge users* beserta *bridge score* masing-masing; dan tabel pergeseran sentimen yang memuat *username*, jumlah *posting*, sentimen awal, sentimen akhir, besaran pergeseran, dan tipe pergeseran untuk setiap pengguna yang memenuhi syarat.

III.4 Implementasi Solusi

III.4.1 Praproses Teks

Bagian ini adalah tahap pembersihan dan normalisasi data mentah *tweet* sebelum digunakan dalam *pipeline*. Tujuannya adalah menghilangkan *noise* yang tidak relevan bagi analisis sentimen, seperti URL, *mention*, *emoji*, tanda baca, dan *slang* bahasa Indonesia sehingga teks yang masuk ke model klasifikasi sentimen bersih dan konsisten. Duplikat dan teks kosong juga dihapus untuk menghindari bias pengulangan. Implementasi praproses teks dapat dilihat pada Gambar III.7.

```
FUNCTION preprocess(raw_tweets):  
    tweets ← load_csv(raw_tweets)  
    FOR each tweet IN tweets:  
        text ← lowercase(tweet.text)  
        text ← remove_urls(text)  
        text ← remove_mentions(text)           // @username  
        text ← remove_hashtags_symbols(text)    // keep word, drop #  
        text ← remove_emojis_punctuation(text)  
        text ← normalize_slang(text)             // Indonesian slang → baku  
        text ← remove_stopwords(text)  
        tweet.clean_text ← text
```

```

tweets ← drop_duplicates(tweets, key=clean_text)

tweets ← drop_empty(tweets)

RETURN tweets

```

Gambar III.7. *Pseudocode* praproses teks

III.4.2 Klasifikasi Sentimen (*fine-tuned model*)

Bagian ini adalah tahap pelabelan sentimen setiap *tweet* menggunakan model *fine-tuned* XLM-RoBERTa. Tujuannya adalah menghasilkan label sentimen (*negative*, *neutral*, *positive*) beserta distribusi probabilitasnya untuk setiap *tweet*. Distribusi probabilitas ini (p_{neg} , p_{neu} , p_{pos}) menjadi dasar penghitungan *user leaning* pada tahap selanjutnya, sehingga akurasi dan kalibrasi skor pada tahap ini secara langsung memengaruhi kualitas pengukuran *echo chamber*. Implementasi klasifikasi sentimen teks dapat dilihat pada Gambar III.8.

```

FUNCTION classify_sentiment(tweets, model):

    FOR each batch IN tweets:

        logits ← model.forward(batch.clean_text)

        labels ← argmax(softmax(logits))      // {negative, neutral,
positive}

        scores ← softmax(logits)

        batch.sentiment ← labels

        batch.sentiment_score ← scores

    RETURN tweets

```

Gambar III.8. *Pseudocode* klasifikasi sentimen

III.4.3 Pembangunan Graf Interaksi

Bagian ini adalah tahap pembentukan graf berarah berbobot dari data interaksi antar pengguna. Tujuannya adalah merepresentasikan jaringan sosial sebagai struktur graf $G = (V, E)$ di mana setiap *node* $v \in V$ adalah pengguna dengan atribut sentimen, dan setiap *edge* $(u, v) \in E$ merepresentasikan interaksi (*retweet*, *reply*, atau *mention*) dengan bobot yang diakumulasi jika terdapat interaksi berulang. Graf ini menjadi masukan utama bagi deteksi komunitas, pengukuran homofili, simulasi

difusi, dan penghitungan ECR. Implementasi pembangunan graf interaksi dapat dilihat pada Gambar III.9.

```

FUNCTION build_graph(tweets):

    G ← empty_directed_graph()

    FOR each tweet t IN tweets:

        G.add_node(t.user, sentiment=t.sentiment)

        IF t.is_retweet OR t.is_reply OR t.is_mention:

            target ← t.target_user

            G.add_edge(t.user → target, weight += 1)

    RETURN G

```

Gambar III.9. *Pseudocode* pembangunan graf interaksi

III.4.4 Deteksi Komunitas

Bagian ini adalah tahap partisi graf menjadi komunitas-komunitas menggunakan algoritma Leiden. Tujuannya adalah mengidentifikasi kelompok pengguna yang saling terhubung erat dalam jaringan. Algoritma Leiden dipilih karena memiliki keunggulan dibandingkan Louvain berupa jaminan bahwa setiap komunitas yang dihasilkan bersifat *well-connected*, artinya tidak mengandung subgraf terputus (*disconnected subgraph*). Hal ini dicapai melalui fase *refinement* yang merupakan langkah kunci yang membedakan Leiden dari Louvain. Selain itu, terdapat aliran informasi dengan algoritma Infomap dan konsensus *Multi-level* Partisi komunitas yang dihasilkan menjadi dasar pembagian *edge* menjadi intra-komunitas dan inter-komunitas pada penghitungan ECR. Implementasi deteksi komunitas dapat dilihat pada Gambar III.10.

```

FUNCTION leiden_communities(G, resolution=1.0):

    // Phase 1: local moving

    partition ← singleton_partition(G.nodes)

    REPEAT:

        improved ← FALSE

        FOR each node v IN random_order(G.nodes):

```

```

        best_C ← argmax over neighbor communities C of  $\Delta Q(v \rightarrow C)$ 

        IF best_C ≠ current_community(v):
            move v → best_C
            improved ← TRUE

    UNTIL NOT improved

    // Phase 2: refinement (Leiden's key step vs Louvain)
    refined ← refine_partition(partition)    // ensures well-connected
communities

    // Phase 3: aggregate
    G_agg ← contract(G, refined)

    IF |communities| changed:
        RETURN leiden_communities(G_agg, resolution)

    RETURN partition

FUNCTION infomap_communities(G):
    // Minimize the Map Equation L(M) over modular description lengths
    // using random walks on G (directed flow when G is directed).
    flags ← "--silent --seed <s>"
    IF G is directed: flags ← flags + " --directed"
    im ← new Infomap(flags)
    FOR each edge (u, v, w) IN G.edges:
        im.add_link(u, v, w)
    im.run()
    partition ← {u → module_id(u) : u IN G.nodes}
    RETURN partition

FUNCTION mlcc_consensus(G, partitions, L=3, similarity="cosine"):
    // INPUT : G = interaction graph (N nodes);
    // partitions = [ $\pi_1$ , ...,  $\pi_B$ ] ensemble of partitions of
G.nodes

```

```

//                                (e.g.  $\pi_1 = \text{leiden\_communities}(G)$ ,
//                                 $\pi_2 = \text{infomap\_communities}(G)$ );
//                                L = number of transition levels;
//                                similarity  $\in \{\text{"cosine"}, \text{"euclidean"}\}$ .
// OUTPUT : a single consensus partition of G.nodes.

// Step 1: Ensemble preparation -
// Re-label clusters across partitions to a global index 0..K-1.
global_id       $\leftarrow \{\}$                                 // (b, local_c)  $\rightarrow$  g
cluster_size    $\leftarrow [ ]$                                 // size of each global
cluster

node_cluster    $\leftarrow$  matrix[B  $\times$  N] of NIL            // node  $\rightarrow$  global
cluster per partition

FOR b IN 0..B-1:
    FOR each (node u, local_cluster c) IN partitions[b]:
        IF (b, c)  $\notin$  global_id:
            global_id[(b, c)]  $\leftarrow$  |cluster_size|
            cluster_size.append(0)
            g  $\leftarrow$  global_id[(b, c)]
            node_cluster[b][index(u)]  $\leftarrow$  g
            cluster_size[g]  $\leftarrow$  cluster_size[g] + 1
K  $\leftarrow$  |cluster_size|

// Step 2: Cluster graph G(C) with SCCS weights
// Within-partition overlap = 0 (partitions are disjoint).
intersect  $\leftarrow \{\}$                                 // (g_i, g_j)  $\rightarrow$  |c_i
 $\cap$  c_j|
FOR each node index i IN 0..N-1:
    FOR each pair (b1 < b2):
        g1  $\leftarrow$  node_cluster[b1][i]; g2  $\leftarrow$  node_cluster[b2][i]
        IF g1  $\neq$  NIL AND g2  $\neq$  NIL:
            key  $\leftarrow$  sort(g1, g2)

```

```

        intersect[key] ← intersect[key] + 1

W ← zero_matrix[K × K]

FOR each ((g_i, g_j), inter) IN intersect:
    sz_i ← cluster_size[g_i];  sz_j ← cluster_size[g_j]
    SCCS ← 1/2 + inter / max(sz_i, sz_j) - (sz_i · sz_j) / (2 · N²)
    IF SCCS > 0:
        W[g_i, g_j] ← SCCS;  W[g_j, g_i] ← SCCS

// Step 3: Multi-level transition probability
// Row-normalize W → P¹; then P¹ = (P¹)¹ for 1 = 2..L.
P_1 ← row_normalize(W)
P_levels ← [P_1]
P_curr ← P_1
FOR 1 IN 2..L:
    P_curr ← P_curr · P_1
    P_levels.append(P_curr)

// Step 4: Multi-level feature space –
F ← concat_columns(P_levels) // shape K × (K · L)

// Step 5: Cluster-cluster similarity matrix S = 1 - D(F)
IF similarity == "cosine":
    F_norm ← normalize_rows(F)
    S ← (F_norm · F_normT + 1) / 2 // rescale [-1, 1] → [0, 1]
ELSE: // euclidean
    D ← pairwise_euclidean(F)
    S ← 1 - D / max(D)

// Step 6: Point-point similarity M (sparse over G.edges)

```

```

//  $M(u, v) = (1/B) \cdot \sum_b S(\pi_b(u), \pi_b(v))$ 

H ← empty_undirected_graph(); H.add_nodes(G.nodes)

FOR each edge (u, v, w_uv) IN G.edges:

    IF u == v: CONTINUE

    sims ← [ ]

    FOR b IN 0..B-1:

        g_u ← node_cluster[b][index(u)]

        g_v ← node_cluster[b][index(v)]

        IF g_u ≠ NIL AND g_v ≠ NIL:

            IF g_u == g_v: sims.append(1.0)

            ELSE : sims.append(S[g_u, g_v])

    IF sims is empty: CONTINUE

    m_uv ← mean(sims)

    IF m_uv ≤ 0: CONTINUE

    H.add_edge(u, v, weight = w_uv · m_uv) // accumulate if
exists

// Step 7: Secondary clustering on consensus weighted graph H
// Pho dkk. (2021) propose agglomerative hierarchical clustering with
// complete linkage on M. For large G ( $N \gtrsim 10^5$ ) this is infeasible,
// so Leiden is applied on H instead; the multi-level signal of
// steps 1-6 is preserved through the consensus edge weights.

consensus ← leiden_communities(H, resolution= $\rho$ )

RETURN consensus

```

Gambar III.10. *Pseudocode* deteksi komunitas

III.4.5 Pengukuran Homofili

Bagian ini adalah tahap pengukuran kecenderungan pengguna untuk berinteraksi dengan pengguna lain yang memiliki atribut serupa (*homophily*). Tujuannya adalah mengukur sejauh mana jaringan menunjukkan segregasi berdasarkan sentimen atau komunitas. Homofili dihitung sebagai *assortativity coefficient*, yakni proporsi *edge* yang menghubungkan pengguna dengan atribut sama (*observed*) dibandingkan

dengan ekspektasi pada jaringan acak (*expected*). Nilai asortativitas positif menunjukkan adanya kecenderungan segregasi, yang merupakan salah satu indikator pendukung *echo chamber*. Implementasi pengukuran homofili dapat dilihat pada Gambar III.11.

```

FUNCTION homophily(G, attribute):  // attribute = sentiment or community
    same ← 0
    total ← 0
    FOR each edge (u,v) IN G.edges:
        total ← total + 1
        IF attribute[u] == attribute[v]:
            same ← same + 1
    observed ← same / total

    // Expected under random mixing
    expected ←  $\sum_c (\text{fraction}_c)^2$ 
    assortativity ← (observed - expected) / (1 - expected)
    RETURN assortativity

```

Gambar III.11. *Pseudocode* pengukuran homofili

III.4.6 Bias Difusi

Bagian ini adalah tahap simulasi penyebaran informasi dalam jaringan menggunakan model *Independent Cascade* (IC). Tujuannya adalah mengukur *diffusion bias*, yaitu sejauh mana informasi cenderung menyebar secara selektif di antara pengguna dengan orientasi atau komunitas yang sama. Simulasi dimulai dari sejumlah *seed* pengguna, kemudian informasi menyebar ke tetangga dengan probabilitas yang dipengaruhi oleh fungsi bias sehingga probabilitas aktivasi meningkat jika dua pengguna berada dalam komunitas yang sama (faktor α) atau memiliki sentimen yang sama (faktor β). Hasil simulasi dianalisis untuk menentukan apakah jaringan menunjukkan pola difusi yang terisolasi secara ideologis. Implementasi bias difusi dapat dilihat pada Gambar III.12.

```

FUNCTION diffusion_ic(G, seeds, p_base, bias_fn):

    active ← set(seeds)

    newly_active ← set(seeds)

    cascade_log ← []

    WHILE newly_active not empty:

        next_active ← empty_set

        FOR each u IN newly_active:

            FOR each neighbor v OF u WHERE v NOT IN active:

                // Bias: higher propagation within same community /
sentiment

                p ← p_base × bias_fn(u, v)

                IF random() < p:

                    next_active.add(v)

                    cascade_log.append((u, v, step))

            active ← active ∪ next_active

            newly_active ← next_active

    RETURN active, cascade_log

FUNCTION bias_fn(u, v):

    b ← 1.0

    IF community[u] == community[v]: b ← b ×  $\alpha$     // homophily boost

    IF sentiment[u] == sentiment[v]: b ← b ×  $\beta$ 

    RETURN b

```

Gambar III.12. *Pseudocode* bias difusi

III.4.7 Perhitungan *Echo Chamber Ratio* (ECR)

Bagian ini adalah tahap inti pengukuran *echo chamber* yang menghitung rasio insulasi struktural dan polarisasi sentimen setiap komunitas. Tujuannya adalah

mengkuantifikasi derajat *echo chamber* berdasarkan dua dimensi, yakni sebagai berikut.

- (1) *Structural insularity*, yaitu proporsi *edge* internal terhadap total *edge* komunitas yang menunjukkan seberapa terisolasi komunitas secara struktural.
- (2) *Sentiment polarization*, yaitu selisih antara fraksi sentimen positif dan negatif dalam komunitas yang menunjukkan seberapa homogen opini di dalam komunitas tersebut.

Kombinasi kedua metrik ini memberikan ukuran komprehensif tentang apakah suatu komunitas berperilaku sebagai *echo chamber*. Implementasi perhitungan ECR dapat dilihat pada Gambar III.13.

```

FUNCTION compute_ECR(G, communities, leaning):

    // leaning : user → lean_scalar ∈ [-1, +1]

    // Agreement kernel  $a(u,v) = 1 - |\text{leaning}[u] - \text{leaning}[v]| / 2 \in [0, 1]$ .

    intra_vals ← [ ]
    inter_vals ← [ ]

    FOR each edge (u, v) IN G.edges:

        IF u ∉ leaning OR v ∉ leaning: CONTINUE

        a ← 1 - |leaning[u] - leaning[v]| / 2

        IF communities[u] == communities[v]:

            intra_vals.append(a)

        ELSE:

            inter_vals.append(a)

    intra ← mean(intra_vals)
    inter ← mean(inter_vals)

    ratio ← intra / inter                                // ECR 2.0

    RETURN {intra, inter, ratio}

FUNCTION estimate_threshold(G, leaning, communities, n_samples=100):

    null_ratios ← [ ]

```

```

FOR i IN 1..n_samples:

    G_rand ← directed_edge_swap(G)                // preserve degree
sequence

    r      ← compute_ECR(G_rand, communities, leaning).ratio

    IF r is finite AND r > 0:

        null_ratios.append(r)

     $\tau$  ← mean(null_ratios) + std(null_ratios)

RETURN  $\tau$ 

FUNCTION classify(ratio,  $\tau$ ):

    IF ratio ≥  $\tau$ : RETURN "Fenomena Echo Chamber"

    ELSE          : RETURN "Fenomena Non-Echo Chamber"

```

Gambar III.13. *Pseudocode* perhitungan ECR

III.4.8 Pipeline Utama

Bagian ini merangkai seluruh tahap menjadi satu alur kerja *end-to-end*. Tujuannya adalah menjalankan keseluruhan proses secara berurutan, dari praproses teks, klasifikasi sentimen, pembangunan graf, deteksi komunitas, pengukuran homofili, simulasi difusi, hingga penghitungan ECR dan mengemas seluruh hasilnya dalam satu objek keluaran. Dengan demikian, pengguna cukup menyediakan data mentah CSV dan seluruh analisis *echo chamber* akan dihasilkan secara otomatis. Implementasi *pipeline* utama dapat dilihat pada Gambar III.14.

```

FUNCTION ecr2_pipeline(raw_csv):

    tweets ← preprocess(raw_csv)

    tweets ← classify_sentiment(tweets, finetuned_model)

    G      ← build_graph(tweets)

    leaning ← estimate_user_leaning(tweets)        // [-1, +1] per user

    // Multi-algorithm community detection + MLCC consensus

     $\pi_{leiden}$  ← leiden_communities(G, resolution= $\rho$ )

     $\pi_{infomap}$  ← infomap_communities(G)

```

```

 $\pi$ _consensus  $\leftarrow$  mlcc_consensus(G, [ $\pi$ _leiden,  $\pi$ _infomap], L=3,
similarity="cosine")

partitions  $\leftarrow$  {Leiden:  $\pi$ _leiden, Infomap:  $\pi$ _infomap, Consensus:
 $\pi$ _consensus}

h_sent  $\leftarrow$  homophily(G, sentiment)
h_comm  $\leftarrow$  homophily(G, community)
cascades  $\leftarrow$  diffusion_ic(G, seeds, p_base=0.05, bias_fn)

results  $\leftarrow$  {}
FOR each (label,  $\pi$ ) IN partitions:
    ecr  $\leftarrow$  compute_ECR(G,  $\pi$ , leaning)
     $\tau$   $\leftarrow$  estimate_threshold(G, leaning,  $\pi$ , n_samples=100)
    results[label]  $\leftarrow$  {ecr: ecr, threshold:  $\tau$ ,
                        classification: classify(ecr.ratio,  $\tau$ )}

RETURN {graph: G, partitions: partitions,
        homophily: (h_sent, h_comm), diffusion: cascades,
        results: results}

```

Gambar III.14. *Pseudocode pipeline utama*

BAB IV

EKSPERIMEN DAN PENGUJIAN

IV.1 Eksperimen Praproses

Eksperimen praproses teks dilakukan untuk membersihkan data mentah dari ± 700.000 data *tweet* pada ketiga topik agar siap diproses oleh model klasifikasi sentimen. Tujuan eksperimen ini adalah memastikan bahwa konten yang masuk ke *pipeline* ECR bebas dari elemen non-semantik seperti URL, *mention*, emoji, tanda baca, dan slang yang dapat menurunkan kualitas analisis.

Hasil eksperimen menunjukkan bahwa setelah seluruh delapan langkah praproses diterapkan, jumlah data efektif yang digunakan dalam *pipeline* berkurang menjadi ± 600.000 data dengan distribusi sebagai berikut: 641.138 data pada topik *Indonesia Vaccination*, 600.270 data pada topik Indonesia Gelap, dan 515.135 data pada topik Boikot Produk Israel. Penurunan jumlah data terjadi karena tiga faktor utama, yakni sebagai berikut.

- (1) Penyaringan data berdasarkan ambang *sentiment_confidence_level* $\geq 0,2$ yang menghapus data dengan keyakinan model sangat rendah.
- (2) Penghapusan duplikat teks setelah praproses, terutama pada konten retweet yang memiliki teks identik.
- (3) Penyaringan bahasa Indonesia dengan modul *langdetect* yang menghapus konten berbahasa asing.

Tabel IV.1 menunjukkan ringkasan jumlah data per tahap praproses. Praproses berhasil mengurangi panjang rata-rata teks dari 124 karakter menjadi 87 karakter sehingga lebih efisien untuk diproses oleh model *transformer*. Selain itu, praproses berhasil mengonversi *slang* seperti "yg" $\rightarrow$ "yang", "krn" $\rightarrow$ "karena", "ga" $\rightarrow$ "tidak", "bgt" $\rightarrow$ "banget" sehingga konsistensi penulisan meningkat secara signifikan.

Tabel IV.1. Jumlah data mentah dan praproses

Topik	Data Mentah	Data Setelah Praproses	Reduksi (%)
<i>Indonesia Vaccination</i>	700.000	641.138	~8,41
Indonesia Gelap	700.000	600.270	~14,25
Boikot Produk Israel	700.000	515.135	~26,41
Ijazah Jokowi	89.741	89.741	0
Korupsi Haji	10.211	10.211	0
Keracunan MBG	147.804	147.804	0
Total	2.347.756	2.004.299	~14,63

IV.2 Eksperimen Klasifikasi Sentimen

Eksperimen klasifikasi sentimen dilakukan untuk memvalidasi kualitas label sentimen dari IndSight API serta memilih model terbaik untuk *pipeline* ECR. Diambil sampel sebanyak 10.000 data acak per topik (total 30.000 data) untuk membandingkan empat model klasifikasi, yakni IndoBERT (mdhugol/indonesia-bert-sentiment-classification), GPT 5.4-mini, IndoBERT API (No Limit), dan model fine-tuned XLM-RoBERTa.

IV.2.1 Performa Model *Fine-Tuned* XLM-RoBERTa

Model *fine-tuned* XLM-RoBERTa dilatih dengan proporsi *train: validation: test* = 80: 10: 10 dengan rincian per topik pada Tabel IV.2.

Tabel IV.2. Jumlah data per topik

<i>Dataset</i>	Jumlah Data Latih	Jumlah Data Uji	Jumlah Data Validasi
<i>Indonesia Vaccination</i>	34160	4271	4270

<i>Dataset</i>	Jumlah Data Latih	Jumlah Data Uji	Jumlah Data Validasi
Indonesia Gelap	15.251	1.907	1.906
Boikot Produk Israel	27.771	3.472	3.471
Korupsi Haji	360	45	45
Ijazah Jokowi	7.676	960	960
Keracunan MBG	15.042	1.881	1.880
Total	100.260	12.536	12.532

Hasil evaluasi pada data uji 9.650 data menunjukkan akurasi keseluruhan 90,44% dengan rincian per kelas pada Tabel IV.3.

Tabel IV.3. Evaluasi dari XLM RoBERTa


	precision	recall	f1-score	support
<i>negative</i>	0.9496	0.9236	0.9364	9029
<i>neutral</i>	0.7651	0.8275	0.7951	2354
<i>positive</i>	0.8634	0.9046	0.8835	1153
accuracy			0.9038	12536
macro avg	0.8594	0.8852	0.8717	12536
weighted avg	0.9070	0.9038	0.9050	12536

IV.2.2 Hasil Perbandingan Model


Gambar IV.1, IV.2, dan IV.3 menunjukkan *confusion matrix* untuk model IndoBERT dan GPT 5.4-mini pada ketiga topik. Hasil akurasi kedua model dirangkum pada Tabel IV.4.

Tabel IV.4. Akurasi pada sampel 10K dengan *pseudo ground truth* IndSight


Model	Vaksinasi	Indonesia Gelap	Boikot	Rata-rata
IndoBERT	0,277	0,583	0,613	0,491
GPT 5.4-mini	0,339	0,376	0,566	0,427



Gambar IV.1. *Confusion matrices* dari topik *Indonesia Vaccination*




Gambar IV.2. *Confusion matrices* dari topik *Indonesia Gelap*



Gambar IV.3. *Confusion matrices* dari topik Boikot Produk Israel

Untuk validasi yang lebih ketat, diambil 60 sampel *gold label* per topik (total 180 sampel) yang dipilih dari sel *off-diagonal* matriks konfusi, yaitu sampel di mana model-model tersebut tidak sepakat. Hasil *Macro-F1* dan akurasi pada *gold label* ditunjukkan pada Gambar IV.4.



Gambar IV.4. *Macro-F1* dan akurasi pada *gold label*

GPT 5.4-mini menunjukkan Macro-F1 tertinggi (0,52), namun karena memerlukan biaya berlangganan API, model *fine-tuned* XLM-RoBERTa dipilih sebagai model utama dengan Macro-F1 0,49, yakni memiliki selisih hanya 0,03 dari GPT 5.4-mini. Model *fine-tuned* XLM-RoBERTa juga gratis, dapat dijalankan secara lokal, dan memberikan kontrol penuh terhadap *inference* dengan evaluasi yang ditunjukkan pada Tabel IV.5.

Tabel IV.5. *Macro-F1* pada gold label

Model	Macro-F1 Overall	Macro-F1 Boikot	Macro-F1 Vaksin	Macro-F1 Indo Gelap
Fine-tuned XLM-RoBERTa	0,49	0,38	0,45	0,56
IndoBERT API (No Limit)	0,45	0,38	0,39	0,53
RoBERTa API (cached)	0,41	0,43	0,21	0,53
GPT 5.4-mini	0,52	0,38	0,59	0,47
IndoBERT	0,31	0,22	0,39	0,29

Contoh teks serta sentimen dari tiap topik yang ditentukan oleh setiap model, yakni ditunjukkan pada Tabel IV.5.

Tabel IV.6. Contoh sentimen dari tiap model serta *gold label*


Dataset	Teks	Model dan Sentimen
Indonesia Vaccination	Kelemahan Indonesia blm bisa menangani pandemi covid adalah seolah2 yg berjuang sendiri Tdk adanya kesatuan dr yg merasa elit, pemimpin negeri ini yg terjun bersama mengatasi covid Yg ada hanya	Fine-tuned_XLM-RoBERTa: <i>negative</i>
		IndoBERT_API_NoLimit: <i>neutral</i>
		RoBERTa_API_Cached: <i>positive</i>
		GPT_5.4-mini: <i>neutral</i>
		IndoBERT: <i>neutral</i>

Dataset	Teks	Model dan Sentimen
	berpikir, ada duitnya gk, aku dpt apa, mknya sulit diatasi	GOLD_LABEL: <i>negative</i>
Indonesia Gelap	Duka mendalam atas kepergian Affan Kurniawan Meski tak saling kenal, kami turut kehilangan. Ku coba semampuku menyuarakan kesadaran tentang bobroknya negeri dan hilangnya kemanusiaan. Semoga kau damai di sana, dalam keabadian.	Fine-tuned_XLM-RoBERTa: <i>negative</i>
		IndoBERT_API_NoLimit: <i>neutral</i>
		RoBERTa_API_Cached: <i>negative</i>
		GPT_5.4-mini: <i>negative</i>
		IndoBERT: <i>neutral</i>
		GOLD_LABEL: <i>negative</i>
Boikot Produk Israel	Pak cukup 1 periode saja lah yaa pak sudah cukup jdi antek2 asing	Fine-tuned_XLM-RoBERTa: <i>negative</i>
		IndoBERT_API_NoLimit: <i>neutral</i>
		RoBERTa_API_Cached: <i>negative</i>
		GPT_5.4-mini: <i>negative</i>
		IndoBERT: <i>neutral</i>
		GOLD_LABEL: <i>negative</i>
Korupsi Haji	Tapi kata pembelanya... Ada UPAYA PEMBUNUHAN KARAKTER asu tenan.. LHA EMANG MEREKA BUSUK KELAKUANNYA (KORUPSI HAJI)	Fine-tuned_XLM-RoBERTa: <i>negative</i>
		IndoBERT_API_NoLimit: <i>neutral</i>
		RoBERTa_API_Cached: <i>neutral</i>
		GPT_5.4-mini: <i>negative</i>
		IndoBERT: <i>neutral</i>
		GOLD_LABEL: <i>negative</i>
		Fine-tuned_XLM-RoBERTa: <i>positive</i>

Dataset	Teks	Model dan Sentimen
Ijazah Jokowi	terseru yang mengungkap kebenaran lebih gamblang dan lebih jernih, tentang Ijazah Jokowi. Sehingga kita memiliki keyakinan tentang Ijazah Jokowi. Semoga tayangan di Youtubanya tidak ada yang minta untuk ditakedown. Yang belum nonton, kayaknya wajib nonton, karena	IndoBERT_API_NoLimit: <i>neutral</i>
		RoBERTa_API_Cached: <i>positive</i>
		GPT_5.4-mini: <i>neutral</i>
		IndoBERT: <i>neutral</i>
		GOLD_LABEL: <i>neutral</i>
Keracunan MBG	mulai dr keracunan MBG (tercatat 8.649 org), PT Gag Nikel Raja Empat jalan lagi, monopoli BBM, 10 org meninggal dan 900++ org tersangka demonstrasi kmaren (2 org masih hilang juga), polisi inkompeten, pidato Prabs di PBB, pejabat2 stay di hotel AMAN NY, 38M alat tulis kantor dan	Fine-tuned_XLM-RoBERTa: <i>negative</i>
		IndoBERT_API_NoLimit: <i>neutral</i>
		RoBERTa_API_Cached: <i>neutral</i>
		GPT_5.4-mini: <i>neutral</i>
		IndoBERT: <i>neutral</i>
		GOLD_LABEL: <i>neutral</i>


IV.2.3 Distribusi *Confidence Bucket*

Untuk memastikan kelayakan *dataset*, dilakukan pengecekan distribusi *sentiment_confidence_level* di atas dan di bawah 0,8. Hasil ditunjukkan pada Gambar IV.1, IV.2, dan IV.3.




Gambar IV.5. *Confidence bucket* dari *Indonesia Vaccination*

Dapat dilihat dari Gambar IV.5 bahwa ada 595,705 (92,9%) pada rentang [0, 0.8) dan 45,433 (7,1%) pada rentang [0.8, 1] untuk *full dataset*. Sedangkan setelah dilakukan pengecekan terhadap *gold label*, terdapat 56 (93,3%) pada rentang [0, 0.8) dan 4 (6,7%) pada rentang [0.8, 1].



Gambar IV.6. *Confidence bucket* dari Indonesia Gelap

Dapat dilihat dari Gambar IV.6 bahwa ada 458,899 (76,4%) pada rentang [0, 0.8) dan 141,371 (23,6%) pada rentang [0.8, 1] untuk *full dataset*. Sedangkan setelah dilakukan pengecekan terhadap *gold label*, terdapat 43 (71,7%) pada rentang [0, 0.8) dan 17 (28,3%) pada rentang [0.8, 1].



Gambar IV.7. *Confidence bucket* dari Boikot Produk Israel

Dapat dilihat dari Gambar IV.7 bahwa ada 370,362 (71,9%) pada rentang [0, 0.8) dan 144,773 (28,1%) pada rentang [0.8, 1] untuk *full dataset*. Sedangkan setelah

dilakukan pengecekan terhadap *gold label*, terdapat 53 (88,3%) pada rentang [0, 0.8) dan 7 (11,7%) pada rentang [0.8, 1].

IV.3 Eksperimen Kalibrasi Probabilistik

Eksperimen kalibrasi probabilistik dilakukan untuk mengevaluasi efektivitas kalibrasi dalam meningkatkan keandalan skor kepercayaan model sentimen *fine-tuned* XLM-RoBERTa. Tiga metode kalibrasi dibandingkan: *isotonic regression*, *sigmoid (Platt) scaling*, dan *temperature scaling*. Evaluasi menggunakan tiga metrik: *Expected Calibration Error* (ECE), *log loss*, dan *Brier score*. Hasil kalibrasi probabilistik terhadap ketiga topik, yakni ditunjukkan pada Tabel IV.3, Tabel IV.4, dan Tabel IV.6.

Tabel IV.7. Hasil kalibrasi probabilistik pada topik *Indonesia vaccination*

Metode	ECE	<i>Log Loss</i>	<i>Brier Score</i>
<i>Uncalibrated</i>	0,2768	0,33	0,1247
<i>Isotonic regression</i>	$\approx 0,0000$	$\approx 0,0000$	$\approx 0,0000$
<i>Sigmoid scaling</i>	0,0004	0,0004	$\approx 0,0000$
<i>Temperature scaling</i>	0,2768	0,33	0,1247

Tabel IV.8. Hasil kalibrasi probabilistik pada topik Indonesia gelap


Metode	ECE	<i>Log Loss</i>	<i>Brier Score</i>
<i>Uncalibrated</i>	0,2413	0,2999	0,1216
<i>Isotonic regression</i>	$\approx 0,0000$	0,0001	$\approx 0,0000$
<i>Sigmoid scaling</i>	0,0021	0,0023	0,0004
<i>Temperature scaling</i>	0,2413	0,2999	0,1216

Tabel IV.9. Hasil kalibrasi probabilistik pada topik boikot produk Israel


Metode	ECE	Log Loss	Brier Score
<i>Uncalibrated</i>	0,2120	0,2493	0,0853
<i>Isotonic regression</i>	$\approx 0,0000$	0,0008	0,0004
<i>Sigmoid scaling</i>	0,0006	0,0014	0,0005
<i>Temperature scaling</i>	0,2120	0,2493	0,0853

Hasil eksperimen menunjukkan bahwa *isotonic regression* secara konsisten menghasilkan kalibrasi terbaik pada ketiga topik, dengan ECE mendekati nol. Hal ini mengindikasikan bahwa skor kepercayaan yang dikalibrasi dengan *isotonic regression* sangat akurat dalam merepresentasikan probabilitas sesungguhnya. *Sigmoid scaling* juga menunjukkan perbaikan signifikan meskipun tidak sebaik *isotonic regression*. Sebaliknya, *temperature scaling* tidak memberikan perbaikan yang berarti sehingga nilai ECE tetap hampir identik dengan model tanpa kalibrasi. Ini disebabkan oleh *temperature scaling* yang hanya melakukan transformasi linier pada *logit*, sehingga tidak mampu menangani *miscalibration* non-linier yang terdapat pada model *fine-tuned* XLM-RoBERTa.


Berdasarkan hasil ini, *isotonic regression* dipilih sebagai metode kalibrasi untuk seluruh eksperimen selanjutnya. Kalibrasi ini penting karena memengaruhi kualitas estimasi *user leaning* yang menjadi dasar penghitungan ECR. Skor kepercayaan yang tidak terkalibrasi dapat menyebabkan estimasi *leaning* yang *overconfident* atau *underconfident*, yang pada akhirnya berdampak pada akurasi pengukuran *echo chamber*. Selanjutnya, dicek pengaruh *isotonic regression* terhadap perubahan sentimen suatu teks. Hasil perubahan sentimen tersebut dapat dilihat pada Gambar IV.4, Gambar IV.5, dan Gambar IV.6.



Gambar IV.8. Analisis kalibrasi probabilistik pada topik *Indonesia Vaccination*



Gambar IV.9. Analisis kalibrasi probabilistik pada topik Indonesia Gelap



Gambar IV.10. Analisis kalibrasi probabilistik pada topik boikot produk Israel


Dari hasil analisis kalibrasi per tingkat *confidence*, semua ECE bernilai 0 (nol). Namun, tidak ada pengaruh pada perubahan label sentimen. Hal ini bisa terjadi

karena tidak ada perubahan ECE yang signifikan, maka metode kalibrasi probabilistik tidak digunakan dalam *pipeline* ECR.


IV.4 Eksperimen Estimasi *User Leaning*

Eksperimen estimasi user leaning dilakukan untuk memetakan setiap pengguna ke dalam rentang $[-1, +1]$. Hasil distribusi *user leaning* pada ketiga topik menunjukkan pola *bimodal* dengan dominasi pada ± 1 , yang berarti pengguna cenderung berada di kutub pro atau kutub kontra dengan keyakinan tinggi.


Untuk topik *Indonesia Vaccination*, mayoritas pengguna berada di sisi pro (mendukung vaksinasi), diikuti kontra, dan terakhir netral. Tingkat *confidence* terhadap penempatan pengguna ke tim juga sangat tinggi (mendekati 100%), menunjukkan bahwa mayoritas pengguna konsisten dalam orientasinya. Untuk topik Indonesia Gelap, pola serupa ditemukan namun dengan dominasi yang lebih kuat ke sisi pro (yang berarti setuju Indonesia sedang gelap). Untuk topik Boikot Produk Israel, dominasi pro-boikot sangat kuat dengan rerata *lean_scalar* 0,983 pada komunitas terbesar. Dapat dilihat hasilnya pada Gambar IV.11, Gambar IV.12, Gambar IV.13, Gambar IV.14, Gambar IV.15, Gambar IV.16.




Gambar IV.11. *User leaning* dari topik *Indonesia Vaccination*




Gambar IV.12. *User leaning* dari topik Indonesia Gelap




Gambar IV.13. *User leaning* dari topik Boikot Produk Israel



Gambar IV.14. *User leaning* dari topik Korupsi Haji



Gambar IV.15. *User leaning* dari topik Ijazah Jokowi



Gambar IV.16. *User leaning* dari topik Keracunan MBG

IV.5 Eksperimen Deteksi Komunitas Algoritma Leiden dan Louvain


Perbandingan antara algoritma Leiden dan Louvain menunjukkan perbedaan yang sangat signifikan dalam hal jumlah komunitas yang dihasilkan, yakni ditunjukkan pada Tabel IV.9.

Tabel IV.10. Perbandingan jumlah komunitas Leiden vs Louvain


<i>Dataset</i>	Leiden	Infomap	MLCC	Louvain
<i>Indonesia Vaccination</i>	9.700	9.716	9.786	478.200

<i>Dataset</i>	Leiden	Infomap	MLCC	Louvain
Indonesia Gelap	471	4.720	496	442.169
Boikot Produk Israel	2.138	3.663	2.208	364.610
Korupsi Haji	146	103	144	4.674
Ijazah Jokowi	181	64	175	17.687
Keracunan MBG	520	694	522	35.784
Total	13.156	18.960	13.331	1.343.124
Rasio	1 : 1,44 : 1,01 : 102,09			


Algoritma Louvain menghasilkan jumlah komunitas yang jauh lebih banyak dibandingkan ketiga algoritma lainnya. Perbedaan ini disebabkan oleh kelemahan fundamental Louvain yang tidak menjamin konektivitas internal komunitas. Louvain dapat menggabungkan *node-node* yang tidak saling terhubung langsung ke dalam satu komunitas, kemudian memecahnya menjadi banyak sub-komunitas kecil yang terfragmentasi.




Gambar IV.17. Komunitas pro vs kontra topik *Indonesia Vaccination*




Gambar IV.18. Komunitas pro vs kontra topik *Indonesia Gelap*




Gambar IV.19. Komunitas pro vs kontra topik *Boikot Produk Israel*



Gambar IV.20. Komunitas pro vs kontra topik Korupsi Haji



Gambar IV.21. Komunitas pro vs kontra topik Ijzah Jokowi



Gambar IV.22. Komunitas pro vs kontra topik Keracunan MBG

Berdasarkan Gambar IV.17, terdapat komunitas terbanyak adalah komunitas netral yang diikuti dengan komunitas kontra dan kemudian komunitas pro, ini sangat terpolarisasi. Terdapat kontradiksi, yakni dengan *username*: jokowi. Kontradiksinya adalah Presiden Joko Widodo seharusnya dalam tim pro terhadap perkembangan vaksinasi di Indonesia. Namun, dikarenakan pada *dataset* ini tertulis bahwa Jokowi memiliki sentimen negatif dengan tingkat kepercayaan sentimen lebih dari 80%, maka model sentimen yang dilatih dari *dataset* tersebut menghasilkan sentimen negatif juga. Sentimen negatif ini termasuk dalam tim kontra pada topik *Indonesia Vaccination*.

Berdasarkan Gambar IV.18 dan Gambar IV.19, komunitas tim pro sangat dominan. Tingkat polarisasinya cukup rendah perbandingan antara ketiga jenis komunitas. Sentimen positif termasuk dalam tim kontra pada topik Indonesia Gelap dan Boikot Produk Israel karena topiknya tersebut mengandung sentimen negatif sehingga yang searah dengan sentimen negatif adalah tim pro. Sebaliknya, termasuk tim kontra.

Berdasarkan Gambar IV.20, Gambar IV.21, Gambar IV.22, komunitas tim kontra sangat dominan. Tingkat polarisasinya cukup rendah perbandingan antara ketiga jenis komunitas. Sentimen negatif termasuk dalam tim kontra pada topik Korupsi Haji, Ijazah Jokowi, dan Keracunan MBG karena topiknya tersebut mengandung

sentimen positif sehingga yang searah dengan sentimen positif adalah tim pro. Sebaliknya, termasuk tim kontra.

IV.6 Eksperimen Pengukuran *Echo chamber*

Pengujian pengukuran *echo chamber* dilakukan menggunakan metrik *Echo Chamber Ratio* (ECR) yang didefinisikan sebagai rasio antara *intra-community agreement* dan *inter-community agreement*. Pengujian ini melibatkan beberapa komponen, yakni deteksi komunitas, perhitungan ECR, analisis *homophily*, analisis *diffusion bias*, dan analisis *bridge users*.

Tabel IV.11. Hasil pengukuran ECR pada ketiga *dataset*

Metrik	Indonesia Vaccination	Indonesia Gelap	Boikot Produk Israel	Korupsi Haji	Ijazah Jokowi	Keracunan MBG
Intra-community Agreement	0,7663	0,8131	0,8535	0,8720	0,8384	0,8764
Inter-community Agreement	0,7776	0,8410	0,8807	0,8489	0,8634	0,8928
ECR (Agreement)	0,9855	0,9667	0,9691	1,0272	0,9711	0,9816
Homophily (Korelasi Pearson)	0,0838	0,5101	0,3928	0,0235	0,1635	0,1584
Threshold	0,9990	1,0000	0,9896	1,0000	0,9680	0,9670
Klasifikasi	Non-Echo Chamber	Non-Echo Chamber	Non-Echo Chamber	Echo Chamber	Echo Chamber	Echo Chamber

Berdasarkan Tabel IV.10, Ketiga *dataset* yang diklasifikasikan *echo chamber* (Korupsi Haji, Ijazah Jokowi, dan Keracunan MBG) memiliki karakteristik unik yang konsisten: *homophily* rendah (0,02 hingga 0,16) namun $ECR > Threshold$. Pola ini menyimpang dari intuisi klasik *echo chamber* yang membayangkan dua kubu ideologis terpisah dengan jelas. Sebaliknya, ketiga *dataset* ini menampilkan *echo chamber* konsensual, yaitu kondisi di mana mayoritas pengguna menyepakati

satu sikap dominan terhadap suatu isu (mengecam korupsi haji, mempertanyakan validitas ijazah, dan mengecam keracunan MBG), dan komunitas-komunitas yang terbentuk menjadi gema berulang dari sikap konsensus mayoritas tersebut walaupun pengguna tetap saling berinteraksi tanpa filter ideologis yang ketat. Fenomena ini berbeda secara konseptual dari *echo chamber* polarisasi (Sunstein, 2017) dan mendekati konsep *resonance chamber* atau *agreement reinforcement loop*.

Ketiga dataset *non-echo chamber* (*Indonesia Vaccination*, *Indonesia Gelap*, dan *Boikot Produk Israel*) menampilkan pola yang lebih bervariasi dan secara teoretis lebih informatif. *Indonesia Vaccination* menampilkan heterogenitas opini yang menyeluruh tanpa segregasi struktural maupun konsensus internal, diskusi yang terbuka di seluruh jaringan. *Indonesia Gelap* menampilkan segregasi struktural yang sangat kuat (*homophily* 0,51) tetapi tanpa konsensus internal yang cukup tajam untuk melampaui *threshold*, kasus polarisasi struktural tanpa polarisasi semantik, yang menggambarkan bahwa walaupun pengguna terkelompok berdasarkan *stance*, intensitas opini di dalam kelompok masih bervariasi. *Boikot Produk Israel* menampilkan konsensus opini global yang merata di seluruh jaringan sehingga tidak terlokalisasi menjadi *echo chamber* komunitas-spesifik, semua pengguna secara umum menyepakati basis moral yang sama walaupun komunitasnya berbeda.

Berdasarkan hasil dari keenam *dataset* ini menunjukkan bahwa *echo chamber* tidak harus dimanifestasikan dalam bentuk dua kubu yang terpisah. Tugas akhir ini berhasil mendokumentasikan tipologi baru bahwa *echo chamber* konsensual (Korupsi, MBG) dan polarisasi struktural *non-echo* (*Indonesia Gelap*), yang sebelumnya tidak ditangkap oleh kerangka *echo chamber* klasik Sunstein (2017) atau Cinelli dkk. (2021) yang hanya berfokus pada konflik dua kubu yang tersegregasi.

Tabel IV.12. Perbandingan ECR antara Leiden dan Louvain

<i>Dataset</i>	ECR (Agreement)	ECR (Louvain)	Threshold (ECR Agreement)	Threshold (ECR Louvain)
<i>Indonesia Vaccination</i>	0,9855	1.0139	0,9990	1.0000
Indonesia Gelap	0,9667	1.0876	1,0000	1.0000
Boikot Produk Israel	0,9691	1.0803	0,9896	1.0000
Korupsi Haji	1,0272	1.0016	1,0000	1.0000
Ijazah Jokowi	0,9711	1.0073	0,9680	1.0000
Keracunan MBG	0,9816	1.0218	0,9670	1.0000

Berdasarkan Tabel IV.11, dengan algoritma Louvain, ketiga *dataset* menghasilkan ECR di atas 1,0, yang berarti *within-community agreement* lebih tinggi dari *between-community agreement*. Namun, hasil ini menyesatkan karena komunitas yang dihasilkan Louvain terlalu terfragmentasi (*badly-connected*), sehingga perbandingan *agreement* antar komunitas tidak bermakna. Algoritma Leiden dipilih sebagai algoritma utama karena menghasilkan komunitas yang *well-connected* dan secara teoritis lebih valid untuk analisis *echo chamber*.

IV.6.1 Analisis *Homophily*

Homophily mengukur korelasi *Pearson* antara sentimen pengguna dan sentimen rata-rata tetangganya dalam jaringan. Hasil *homophily* ditunjukkan pada Tabel IV.12.

Tabel IV.13. Nilai *homophily* per *dataset*

<i>Dataset</i>	Korelasi Pearson (<i>Homophily</i>)	Interpretasi
<i>Indonesia Vaccination</i>	0,0838	Homofili sangat lemah (mendekati nol). Pengguna pro-vaksin dan kontra-vaksin tidak menunjukkan kecenderungan kuat untuk hanya berinteraksi dengan pengguna <i>ber-leaning</i> serupa. Komunitas yang terbentuk pada graf interaksi tidak terpolarisasi berdasarkan <i>stance</i> vaksinasi, melainkan kemungkinan terbentuk berdasarkan klaster tematik (efek sampling, distribusi, klarifikasi otoritas) yang masing-masing menampung berbagai sudut pandang. Diskusi berlangsung relatif terbuka tanpa segregasi ideologis yang tajam.
Indonesia Gelap	0,5101	Homofili tertinggi di antara enam <i>dataset</i> , masuk kategori moderat-kuat. Pengguna pro-pemerintah berinteraksi terutama dengan sesama pro-pemerintah, dan pengguna kontra-pemerintah dengan sesama kontra-pemerintah. Jaringan interaksi menunjukkan tingkat segregasi struktural paling kuat, terbentuk dua kubu yang saling terisolasi dalam berinteraksi. Walaupun ECR observasi belum melampaui

<i>Dataset</i>	Korelasi Pearson (<i>Homophily</i>)	Interpretasi
		<i>threshold (non-echo chamber)</i> , pola ini menandakan polarisasi struktural sosial yang nyata bahwa gerakan protes berhasil membelah jaringan diskusi menjadi dua kubu ideologis yang jelas.
Boikot Produk Israel	0,3928	Homofili moderat, lebih lemah dari Indonesia Gelap namun jauh lebih kuat dari <i>Indonesia Vaccination</i> . Pengguna pendukung boikot cenderung berinteraksi dengan sesama pendukung boikot, namun masih terdapat <i>cross-interaction</i> yang signifikan dengan pengguna lain. Segregasi ada tetapi tidak sekaku Indonesia Gelap, kemungkinan karena topik boikot menyentuh dimensi keagamaan, ekonomi, dan kemanusiaan yang membuat banyak pengguna lintas- <i>stance</i> sepakat secara moral walaupun berbeda taktik aksi.
Korupsi Haji	0,0235	Homofili praktis nol (terendah di antara enam <i>dataset</i>). Pengguna tidak menyaring lawan interaksinya berdasarkan <i>stance</i> , karena memang tidak ada dua kubu yang

<i>Dataset</i>	Korelasi Pearson (<i>Homophily</i>)	Interpretasi
		nyata pada topik ini, hampir seluruh pengguna sepakat mengecam korupsi haji. Tidak ada pembela korupsi yang aktif berinteraksi, sehingga jaringan menjadi homogen secara <i>stance</i> . Inilah yang menyebabkan paradoks Korupsi Haji bahwa homofili nyaris nol namun $ECR > 1$ (<i>Echo Chamber</i>). Komunitas terbentuk secara spontan tanpa filter ideologis, namun setiap komunitas tetap menggemakan konsensus negatif mayoritas, sebuah <i>echo chamber</i> konsensual yang berbeda dari klasifikasi klasik.
Ijazah Jokowi	0,1635	Homofili lemah. Pengguna yang mempertanyakan validitas ijazah dan pengguna yang membela tidak sepenuhnya tersegregasi dalam jaringan interaksi. Hal ini wajar karena topik ijazah Jokowi memicu polarisasi yang lebih kompleks daripada sekadar pro-kontra Jokowi: ada dimensi forensik dokumen, kepercayaan terhadap institusi pendidikan, dan partai politik yang membuat pengguna ber- <i>leaning</i> serupa pun bisa berseberangan dalam

<i>Dataset</i>	Korelasi Pearson (<i>Homophily</i>)	Interpretasi
		sub-isu. Klasifikasi <i>echo chamber</i> pada <i>dataset</i> ini tetap muncul karena ECR melampaui <i>threshold</i> , namun bukan didorong oleh homofili struktural yang kuat.
Keracunan MBG	0,1584	Homofili lemah, sangat dekat dengan Ijazah Jokowi (0,1635). Pengguna yang mengecam program Makan Bergizi Gratis dan pengguna yang membela program belum tersegregasi secara tajam, interaksi lintas <i>stance</i> masih terjadi dalam volume yang signifikan. Pola homofili lemah dengan $ECR > Threshold$ ini mengulangi tipologi <i>echo chamber</i> konsensual seperti Korupsi Haji: konsensus negatif mayoritas (terhadap kasus keracunan, bukan terhadap konsep program MBG itu sendiri) menggema di dalam komunitas-komunitas yang terbentuk tanpa filter ideologis yang ketat.

Tiga dataset dengan homofili tertinggi (Indonesia Gelap 0,5101, Boikot 0,3928, dan Ijazah 0,1635) menampilkan korelasi dengan tingkat konflik dari dua kubu yang nyata pada topik tersebut. Indonesia Gelap memiliki dua kubu yang jelas (pro vs kontra pemerintah), Boikot Produk Israel memiliki dua kubu (pendukung vs penentang boikot), Ijazah Jokowi memiliki kubu yang kabur (pemeriksaan vs

pembela). Sebaliknya, tiga *dataset* dengan homofili rendah (Korupsi 0,0235, Vaksin 0,0838, MBG 0,1584) menggambarkan topik yang tidak punya kubu pembela yang terartikulasi, entah karena ada konsensus mayoritas yang sangat kuat (korupsi, MBG) atau karena diskusinya terlalu beragam untuk membentuk kubu (vaksinasi).

Pola ini secara empiris menggambarkan bahwa homofili bukanlah ukuran tunggal yang cukup untuk menyimpulkan *echo chamber* bahwa *dataset* dengan homofili tertinggi (Indonesia Gelap) ternyata bukan *echo chamber*, sedangkan *dataset* dengan homofili terendah (Korupsi Haji) cenderung menjadi *echo chamber*. Inilah salah satu temuan penting tugas akhir ini yang mengoreksi asumsi sederhana di literatur sebelumnya tentang relasi homofili dan *echo chamber*.

IV.6.2 Analisis *Diffusion Bias*

Diffusion bias diukur menggunakan simulasi *Independent Cascade* (IC) untuk menganalisis apakah informasi cenderung menyebar secara bias di dalam jaringan. Setiap pengguna dijadikan *seed*, lalu sentimen rata-rata pengguna yang terpengaruh (*influenced users*) dibandingkan dengan sentimen *seed*. Hasil analisis *diffusion bias* ditunjukkan pada Gambar IV.20, Gambar IV.21, Gambar IV.22, dan Tabel IV.13.

Tabel IV.14. Hasil analisis *diffusion bias* pada ketiga *dataset*

Metrik	<i>Indonesia Vaccination</i>	Indonesia Gelap	Boikot Produk Israel	Korupsi Haji	Ijazah Jokowi	Keracunan MBG
<i>Slope regresi</i>	0,0512	0,2944	0,2434	0,0242	0,0508	0,072
<i>R-squared</i>	0,0058	0,2174	0,1248	0,0002	0,0098	0,0086
<i>Bias ratio</i>	0,7588	0,7924	0,9675	0,9952	0,9771	0,9816
<i>t-test statistic</i>	21,79	186,21	134,11	0,6	10,38	17,82

Metrik	<i>Indonesia Vaccination</i>	Indonesia Gelap	Boikot Produk Israel	Korupsi Haji	Ijazah Jokowi	Keracunan MBG
<i>p-value (t-test)</i>	< 0,001	< 0,001	< 0,001	0,5502	< 0,001	< 0,001
<i>Cohen's d</i>	0,2045	1,0528	1,8468	-0,0311	0,3934	0,7474

Slope regresi mengukur seberapa kuat *seed leaning* memprediksi *influence_mean*. *Slope* positif berarti pengguna pro cenderung menyebar ke pengguna pro. Indonesia Gelap dan Boikot Produk Israel memiliki *slope* tertinggi (+0,2944 dan +0,2434), yang berarti bias difusi yang sangat kuat dan informasi memang menyebar sesuai jalur ideologis. Sebaliknya, Korupsi Haji memiliki *slope* hampir nol (+0,0242) karena hampir semua *seed* berada di sisi kontra (homofili 0,0235); tidak ada keragaman *leaning* yang cukup untuk membentuk regresi yang bermakna.

R-squared menggambarkan proporsi varians yang dijelaskan oleh model regresi linier. Indonesia Gelap memiliki R^2 0,2174 (22% varians dijelaskan) yang menandakan hubungan deterministik kuat antara *seed leaning* dan *influence*, ini konsisten dengan homofili tertinggi 0,5101. Boikot Produk Israel di posisi kedua ($R^2 = 0,1248$). Sisanya semua memiliki $R^2 < 0,01$, menandakan bahwa untuk *dataset-dataset* tersebut, *seed leaning* bukan prediktor utama *influence*, ada faktor lain (popularitas *seed*, struktur lokal komunitas) yang lebih dominan.


Bias ratio mengukur proporsi *seed* yang *influence_mean*-nya searah dengan *leaning seed*-nya. Nilai mendekati 1 berarti hampir semua *seed* berhasil menyebar ke pengguna ber-*leaning* sama. Korupsi Haji (0,9952) memimpin di sini karena praktis seluruh pengguna (kontra-korupsi) menyebar ke sesama kontra-korupsi, bukan karena adanya filter ideologis, melainkan karena populasi memang homogen. *Indonesia Vaccination* terendah (0,7588), menandakan ~24% *seed* difusinya melintas batas ideologis.

t-test statistic menguji signifikansi $slope \neq 0$. Semua *dataset* kecuali Korupsi Haji memiliki $t > 10$ (sangat signifikan). Korupsi Haji satu-satunya yang *slope*-nya tidak signifikan ($t = +0,60$, $p = 0,5502$) karena variansi *seed_lean* sangat kecil.


Cohen's d mengukur *effect size* perbedaan rata-rata *influence* antara *seed* pro dan *seed* kontra. Boikot Produk Israel dengan $d = +1,8468$ memiliki *effect size* terbesar (kategori "*very large effect*" pada konvensi $Cohen \geq 0,8$), menandakan pengguna pro dan kontra menyebarkan informasi ke audiens yang sangat berbeda intensitas *leaning*-nya. Indonesia Gelap ($d = +1,0528$) juga "*large effect*". Sebaliknya, Korupsi Haji ($d = -0,0311$) dan *Indonesia Vaccination* ($d = +0,2045$) menampilkan *effect size* kecil, tidak ada perbedaan substantif antara difusi *seed* pro vs kontra.

IV.7 Eksperimen Pergeseran Sentimen


Eksperimen pergeseran topik dilakukan untuk menganalisis bagaimana sentimen pengguna berubah dari waktu ke waktu pada setiap topik. Untuk setiap pengguna yang memiliki minimal 10 *tweet*, *tweet* dibagi menjadi dua periode berdasarkan waktu *posting*: paruh awal (*early*) dan paruh akhir (*late*). Sentimen rata-rata dari masing-masing periode dihitung berdasarkan *user leaning scalar*, kemudian dibandingkan untuk menentukan jenis pergeseran sentimen. Hasil analisis pergeseran sentimen pada ketiga *dataset* ditunjukkan pada Gambar IV.23, Gambar IV.24, Gambar IV.25, dan Tabel IV.15.




Gambar IV.23. Distribusi pergeseran sentimen *dataset Indonesia Vaccination*




Gambar IV.24. Distribusi pergeseran sentimen *dataset Indonesia Gelap*




Gambar IV.25. Distribusi pergeseran sentimen *dataset* Boikot Produk Israel



Gambar IV.26. Distribusi pergeseran sentimen *dataset* Korupsi Haji



Gambar IV.27. Distribusi pergeseran sentimen *dataset* Ijazah Jokowi



Gambar IV.28. Distribusi pergeseran sentimen *dataset* Keracunan MBG

Tabel IV.15. Distribusi jenis pergeseran sentimen pada ketiga *dataset*

Jenis Pergeseran	Indonesia Vaccination (n=91.755)	Boikot Produk Israel (n=86.627)	Indonesia Gelap (n=93.375)	Korupsi Haji (n=1.367)	Ijazah Jokowi (n=8.024)	Keracunan MBG (n=20.864)
<i>Moderated</i>	37.128 (40,5%)	37.862 (43,7%)	44.813 (48,0%)	98 (7,2%)	1.114 (13,9%)	5.056 (24,2%)
<i>Polarized</i>	23.954 (26,1%)	34.167 (39,4%)	36.588 (39,2%)	107 (7,8%)	2.492 (31,1%)	10.669 (51,1%)
<i>Stable</i>	5.404 (5,9%)	11.562 (13,3%)	8.813 (9,4%)	1.161 (84,9%)	4.322 (53,9%)	5.010 (24,0%)
<i>Pro to Contra</i>	12.928 (14,1%)	1.782 (2,1%)	1.217 (1,3%)	0 (0,0%)	52 (0,7%)	92 (0,4%)
<i>Contra to Pro</i>	12.341 (13,4%)	1.254 (1,4%)	1.944 (2,1%)	1 (0,1%)	44 (0,6%)	37 (0,2%)

Indonesia Vaccination (n = 91.755 pengguna) adalah satu-satunya *dataset* dengan proporsi Pro ↔ Contra yang signifikan (14,1% + 13,4% = 27,5%), menandakan fluktuasi opini lintas kutub yang nyata dalam diskursus vaksinasi. Mayoritas pengguna mengalami moderation (40,5%) atau polarisasi (26,1%), tetapi seperempat populasi berubah arah ideologis sepenuhnya. Konsisten dengan klasifikasi *non-echo chamber* dan *homophily* yang sangat rendah (0,0838).

Boikot Produk Israel dan Indonesia Gelap menampilkan pola yang sangat mirip: dominasi *Moderated* (~44-48%) dan *Polarized* (~39-40%), dengan *Stable* 9-13% dan Pro ↔ Contra < 3,5%. Artinya pengguna bereaksi terhadap perkembangan isu (berubah intensitasnya) tetapi jarang berbalik kubu. Pengguna pro-Palestina tetap pro-Palestina tetapi intensitasnya naik-turun, pengguna pro/kontra-pemerintah serupa.

Korupsi Haji (n = 1.367) menampilkan profil paling berbeda: 84,9% pengguna *Stable*, pengguna mempertahankan posisi tanpa perubahan signifikan. Hanya 7,2% *Moderated* dan 7,8% *Polarized*, dan praktis nol perubahan kutub (0 + 1 *user*). Pola ini mendukung interpretasi *echo chamber* konsensual, yakni mayoritas pengguna

konsisten kontra-korupsi tanpa fluktuasi. Tidak ada dinamika persuasi karena tidak ada lawan opini yang dapat diperdebatkan.

Ijazah Jokowi ($n = 8.024$) juga didominasi *Stable* (53,9%) dengan sedikit *Polarized* (31,1%). Konsisten dengan margin *echo chamber* yang tipis, yakni pengguna pegang teguh posisi awalnya (entah pemverifikasi atau pembela ijazah) tanpa banyak fluktuasi.

Keracunan MBG ($n = 20.864$) menarik karena *Polarized* mencapai 51,1%, yakni tertinggi di antara enam *dataset*. Mayoritas pengguna semakin tajam intensitas opininya seiring waktu. *Stable* hanya 24,0%, jauh lebih rendah daripada Korupsi/Ijazah. Pola ini menandakan *echo chamber* yang aktif memperkuat opini awal — pengguna yang awalnya sedikit kritis menjadi sangat kritis terhadap kasus keracunan MBG, namun tetap di sisi yang sama. Tidak ada perubahan kutub ($\text{Pro} \leftrightarrow \text{Contra} < 0,5\%$).

IV.8 Uji Hipotesis Pengukuran *Echo Chamber*

IV.8.1 Perumusan Hipotesis

Berdasarkan kerangka ECR yang dikembangkan dalam penelitian ini, hipotesis yang diuji adalah

- (1) H_0 (Hipotesis Nol): Tidak terdapat fenomena *echo chamber* pada diskursus Twitter Indonesia untuk topik tertentu. Nilai ECR observasi tidak berbeda secara signifikan dari distribusi ECR *null model* ($\text{ECR observasi} \leq \text{threshold}$).
- (2) H_1 (Hipotesis Alternatif): Terdapat fenomena *echo chamber* pada diskursus Twitter Indonesia untuk topik tertentu. Nilai ECR observasi lebih besar secara signifikan dari distribusi ECR *null model* ($\text{ECR observasi} > \text{threshold}$).

IV.8.2 Prosedur Pengujian

Pengujian hipotesis dilakukan menggunakan pendekatan *null model* berbasis permutasi. Prosedur pengujian adalah sebagai berikut.

- (1) Untuk setiap *dataset*, *assignment* komunitas pengguna diacak secara acak sebanyak 1.000 iterasi permutasi.

- (2) Pada setiap permutasi, ECR dihitung ulang menggunakan formula yang sama (rasio *intra-community agreement* terhadap *inter-community agreement*).
- (3) Dari 1.000 nilai ECR hasil permutasi, dihitung rata-rata (*mean*) dan simpangan baku (*std*).
- (4) *Threshold echo chamber* setara dengan batas atas interval kepercayaan satu sisi, di mana nilai ECR yang melebihi *threshold* dianggap tidak dapat dijelaskan oleh distribusi acak.
- (5) Keputusannya adalah jika $ECR_{\text{observasi}} > \text{threshold}$, maka H_0 ditolak dan *dataset* diklasifikasikan sebagai *echo chamber*. Jika $ECR_{\text{observasi}} \leq \text{threshold}$, maka H_0 gagal ditolak dan *dataset* diklasifikasikan sebagai *non-echo chamber*.

IV.8.3 Hasil Uji Hipotesis

Hasil pengujian hipotesis pada ketiga *dataset* ditunjukkan pada Tabel IV.16.

Tabel IV.16. Hasil uji hipotesis *echo chamber*

<i>Dataset</i>	ECR Observasi	<i>Threshold</i> (mean + std)	Selisih (ECR - <i>Threshold</i>)	Keputusan
<i>Indonesia Vaccination</i>	0,9855	0,9990	-0,0135	<i>Non-Echo Chamber</i>
Indonesia Gelap	0,9667	1,0000	-0,0333	<i>Non-Echo Chamber</i>
Boikot Produk Israel	0,9691	0,9896	-0,0205	<i>Non-Echo Chamber</i>
Korupsi Haji	1,0272	1,0000	0,0272	<i>Echo Chamber</i>
Ijazah Jokowi	0,9711	0,9680	0,0031	<i>Echo Chamber</i>

<i>Dataset</i>	ECR Observasi	<i>Threshold</i> (mean + std)	Selisih (ECR - <i>Threshold</i>)	Keputusan
Keracunan MBG	0,9816	0,9670	0,0146	<i>Echo Chamber</i>

Untuk tiga *dataset non-echo chamber*, selisih bernilai negatif berkisar dari -0,0135 (*Indonesia Vaccination*, paling dekat dengan *threshold*) hingga -0,0333 (*Indonesia Gelap*, paling jauh dari *threshold*). *Indonesia Gelap* memiliki "jarak ke *threshold*" terlebar, yang berarti walaupun homofili-nya paling tinggi (0,5101), polarisasi semantik internal komunitas justru paling jauh dari ekspektasi *echo chamber*.

Untuk tiga *dataset echo chamber*, selisih positif berkisar dari +0,0031 (*Ijazah Jokowi*, margin sangat tipis) hingga +0,0272 (*Korupsi Haji*, margin terbesar). *Korupsi Haji* menjadi kasus paling kuat secara struktural karena ECR-nya melampaui 1,0, maka satu-satunya *dataset* di mana intra *agreement* benar-benar lebih tinggi dari inter *agreement*. *Ijazah Jokowi* memiliki margin terkecil (hanya tiga per seribu di atas *threshold*), sehingga klasifikasi *echo chamber* pada *dataset* ini perlu diinterpretasi sebagai indikasi marginal.

Pola selisih ini juga menginformasikan tipologi *echo chamber* yang berbeda-beda, yakni *Korupsi Haji* menampilkan *echo chamber* dengan bukti kuantitatif kuat (ECR > 1 dan jauh di atas *threshold*), MBG dengan bukti moderat (selisih +0,0146), dan *Ijazah Jokowi* dengan bukti marginal (selisih +0,0031).

IV.8.4 *Ground Truth* ECR

Berdasarkan narasumber dari perusahaan No Limit, yakni *data provider* dari seluruh *dataset* yang dianalisis *echo chamber*-nya, memberikan keterangan *ground truth* ECR sebagai berikut.

No.	Topik	Kategori <i>Echo-Chamber</i>
1	<i>Indonesia Vaccination</i>	<i>Non-echo chamber</i>
2	<i>Indonesia Gelap</i>	<i>Non-echo chamber</i>

No.	Topik	Kategori <i>Echo-Chamber</i>
3	Boikot Produk Israel	<i>Non-echo chamber</i>
4	Korupsi Haji	<i>Echo chamber</i>
5	Ijazah Jokowi	<i>Echo chamber</i>
6	Keracunan MBG	<i>Echo chamber</i>

IV.8.5 Kesimpulan Uji Hipotesis

Berdasarkan pengujian hipotesis menggunakan *null model* berbasis permutasi, dapat disimpulkan bahwa fenomena *echo chamber* pada Twitter (X) Indonesia tidak muncul secara seragam pada semua topik, melainkan bergantung pada karakteristik isu yang dibahas. Dari enam dataset yang diuji, tiga dataset yaitu *Indonesia Vaccination*, *Indonesia Gelap*, dan *Boikot Produk Israel* berada pada kategori *non-echo chamber* karena nilai ECR observasi tidak melampaui *threshold null model*. Sebaliknya, tiga dataset yaitu *Korupsi Haji*, *Ijazah Jokowi*, dan *Keracunan MBG* berada pada kategori *echo chamber* karena nilai ECR observasi lebih besar dari *threshold*, sehingga H_0 ditolak pada ketiga dataset tersebut.

Secara lebih rinci, *Korupsi Haji* menunjukkan indikasi *echo chamber* paling kuat karena memiliki selisih ECR terbesar di atas *threshold*, sedangkan *Ijazah Jokowi* hanya melampaui *threshold* secara marginal. Temuan ini menunjukkan bahwa intensitas *echo chamber* bersifat bertingkat, bukan hitam-putih. Hasil ini juga konsisten dengan *ground truth* dari *No Limit*, sehingga mendukung bahwa kerangka ECR yang digunakan memiliki kemampuan yang baik dalam membedakan topik yang termasuk *echo chamber* dan *non-echo chamber*.

BAB V

KESIMPULAN DAN SARAN

V.1 Kesimpulan

Kesimpulan yang dapat diambil dari tugas akhir ini, yakni sebagai berikut.

- 1) Penggunaan algoritma Leiden dan Infomap berhasil mengatasi keterbatasan algoritma Louvain dalam pengukuran *echo chamber*, baik secara struktural maupun semantik. Pada keenam dataset, Louvain menghasilkan 1.343.124 komunitas (rasio 1 : 102 terhadap Leiden) sebagai akibat dari kelemahan fundamentalnya yang tidak menjamin konektivitas internal (*badly-connected*), sedangkan Leiden, Infomap, dan konsensus *multi-level* (MLCC) menghasilkan komunitas yang sebanding (rasio 1 : 1,44 : 1,01) dan *well-connected*. Akibat fragmentasi ini, ECR berbasis Louvain secara konsisten menghasilkan nilai > 1 pada seluruh topik sehingga gagal membedakan *echo chamber* dari *non-echo chamber*. Sebaliknya, pengukuran ECR berbasis Leiden mampu menghasilkan klasifikasi yang terdiferensiasi yaitu *non-echo chamber* untuk *Indonesia Vaccination* (ECR = 0,9855), *Indonesia Gelap* (ECR = 0,9667), dan *Boikot Produk Israel* (ECR = 0,9691), serta *echo chamber* untuk *Korupsi Haji* (ECR = 1,0272), *Ijazah Jokowi* (ECR = 0,9711), dan *Keracunan MBG* (ECR = 0,9816). Klasifikasi ini konsisten 6 dari 6 dengan *ground truth* dari No Limit, sehingga pendekatan Leiden dan Infomap melalui kerangka konsensus *multi-level* terbukti lebih valid dan reliabel dibandingkan Louvain. Selain itu, kombinasi ini juga mengungkap tipologi baru, yakni *echo chamber* konsensual (*Korupsi Haji*, *MBG*) dan polarisasi struktural *non-echo* (*Indonesia Gelap*), yakni pola yang tidak tertangkap kerangka klasik berbasis Louvain.
- 2) Kalibrasi probabilistik digunakan untuk menilai kekonsistenan orientasi informasi pengguna melalui evaluasi *Expected Calibration Error* (ECE) terhadap tiga metode pembandingan, yaitu *isotonic regression*, *sigmoid (Platt) scaling*, dan *temperature scaling*. Hasil eksperimen menunjukkan bahwa *isotonic regression* secara konsisten menghasilkan kalibrasi terbaik dengan

ECE mendekati nol pada ketiga topik utama (*Indonesia Vaccination*, *Indonesia Gelap*, dan *Boikot Produk Israel*), sedangkan *sigmoid scaling* memberikan perbaikan signifikan namun tidak sebaik *isotonic*, dan *temperature scaling* tidak memberikan perbaikan berarti karena hanya melakukan transformasi linier pada logit. Penurunan ECE dari $\sim 0,21-0,28$ (*uncalibrated*) menjadi $\approx 0,0000$ (*isotonic*) membuktikan bahwa skor *confidence* model *fine-tuned* XLM-RoBERTa awalnya bersifat *overconfident*, sehingga *user leaning* yang dihitung darinya berpotensi bias secara sistematis baik pada *intra-community agreement* maupun *inter-community agreement*. Namun, eksperimen lanjutan menunjukkan bahwa kalibrasi tidak mengubah label sentimen akhir maupun arah keputusan klasifikasi *echo chamber*, sehingga kalibrasi pada akhirnya tidak diaktifkan dalam pipeline ECR. Temuan ini menegaskan bahwa kalibrasi probabilistik berperan sebagai mekanisme validasi reliabilitas estimasi preferensi, yang memberikan jaminan kuantitatif bahwa skor *user leaning* yang digunakan untuk menilai bias internal maupun eksternal komunitas memang merefleksikan tingkat keyakinan model secara konsisten.

V.2 Saran

Berikut adalah beberapa saran untuk pengembangan lebih lanjut dari topik penelitian ini.

- 1) Penelitian selanjutnya dapat mengeksplorasi algoritma deteksi komunitas lain seperti *Stochastic Block Model* (SBM) atau *Label Propagation Algorithm* (LPA) untuk memperkaya perspektif konsensus *multi-level* dan menguji sensitivitas pengukuran ECR terhadap lebih banyak metode partisi.
- 2) Pengembangan analisis pergeseran sentimen dengan resolusi temporal yang lebih halus (misalnya per minggu atau per peristiwa) dapat memberikan pemahaman yang lebih baik tentang dinamika perubahan opini dan kaitannya dengan peristiwa eksternal.
- 3) Validasi model pengukuran ECR pada platform selain X/Twitter, seperti Instagram, TikTok, atau Reddit, dapat menguji generalizabilitas pendekatan ini pada konteks interaksi sosial yang berbeda.

- 4) Pengembangan analisis yang mencakup konten visual (gambar, video) selain teks dapat memberikan pengukuran orientasi informasi yang lebih komprehensif, mengingat banyak konten di media sosial yang bersifat multimodal.
- 5) Penelitian longitudinal yang membandingkan dinamika *echo chamber* pada berbagai topik secara simultan dapat mengungkap pola sistemik pembentukan *echo chamber* yang tidak terlihat pada analisis topik tunggal.

DAFTAR PUSTAKA

- Aidira, P. N. (2025). Pengembangan model pengukuran *echo chamber* dengan analisis sentimen berbasis aspek bebas domain dan konsensus *group decision making* (Tugas Akhir Sarjana). Institut Teknologi Bandung.
- Aleksandric, A., Roy, S. S., & Nilizadeh, S. (2022). *Twitter Users' Behavioral Response to Toxic Replies*. <http://arxiv.org/abs/2210.13420>
- Amendola, M., Cavaliere, D., De Maio, C., Fenza, G., & Loia, V. (2024). Towards *echo chamber* assessment by employing aspect-based sentiment analysis and GDM consensus metrics. *Online Social Networks and Media*, 39–40. <https://doi.org/10.1016/j.osnem.2024.100276>
- Blekanov, I., Bodrunova, S. S., & Akhmetov, A. (2021). Detection of Hidden Communities in Twitter Discussions of Varying Volumes. *Future Internet*, 13(11). <https://doi.org/10.3390/FI13110295>
- Bonafilia, B. (2023). *Methods for detecting echo chambers in social media networks Using Natural Language Processing to explore the differences in language use within the Swedish NATO debate*. www.chalmers.se
- Cinelli, M., de Francisci Morales, G., Galeazzi, A., Quattrociocchi, W., & Starnini, M. (2021). The *echo chamber* effect on social media. *Proceedings of the National Academy of Sciences of the United States of America*, 118(9). <https://doi.org/10.1073/pnas.2023301118>
- Cinelli, M., De, G., Morales, F., Galeazzi, A., Quattrociocchi, W., & Starnini, M. (2021). *The echo chamber effect on social media*. <https://doi.org/10.1073/pnas.2023301118/-/DCSupplemental.y>
- Dheur, V., & Ben, S. (2023). *A Large-Scale Study of Probabilistic Calibration in Neural Network Regression*.
- Jensen, K. S. H., Taylor, M., & Williamson, S. (2023). A typology of Twitter interactions to effectively analyse engagement and evidence research impact. *Research for All*, 7(1). <https://doi.org/10.14324/RFA.07.1.11>

- Kaplan, A. M., & Haenlein, M. (2010). Users of the world, unite! The challenges and opportunities of Social Media. *Business Horizons*, 53(1), 59–68. <https://doi.org/10.1016/j.bushor.2009.09.003>
- Milo, R., Shen-Orr, S., Itzkovitz, S., Kashtan, N., Chklovskii, D., & Alon, U. (2011). Network Motifs: Simple Building Blocks of Complex Networks. *The Structure and Dynamics of Networks*, 9781400841(October), 217–220. <https://doi.org/10.1515/9781400841356.217>
- Pariser, E. (2011). *The Filter Bubble: What the Internet Is Hiding from You*. Penguin Group, The.
- Pho, K. H., Akbarzadeh, H., Parvin, H., Nejatian, S., & Alinejad-Rokny, H. (2021). A multi-level consensus function clustering ensemble. *Soft Computing*, 25(21), 13147–13165. <https://doi.org/10.1007/s00500-021-06092-7>
- Rosvall, M., & Bergstrom, C. (2008). Maps of Random Walks on Complex Networks Reveal Community Structure. *Proceedings of the National Academy of Sciences of the United States of America*, 105, 1118–1123. <https://doi.org/10.1073/pnas.0706851105>
- Sunstein, C. R. (2017). *#Republic*. Princeton University Press.
- Terren, L., & Borge, R. (2021). Echo chambers on Social Media: A Systematic Review of the Literature. *Review of Communication Research*, 9, 1–39. <https://doi.org/10.12840/ISSN.2255-4165.028>
- Traag, V. A., Waltman, L., & van Eck, N. J. (2019). From Louvain to Leiden: guaranteeing well-connected communities. *Scientific Reports*, 9(1). <https://doi.org/10.1038/s41598-019-41695-z>

Lampiran A. Analisis Masalah

Pengguna direpresentasikan sebagai simpul dan interaksi direpresentasikan sebagai sisi pada graf. Sedangkan konten mengalir dari simpul ke simpul melalui sisi dari suatu graf. *Dataset* interaksi memiliki empat kolom, yakni pengguna yang melakukan interaksi pengguna yang menjadi target interaksi, serta ada jenis interaksi, dan bobot interaksi. *Dataset* konten memiliki empat kolom, yakni semua pengguna yang terlibat dalam interaksi, serta probabilitas sentimen positif, negatif, dan netral. Kedua hal ini membentuk komunitas yang dihubungkan oleh algoritma Leiden dan Infomap.

```
1 interactions_df = pd.read_csv('interactions.csv') # columns: src, dst, tipe, weight
2 '''
3 | Kolom      | Isi |
4 | ----- | ----- |
5 | **src**    | user yang melakukan interaksi |
6 | **dst**    | user yang menjadi target interaksi |
7 | **type**   | jenis interaksi ('retweet', 'reply', 'mention', 'quote') |
8 | **weight** | bobot interaksi (default = 1) |
9
10 interactions_df = pd.DataFrame({
11     'src': ['u1', 'u2', 'u3', 'u4'],
12     'dst': ['u2', 'u3', 'u1', 'u5'],
13     'type': ['retweet', 'reply', 'mention', 'retweet'],
14     'weight': [1, 1, 1, 1]
15 })
16
17 '''
18
19 content_df = pd.read_csv('content.csv') # columns: user, p_neg, p_neu, p_pos
20 '''
21 | Kolom      | Isi |
22 | ----- | ----- |
23 | **user**   | ID user |
24 | **p_neg**  | probabilitas kontra |
25 | **p_neu**  | probabilitas netral |
26 | **p_pos**  | probabilitas pro |
27
28 content_df = pd.DataFrame({
29     'user': ['u1', 'u2', 'u3', 'u4', 'u5'],
30     'p_neg': [0.2, 0.1, 0.9, 0.4, 0.5],
31     'p_neu': [0.3, 0.6, 0.1, 0.4, 0.3],
32     'p_pos': [0.5, 0.3, 0.0, 0.2, 0.2]
33 })
34 '''
```

Lampiran B. Pengguna Pasif dan Hubungan Tidak Simetris

Pengguna pasif dalam jaringan media sosial merujuk pada akun yang memiliki tingkat aktivitas interaksi yang rendah atau bersifat satu arah. Pengguna jenis ini umumnya hanya melakukan tindakan seperti membaca konten, melakukan *like*, atau sesekali *me-retweet* tanpa terlibat dalam percakapan lanjutan seperti *reply* atau *mention*. Dalam konteks graf interaksi, pengguna pasif sering kali memiliki derajat (*degree*) yang sangat kecil, bahkan hanya terhubung melalui satu atau dua sisi. Keberadaan pengguna pasif menyebabkan terbentuknya banyak simpul dengan konektivitas rendah, sehingga struktur jaringan menjadi jarang (*sparse*) dan tidak merata.

Hubungan yang tidak simetris dalam jaringan media sosial terjadi ketika interaksi antar pengguna bersifat satu arah. Contohnya adalah ketika seorang pengguna *me-retweet* atau *me-mention* pengguna lain tanpa adanya interaksi balasan. Dalam representasi graf berarah, kondisi ini tercermin sebagai sisi dari simpul sumber ke simpul tujuan tanpa sisi balik yang sepadan. Hubungan semacam ini umum terjadi pada media sosial, terutama dalam interaksi antara pengguna biasa dan akun berpengaruh seperti tokoh publik atau media massa.

Lampiran C. Gambaran Umum Solusi

BEAM Notation adalah diagram yang diperkenalkan oleh Prock & Ekaputra (2025). Dokumentasi BEAM Notation dapat dilihat pada GitHub: https://github.com/wu-semsys/beam_tutorial/blob/main/BEAM-instructions.pdf

BEAM Notation yang terlampir, yakni ada pada halaman 40 yang dapat dilihat di: <https://drive.google.com/file/d/1GLEJ6RfB7v5cXSTbVdsXfarn1Rk3tisW/view?usp=sharing>

